ch01 머신러닝 시작하기

- Machine Learning with sklearn @ DJ,Lim
- update : 2022/05

학습 내용

- 머신러닝을 학습하기 위한 기본 라이브러리 이해 및 실습
- 머신러닝 모델 만들어보기

01 기본 개념 이해하기

- **샘플(sample) or 데이터 포인터(data point)** : 하나의 개체 혹은 행을 말한다.
- 특성 or 속성(feature) : 샘플의 속성, 즉 열을 가르킨다.

02 기본 라이브러리 이해하기

scikit-learn(사이킷 런)

- 오픈 소스입니다.
- 매우 인기 높고 독보적인 파이썬 머신러닝 라이브러리입니다.
- url : http://scikit-learn.org/stable/documentation
- 사용자 가이드 : https://scikit-learn.org/stable/user_guide.html

Numpy

- 파이썬으로 과학 계산을 하기 위한 꼭 필요한 패키지
- 다차원 배열을 위한 기능
- 선형 대수 연산 기능
- 푸리에 변환 같은 고수준 수학 함수와 유사 난수 생성기 기능
- python의 데이터 처리에 비해 매우 빠른 속도를 보여주어 pandas, 딥러닝 모델의 기본 자료형으로 사용
- url : https://www.numpy.org/

SciPy

- SciPy(https://www.scipy.org/scipylib) 과학 계산용 함수를 모아놓은 파이썬 패키지.
- 고성능 선형대수 기능, 함수 최적화, 신호 처리, 특수한 수학 함수와 통계 분포 등
- 희소 행렬 기능

Matplotlib

- 파이썬 대표적인 과학 계산용 그래프 라이브러리

Pandas

- 데이터 처리와 분석을 위한 파이썬 라이브러리

- url : https://pandas.pydata.org/
- R의 data.frame을 본떠 설계한 **Dataframe**이라는 데이터 구조를 기반으로 만들어짐.
- SQL 처럼 테이블 쿼리나 조인을 수행 가능함.
- xlsx, csv등의 다양한 파일과 데이터베이스에서 데이터를 읽어들 일 수 있음.
- https://pandas.pydata.org/pandas-docs/stable/getting_started/10min.html

mglearn

- 파이썬 라이브러리를 활용한 머신러닝 저자가 작성한 라이브러리
- 기본 머신러닝 내용 설명을 위한 그래프(knn 알고리즘 설명 등)

In [ ]:
```
from IPython.display import display, Image
```

03 라이브러리 소프트웨어 버전 확인

라이브러리이름.__version__
라이브러리이름.version

In [ ]:
```
import sys
print("파이썬 버전 :", sys.version)
```

```
파이썬 버전 : 3.8.5 (default, Sep  4 2020, 02:22:02)
[Clang 10.0.0 ]
```

In [ ]:
```
import pandas as pd
print("판다스 버전 :", pd.__version__)
```

```
판다스 버전 : 1.1.3
```

In [ ]:
```
import matplotlib
import numpy as np
import scipy as sp
```

직접 해보기1

- matplotlib, numpy, seaborn, scipy의 각각의 버전을 확인해 보자.

- 추가 라이브러리를 설치할 때 명령
  - pip install [라이브러리명]

04 머신러닝 모델을 위한 iris 데이터를 준비

데이터 : 붓꽃

- 종류 : setosa, versicolor, virginica
- 데이터 내용 : 붓꽃의 꽃잎과 꽃받침
- 우리가 해결하려고 하는 문제 : 데이터를 주고 붓꽃의 종류 예측하기

In [ ]:
```
display(Image(filename='img/iris_setosa01.png'))
```



Iris setosa
Photo: Radomil, CC BY-SA 3.0



Iris versicolor
Photo: Dlanglois, CC BY-SA 3.0



Iris virginica
Photo: Frank Mayfield, CC BY-SA 2.0

Source: Wikimedia Commons (adapted: cropped & resized). Licensed CC BY-SA.

용어 이해하기

- **클래스(class)** : 출력될 수 있는 값들. 붓꽃의 종류들, 붓꽃의 종류는 세 클래스 중 하나에 속한다.
  - (구글 용어집) One of a set of enumerated target values for a label.
  - 레이블에 대한 열거된 목표값의 집합 중의 하나.
- **레이블(label)** : 데이터 포인트 하나(붓꽃 하나)에 대한 기대 출력. **특정 데이터 포인트에 대한 출력**
  - (구글 용어집) 지도학습에서 예에 대한 답변 또는 결과 부분

데이터 준비

- scikit-learn에서 제공하는 기본 데이터 자료형를 이용한다.
- load_iris가 반환한 iris객체는 파이썬의 딕셔너리(Dictionary)와 유사한 Bunch 클래스의 객체

In [ ]:
```
from sklearn.datasets import load_iris
iris = load_iris()
iris
```

Out[ ]:
```
{'data': array([[5.1, 3.5, 1.4, 0.2],
        [4.9, 3. , 1.4, 0.2],
        [4.7, 3.2, 1.3, 0.2],
        [4.6, 3.1, 1.5, 0.2],
        [5. , 3.6, 1.4, 0.2],
        [5.4, 3.9, 1.7, 0.4],
        [4.6, 3.4, 1.4, 0.3],
        [5. , 3.4, 1.5, 0.2],
        [4.4, 2.9, 1.4, 0.2],
        [4.9, 3.1, 1.5, 0.1],
        [5.4, 3.7, 1.5, 0.2],
        [4.8, 3.4, 1.6, 0.2],
        [4.8, 3. , 1.4, 0.1],
        [4.3, 3. , 1.1, 0.1],
        [5.8, 4. , 1.2, 0.2],
        [5.7, 4.4, 1.5, 0.4],
        [5.4, 3.9, 1.3, 0.4],
        [5.1, 3.5, 1.4, 0.3],
        [5.7, 3.8, 1.7, 0.3],
        [5.1, 3.8, 1.5, 0.3],
        [5.4, 3.4, 1.7, 0.2],
        [5.1, 3.7, 1.5, 0.4],
        [4.6, 3.6, 1. , 0.2],
        [5.1, 3.3, 1.7, 0.5],
```

```
[4.8, 3.4, 1.9, 0.2],
[5. , 3. , 1.6, 0.2],
[5. , 3.4, 1.6, 0.4],
[5.2, 3.5, 1.5, 0.2],
[5.2, 3.4, 1.4, 0.2],
[4.7, 3.2, 1.6, 0.2],
[4.8, 3.1, 1.6, 0.2],
[5.4, 3.4, 1.5, 0.4],
[5.2, 4.1, 1.5, 0.1],
[5.5, 4.2, 1.4, 0.2],
[4.9, 3.1, 1.5, 0.2],
[5. , 3.2, 1.2, 0.2],
[5.5, 3.5, 1.3, 0.2],
[4.9, 3.6, 1.4, 0.1],
[4.4, 3. , 1.3, 0.2],
[5.1, 3.4, 1.5, 0.2],
[5. , 3.5, 1.3, 0.3],
[4.5, 2.3, 1.3, 0.3],
[4.4, 3.2, 1.3, 0.2],
[5. , 3.5, 1.6, 0.6],
[5.1, 3.8, 1.9, 0.4],
[4.8, 3. , 1.4, 0.3],
[5.1, 3.8, 1.6, 0.2],
[4.6, 3.2, 1.4, 0.2],
[5.3, 3.7, 1.5, 0.2],
[5. , 3.3, 1.4, 0.2],
[7. , 3.2, 4.7, 1.4],
[6.4, 3.2, 4.5, 1.5],
[6.9, 3.1, 4.9, 1.5],
[5.5, 2.3, 4. , 1.3],
[6.5, 2.8, 4.6, 1.5],
[5.7, 2.8, 4.5, 1.3],
[6.3, 3.3, 4.7, 1.6],
[4.9, 2.4, 3.3, 1. ],
[6.6, 2.9, 4.6, 1.3],
[5.2, 2.7, 3.9, 1.4],
[5. , 2. , 3.5, 1. ],
[5.9, 3. , 4.2, 1.5],
[6. , 2.2, 4. , 1. ],
[6.1, 2.9, 4.7, 1.4],
[5.6, 2.9, 3.6, 1.3],
[6.7, 3.1, 4.4, 1.4],
[5.6, 3. , 4.5, 1.5],
[5.8, 2.7, 4.1, 1. ],
[6.2, 2.2, 4.5, 1.5],
[5.6, 2.5, 3.9, 1.1],
[5.9, 3.2, 4.8, 1.8],
[6.1, 2.8, 4. , 1.3],
[6.3, 2.5, 4.9, 1.5],
[6.1, 2.8, 4.7, 1.2],
[6.4, 2.9, 4.3, 1.3],
[6.6, 3. , 4.4, 1.4],
[6.8, 2.8, 4.8, 1.4],
[6.7, 3. , 5. , 1.7],
[6. , 2.9, 4.5, 1.5],
[5.7, 2.6, 3.5, 1. ],
[5.5, 2.4, 3.8, 1.1],
[5.5, 2.4, 3.7, 1. ],
[5.8, 2.7, 3.9, 1.2],
[6. , 2.7, 5.1, 1.6],
[5.4, 3. , 4.5, 1.5],
[6. , 3.4, 4.5, 1.6],
[6.7, 3.1, 4.7, 1.5],
[6.3, 2.3, 4.4, 1.3],
[5.6, 3. , 4.1, 1.3],
```

```
        [5.5, 2.5, 4. , 1.3],
        [5.5, 2.6, 4.4, 1.2],
        [6.1, 3. , 4.6, 1.4],
        [5.8, 2.6, 4. , 1.2],
        [5. , 2.3, 3.3, 1. ],
        [5.6, 2.7, 4.2, 1.3],
        [5.7, 3. , 4.2, 1.2],
        [5.7, 2.9, 4.2, 1.3],
        [6.2, 2.9, 4.3, 1.3],
        [5.1, 2.5, 3. , 1.1],
        [5.7, 2.8, 4.1, 1.3],
        [6.3, 3.3, 6. , 2.5],
        [5.8, 2.7, 5.1, 1.9],
        [7.1, 3. , 5.9, 2.1],
        [6.3, 2.9, 5.6, 1.8],
        [6.5, 3. , 5.8, 2.2],
        [7.6, 3. , 6.6, 2.1],
        [4.9, 2.5, 4.5, 1.7],
        [7.3, 2.9, 6.3, 1.8],
        [6.7, 2.5, 5.8, 1.8],
        [7.2, 3.6, 6.1, 2.5],
        [6.5, 3.2, 5.1, 2. ],
        [6.4, 2.7, 5.3, 1.9],
        [6.8, 3. , 5.5, 2.1],
        [5.7, 2.5, 5. , 2. ],
        [5.8, 2.8, 5.1, 2.4],
        [6.4, 3.2, 5.3, 2.3],
        [6.5, 3. , 5.5, 1.8],
        [7.7, 3.8, 6.7, 2.2],
        [7.7, 2.6, 6.9, 2.3],
        [6. , 2.2, 5. , 1.5],
        [6.9, 3.2, 5.7, 2.3],
        [5.6, 2.8, 4.9, 2. ],
        [7.7, 2.8, 6.7, 2. ],
        [6.3, 2.7, 4.9, 1.8],
        [6.7, 3.3, 5.7, 2.1],
        [7.2, 3.2, 6. , 1.8],
        [6.2, 2.8, 4.8, 1.8],
        [6.1, 3. , 4.9, 1.8],
        [6.4, 2.8, 5.6, 2.1],
        [7.2, 3. , 5.8, 1.6],
        [7.4, 2.8, 6.1, 1.9],
        [7.9, 3.8, 6.4, 2. ],
        [6.4, 2.8, 5.6, 2.2],
        [6.3, 2.8, 5.1, 1.5],
        [6.1, 2.6, 5.6, 1.4],
        [7.7, 3. , 6.1, 2.3],
        [6.3, 3.4, 5.6, 2.4],
        [6.4, 3.1, 5.5, 1.8],
        [6. , 3. , 4.8, 1.8],
        [6.9, 3.1, 5.4, 2.1],
        [6.7, 3.1, 5.6, 2.4],
        [6.9, 3.1, 5.1, 2.3],
        [5.8, 2.7, 5.1, 1.9],
        [6.8, 3.2, 5.9, 2.3],
        [6.7, 3.3, 5.7, 2.5],
        [6.7, 3. , 5.2, 2.3],
        [6.3, 2.5, 5. , 1.9],
        [6.5, 3. , 5.2, 2. ],
        [6.2, 3.4, 5.4, 2.3],
        [5.9, 3. , 5.1, 1.8]]),
 'target': array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0,
       0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,
       0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
```

```
       1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
       1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2,
       2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2,
       2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2]),
 'frame': None,
 'target_names': array(['setosa', 'versicolor', 'virginica'], dtype='<U10'),
 'DESCR': '.. _iris_dataset:\n\nIris plants dataset\n--------------------\n\n**D
ata Set Characteristics:**\n\n    :Number of Instances: 150 (50 in each of three
classes)\n    :Number of Attributes: 4 numeric, predictive attributes and the cl
ass\n    :Attribute Information:\n        - sepal length in cm\n        - sepal
width in cm\n        - petal length in cm\n        - petal width in cm\n
- class:\n                - Iris-Setosa\n                - Iris-Versicolour\n
- Iris-Virginica\n                \n    :Summary Statistics:\n\n    ============
== ==== ==== ======= ===== ====================\n                    Min  Max
Mean    SD   Class Correlation\n    ============== ==== ==== ======= ===== =====
==============\n    sepal length:   4.3  7.9   5.84   0.83    0.7826\n    sepal
width:    2.0  4.4   3.05   0.43   -0.4194\n    petal length:   1.0  6.9   3.76
1.76    0.9490  (high!)\n    petal width:    0.1  2.5   1.20   0.76    0.9565
(high!)\n    ============== ==== ==== ======= ===== ====================\n\n
:Missing Attribute Values: None\n    :Class Distribution: 33.3% for each of 3 cl
asses.\n    :Creator: R.A. Fisher\n    :Donor: Michael Marshall (MARSHALL%PLU@i
o.arc.nasa.gov)\n    :Date: July, 1988\n\nThe famous Iris database, first used b
y Sir R.A. Fisher. The dataset is taken\nfrom Fisher\'s paper. Note that it\'s t
he same as in R, but not as in the UCI\nMachine Learning Repository, which has t
wo wrong data points.\n\nThis is perhaps the best known database to be found in
the\npattern recognition literature.  Fisher\'s paper is a classic in the field
and\nis referenced frequently to this day.  (See Duda & Hart, for example.)  The
\ndata set contains 3 classes of 50 instances each, where each class refers to a
\ntype of iris plant.  One class is linearly separable from the other 2; the\nla
tter are NOT linearly separable from each other.\n\n.. topic:: References\n\n
- Fisher, R.A. "The use of multiple measurements in taxonomic problems"\n     An
nual Eugenics, 7, Part II, 179-188 (1936); also in "Contributions to\n     Mathe
matical Statistics" (John Wiley, NY, 1950).\n   - Duda, R.O., & Hart, P.E. (197
3) Pattern Classification and Scene Analysis.\n     (Q327.D83) John Wiley & Son
s.  ISBN 0-471-22361-1.  See page 218.\n   - Dasarathy, B.V. (1980) "Nosing Arou
nd the Neighborhood: A New System\n     Structure and Classification Rule for Re
cognition in Partially Exposed\n     Environments".  IEEE Transactions on Patter
n Analysis and Machine\n     Intelligence, Vol. PAMI-2, No. 1, 67-71.\n   - Gate
s, G.W. (1972) "The Reduced Nearest Neighbor Rule".  IEEE Transactions\n     on
Information Theory, May 1972, 431-433.\n   - See also: 1988 MLC Proceedings, 54-
64.  Cheeseman et al"s AUTOCLASS II\n     conceptual clustering system finds 3 c
lasses in the data.\n   - Many, many more ...',
 'feature_names': ['sepal length (cm)',
  'sepal width (cm)',
  'petal length (cm)',
  'petal width (cm)'],
 'filename': '/Users/toto/Documents/anaconda3/lib/python3.8/site-packages/sklear
n/datasets/data/iris.csv'}
```

In [ ]:
```
# iris 데이터 셋의 key값들
print( type(iris) )
print(iris.keys())          # iris가 가진 값들
print(iris['target_names']) # 붓꽃의 label의 종류명
print(iris['target'])       # 붓꽃의 종류의 label의 값
print(iris['data'])         # 붓꽃의 꽃잎과 꽃받침의 값
```

```
<class 'sklearn.utils.Bunch'>
dict_keys(['data', 'target', 'frame', 'target_names', 'DESCR', 'feature_names',
'filename'])
['setosa' 'versicolor' 'virginica']
[0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
 0 0 0 0 0 0 0 0 0 0 0 0 0 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1
 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 2 2 2 2 2 2 2 2 2 2 2 2
 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2
 2 2]
```

```
[[5.1 3.5 1.4 0.2]
 [4.9 3.  1.4 0.2]
 [4.7 3.2 1.3 0.2]
 [4.6 3.1 1.5 0.2]
 [5.  3.6 1.4 0.2]
 [5.4 3.9 1.7 0.4]
 [4.6 3.4 1.4 0.3]
 [5.  3.4 1.5 0.2]
 [4.4 2.9 1.4 0.2]
 [4.9 3.1 1.5 0.1]
 [5.4 3.7 1.5 0.2]
 [4.8 3.4 1.6 0.2]
 [4.8 3.  1.4 0.1]
 [4.3 3.  1.1 0.1]
 [5.8 4.  1.2 0.2]
 [5.7 4.4 1.5 0.4]
 [5.4 3.9 1.3 0.4]
 [5.1 3.5 1.4 0.3]
 [5.7 3.8 1.7 0.3]
 [5.1 3.8 1.5 0.3]
 [5.4 3.4 1.7 0.2]
 [5.1 3.7 1.5 0.4]
 [4.6 3.6 1.  0.2]
 [5.1 3.3 1.7 0.5]
 [4.8 3.4 1.9 0.2]
 [5.  3.  1.6 0.2]
 [5.  3.4 1.6 0.4]
 [5.2 3.5 1.5 0.2]
 [5.2 3.4 1.4 0.2]
 [4.7 3.2 1.6 0.2]
 [4.8 3.1 1.6 0.2]
 [5.4 3.4 1.5 0.4]
 [5.2 4.1 1.5 0.1]
 [5.5 4.2 1.4 0.2]
 [4.9 3.1 1.5 0.2]
 [5.  3.2 1.2 0.2]
 [5.5 3.5 1.3 0.2]
 [4.9 3.6 1.4 0.1]
 [4.4 3.  1.3 0.2]
 [5.1 3.4 1.5 0.2]
 [5.  3.5 1.3 0.3]
 [4.5 2.3 1.3 0.3]
 [4.4 3.2 1.3 0.2]
 [5.  3.5 1.6 0.6]
 [5.1 3.8 1.9 0.4]
 [4.8 3.  1.4 0.3]
 [5.1 3.8 1.6 0.2]
 [4.6 3.2 1.4 0.2]
 [5.3 3.7 1.5 0.2]
 [5.  3.3 1.4 0.2]
 [7.  3.2 4.7 1.4]
 [6.4 3.2 4.5 1.5]
 [6.9 3.1 4.9 1.5]
 [5.5 2.3 4.  1.3]
 [6.5 2.8 4.6 1.5]
 [5.7 2.8 4.5 1.3]
 [6.3 3.3 4.7 1.6]
 [4.9 2.4 3.3 1. ]
 [6.6 2.9 4.6 1.3]
 [5.2 2.7 3.9 1.4]
 [5.  2.  3.5 1. ]
 [5.9 3.  4.2 1.5]
 [6.  2.2 4.  1. ]
 [6.1 2.9 4.7 1.4]
 [5.6 2.9 3.6 1.3]
```

```
[6.7 3.1 4.4 1.4]
[5.6 3.  4.5 1.5]
[5.8 2.7 4.1 1. ]
[6.2 2.2 4.5 1.5]
[5.6 2.5 3.9 1.1]
[5.9 3.2 4.8 1.8]
[6.1 2.8 4.  1.3]
[6.3 2.5 4.9 1.5]
[6.1 2.8 4.7 1.2]
[6.4 2.9 4.3 1.3]
[6.6 3.  4.4 1.4]
[6.8 2.8 4.8 1.4]
[6.7 3.  5.  1.7]
[6.  2.9 4.5 1.5]
[5.7 2.6 3.5 1. ]
[5.5 2.4 3.8 1.1]
[5.5 2.4 3.7 1. ]
[5.8 2.7 3.9 1.2]
[6.  2.7 5.1 1.6]
[5.4 3.  4.5 1.5]
[6.  3.4 4.5 1.6]
[6.7 3.1 4.7 1.5]
[6.3 2.3 4.4 1.3]
[5.6 3.  4.1 1.3]
[5.5 2.5 4.  1.3]
[5.5 2.6 4.4 1.2]
[6.1 3.  4.6 1.4]
[5.8 2.6 4.  1.2]
[5.  2.3 3.3 1. ]
[5.6 2.7 4.2 1.3]
[5.7 3.  4.2 1.2]
[5.7 2.9 4.2 1.3]
[6.2 2.9 4.3 1.3]
[5.1 2.5 3.  1.1]
[5.7 2.8 4.1 1.3]
[6.3 3.3 6.  2.5]
[5.8 2.7 5.1 1.9]
[7.1 3.  5.9 2.1]
[6.3 2.9 5.6 1.8]
[6.5 3.  5.8 2.2]
[7.6 3.  6.6 2.1]
[4.9 2.5 4.5 1.7]
[7.3 2.9 6.3 1.8]
[6.7 2.5 5.8 1.8]
[7.2 3.6 6.1 2.5]
[6.5 3.2 5.1 2. ]
[6.4 2.7 5.3 1.9]
[6.8 3.  5.5 2.1]
[5.7 2.5 5.  2. ]
[5.8 2.8 5.1 2.4]
[6.4 3.2 5.3 2.3]
[6.5 3.  5.5 1.8]
[7.7 3.8 6.7 2.2]
[7.7 2.6 6.9 2.3]
[6.  2.2 5.  1.5]
[6.9 3.2 5.7 2.3]
[5.6 2.8 4.9 2. ]
[7.7 2.8 6.7 2. ]
[6.3 2.7 4.9 1.8]
[6.7 3.3 5.7 2.1]
[7.2 3.2 6.  1.8]
[6.2 2.8 4.8 1.8]
[6.1 3.  4.9 1.8]
[6.4 2.8 5.6 2.1]
[7.2 3.  5.8 1.6]
```

```
[7.4 2.8 6.1 1.9]
[7.9 3.8 6.4 2. ]
[6.4 2.8 5.6 2.2]
[6.3 2.8 5.1 1.5]
[6.1 2.6 5.6 1.4]
[7.7 3.  6.1 2.3]
[6.3 3.4 5.6 2.4]
[6.4 3.1 5.5 1.8]
[6.  3.  4.8 1.8]
[6.9 3.1 5.4 2.1]
[6.7 3.1 5.6 2.4]
[6.9 3.1 5.1 2.3]
[5.8 2.7 5.1 1.9]
[6.8 3.2 5.9 2.3]
[6.7 3.3 5.7 2.5]
[6.7 3.  5.2 2.3]
[6.3 2.5 5.  1.9]
[6.5 3.  5.2 2. ]
[6.2 3.4 5.4 2.3]
[5.9 3.  5.1 1.8]]
```

In [ ]:
```
# iris 데이터 셋의 설명 확인
iris['DESCR']
```

Out[ ]:
```
'.. _iris_dataset:\n\nIris plants dataset\n--------------------\n\n**Data Set Ch
aracteristics:**\n\n    :Number of Instances: 150 (50 in each of three classes)
\n    :Number of Attributes: 4 numeric, predictive attributes and the class\n
:Attribute Information:\n        - sepal length in cm\n        - sepal width in
cm\n        - petal length in cm\n        - petal width in cm\n        - clas
s:\n                - Iris-Setosa\n                - Iris-Versicolour\n
- Iris-Virginica\n                \n    :Summary Statistics:\n\n    ============
== ==== ==== ======= ===== ====================\n                    Min  Max
Mean    SD   Class Correlation\n    ============== ==== ==== ======= ===== =====
===============\n    sepal length:   4.3  7.9   5.84   0.83    0.7826\n    sepal
width:    2.0  4.4   3.05   0.43   -0.4194\n    petal length:   1.0  6.9   3.76
1.76    0.9490  (high!)\n    petal width:    0.1  2.5   1.20   0.76    0.9565
(high!)\n    ============== ==== ==== ======= ===== ====================\n\n
:Missing Attribute Values: None\n    :Class Distribution: 33.3% for each of 3 cl
asses.\n    :Creator: R.A. Fisher\n    :Donor: Michael Marshall (MARSHALL%PLU@i
o.arc.nasa.gov)\n    :Date: July, 1988\n\nThe famous Iris database, first used b
y Sir R.A. Fisher. The dataset is taken\nfrom Fisher\'s paper. Note that it\'s t
he same as in R, but not as in the UCI\nMachine Learning Repository, which has t
wo wrong data points.\n\nThis is perhaps the best known database to be found in
the\npattern recognition literature.  Fisher\'s paper is a classic in the field
and\nis referenced frequently to this day.  (See Duda & Hart, for example.)  The
\ndata set contains 3 classes of 50 instances each, where each class refers to a
\ntype of iris plant.  One class is linearly separable from the other 2; the\nla
tter are NOT linearly separable from each other.\n\n.. topic:: References\n\n
- Fisher, R.A. "The use of multiple measurements in taxonomic problems"\n     An
nual Eugenics, 7, Part II, 179-188 (1936); also in "Contributions to\n     Mathe
matical Statistics" (John Wiley, NY, 1950).\n   - Duda, R.O., & Hart, P.E. (197
3) Pattern Classification and Scene Analysis.\n     (Q327.D83) John Wiley & Son
s.  ISBN 0-471-22361-1.  See page 218.\n   - Dasarathy, B.V. (1980) "Nosing Arou
nd the Neighborhood: A New System\n     Structure and Classification Rule for Re
cognition in Partially Exposed\n     Environments".  IEEE Transactions on Patter
n Analysis and Machine\n     Intelligence, Vol. PAMI-2, No. 1, 67-71.\n   - Gate
s, G.W. (1972) "The Reduced Nearest Neighbor Rule".  IEEE Transactions\n     on
Information Theory, May 1972, 431-433.\n   - See also: 1988 MLC Proceedings, 54-
64.  Cheeseman et al"s AUTOCLASS II\n     conceptual clustering system finds 3 c
lasses in the data.\n   - Many, many more ...'
```

In [ ]:
```
print( iris['data'].shape )   # iris 데이터의 'data'의 값이 가지는 행열 확인
print( iris['feature_names']) # iris 데이터 셋의 피처이름 확인
print( iris['data'][:5])      # 5개의 데이터 확인
```

```
print( iris['target_names'][:5])
print( iris['target'][:5])
```

```
(150, 4)
['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal width (c
m)']
[[5.1 3.5 1.4 0.2]
 [4.9 3.  1.4 0.2]
 [4.7 3.2 1.3 0.2]
 [4.6 3.1 1.5 0.2]
 [5.  3.6 1.4 0.2]]
['setosa' 'versicolor' 'virginica']
[0 0 0 0 0]
```

데이터의 크기 확인

- 데이터의 사이즈 확인 : 데이터.shape
- 데이터의 자료형 확인 : type(데이터자료형)

In [ ]:
```
print(iris['target'].shape)  # 타켓
print(iris['data'].shape)
print(type(iris['target']) , type(iris['data']) )
```

```
(150,)
(150, 4)
<class 'numpy.ndarray'> <class 'numpy.ndarray'>
```

05 데이터를 훈련 데이터와 테스트 데이터로 나누기

- 우리는 모델을 만들고 모델의 성능 측정을 위해 학습용 데이터 셋과 테스트용 데이터 셋으로 나누어준다.
- 학습용 데이터 : 모델 선택 후, 실제 학습에 사용하는 데이터 셋(실제 문제지의 문제)
- 테스트 데이터 : 학습 후, 실제 잘 동작하는지 확인하기 위한 데이터 (모의고사시험)
- 내용 : 모델을 새 데이터에 적용하기 전에 우리가 만든 모델이 잘 동작하는지 확인하기 위해 테스트 데이터를 활용하여 평가한다.

훈련 데이터 셋(training set) : 머신러닝 모델을 만들 때 쓰는 데이터 셋

테스트 데이터 셋(test set) : 모델이 얼마나 잘 작동하는지 쓰는 데이터 셋

- 테스트 데이터 셋을 다른 말로 홀드아웃(hold-out data)이라 한다.
  - 홀드 아웃 데이터 : 훈련중에 의도적으로 사용되지 않은 검증 데이터 세트 및 테스트 데이터 셋. 모델이 일반화 능력을 평가하는데 도움이 된다.

- scikit-learn은 데이터 셋을 나눠주기 위해 train_test_split 함수를 이용.
- train_test_split 함수는 기본적으로 75% 훈련 세트, 25%의 테스트 세트

In [ ]:
```
from sklearn.model_selection import train_test_split

X = iris['data']
y = iris['target']

X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=0)
```

In [ ]:
```
# 데이터 사이즈
print(X_train.shape)    # 훈련 데이터 셋 사이즈
```

```
print(X_test.shape)     # 테스트 데이터 셋 사이즈
print(y_train.shape)    # 훈련 데이터 레이블 사이즈
print(y_test.shape)     # 테스트 데이터 레이블 사이즈
```

```
(112, 4)
(38, 4)
(112,)
(38,)
```

06. 데이터 살펴보기 - 시각화

- 머신러닝 모델을 만들기 전 머신러닝 없이도 풀 수 있는 문제는 아닌지, 혹은 필요한 정보가 누락이 없는지 확인
- 산점도(SCATTER PLOT)를 이용하여 확인.
  - 한특성을 x축에 놓고 다른 하나는 y축에 놓아 데이터를 점으로 나타내는 그래프
- 2개의 변수만 사용 가능하여 산점도 행렬(scatter matrix)를 사용

In [ ]:
```
import seaborn as sns
```

In [ ]:
```
print(iris['feature_names'])  # 붓꽃의 꽃잎과 꽃받침의 feature 이름
```

```
['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal width (cm)']
```

In [ ]:
```
iris_df = pd.DataFrame(X_train, columns=iris.feature_names)
iris_df['species'] = y_train
iris_df['species'] = iris_df['species'].astype('category') # 자료형 변환
iris_df.head()
```

Out[ ]:

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	species
0	5.9	3.0	4.2	1.5	1
1	5.8	2.6	4.0	1.2	1
2	6.8	3.0	5.5	2.1	2
3	4.7	3.2	1.3	0.2	0
4	6.9	3.1	5.1	2.3	2

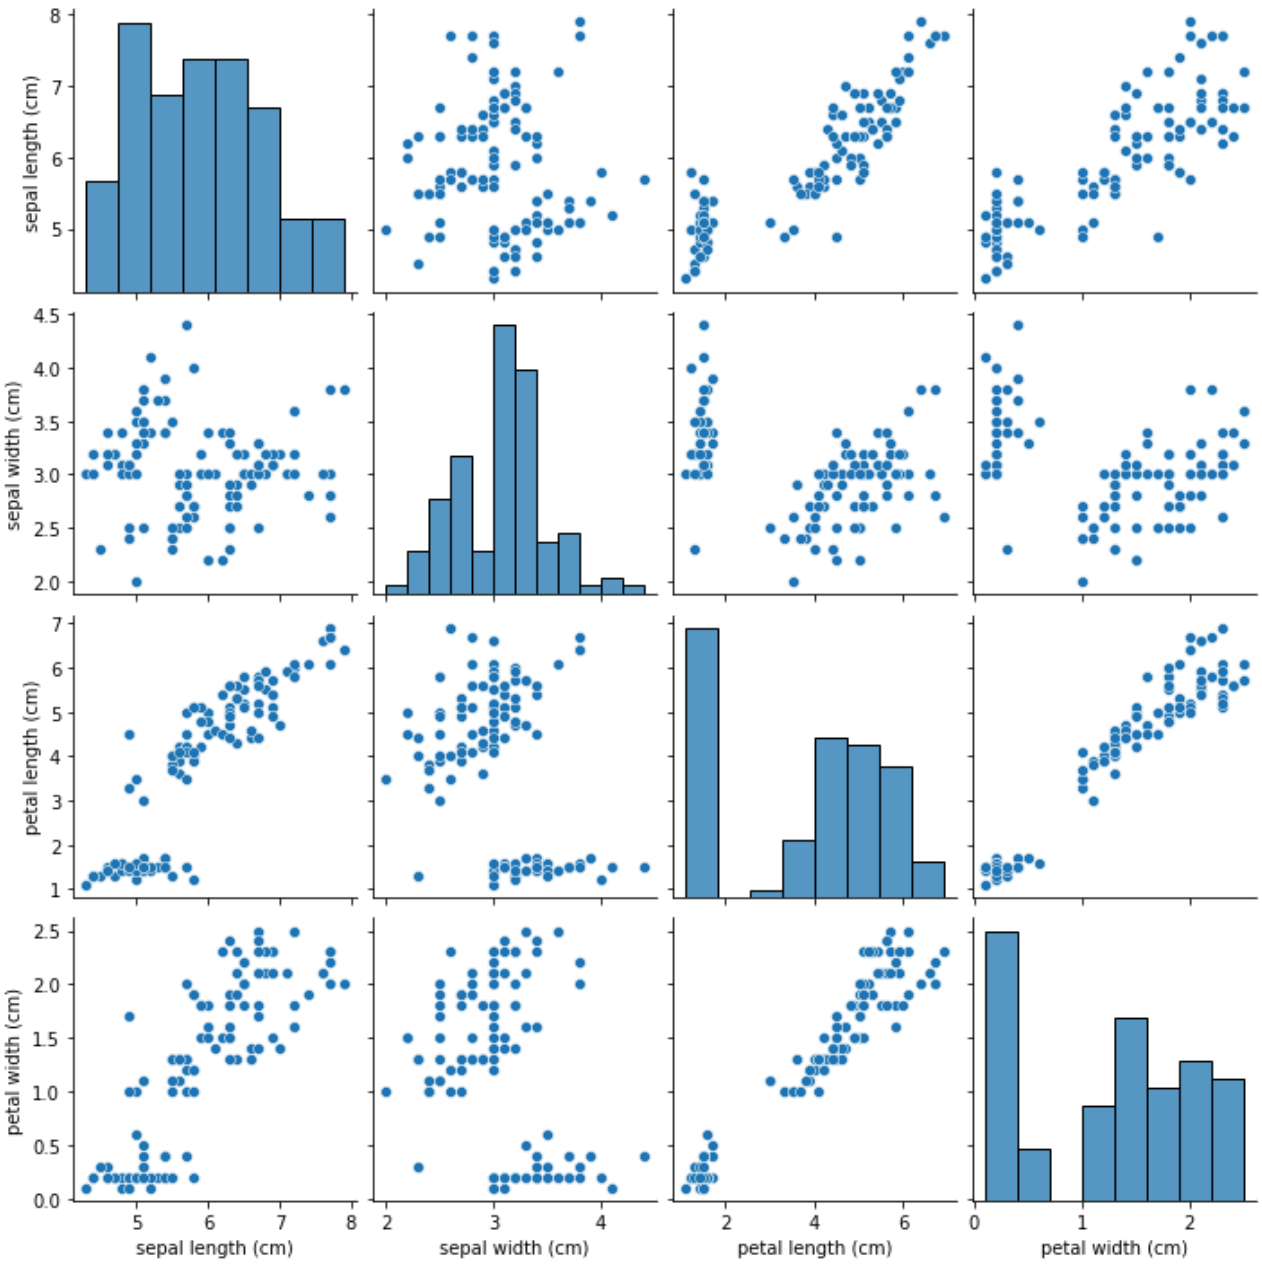
In [ ]:
```
print(iris_df.shape)
print(iris_df.info())
```

```
(112, 5)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 112 entries, 0 to 111
Data columns (total 5 columns):
 #   Column             Non-Null Count  Dtype   
---  ------             --------------  -----   
 0   sepal length (cm)  112 non-null    float64 
 1   sepal width (cm)   112 non-null    float64 
 2   petal length (cm)  112 non-null    float64 
 3   petal width (cm)   112 non-null    float64 
 4   species            112 non-null    category
dtypes: category(1), float64(4)
memory usage: 3.8 KB
None
```

seaborn를 활용한 산점도 행렬 확인

In [ ]:
```
sns.pairplot(iris_df.iloc[ : ,0:4])   # 1~4열 선택
```

Out[ ]:
```
<seaborn.axisgrid.PairGrid at 0x7f850ad86ac0>
```

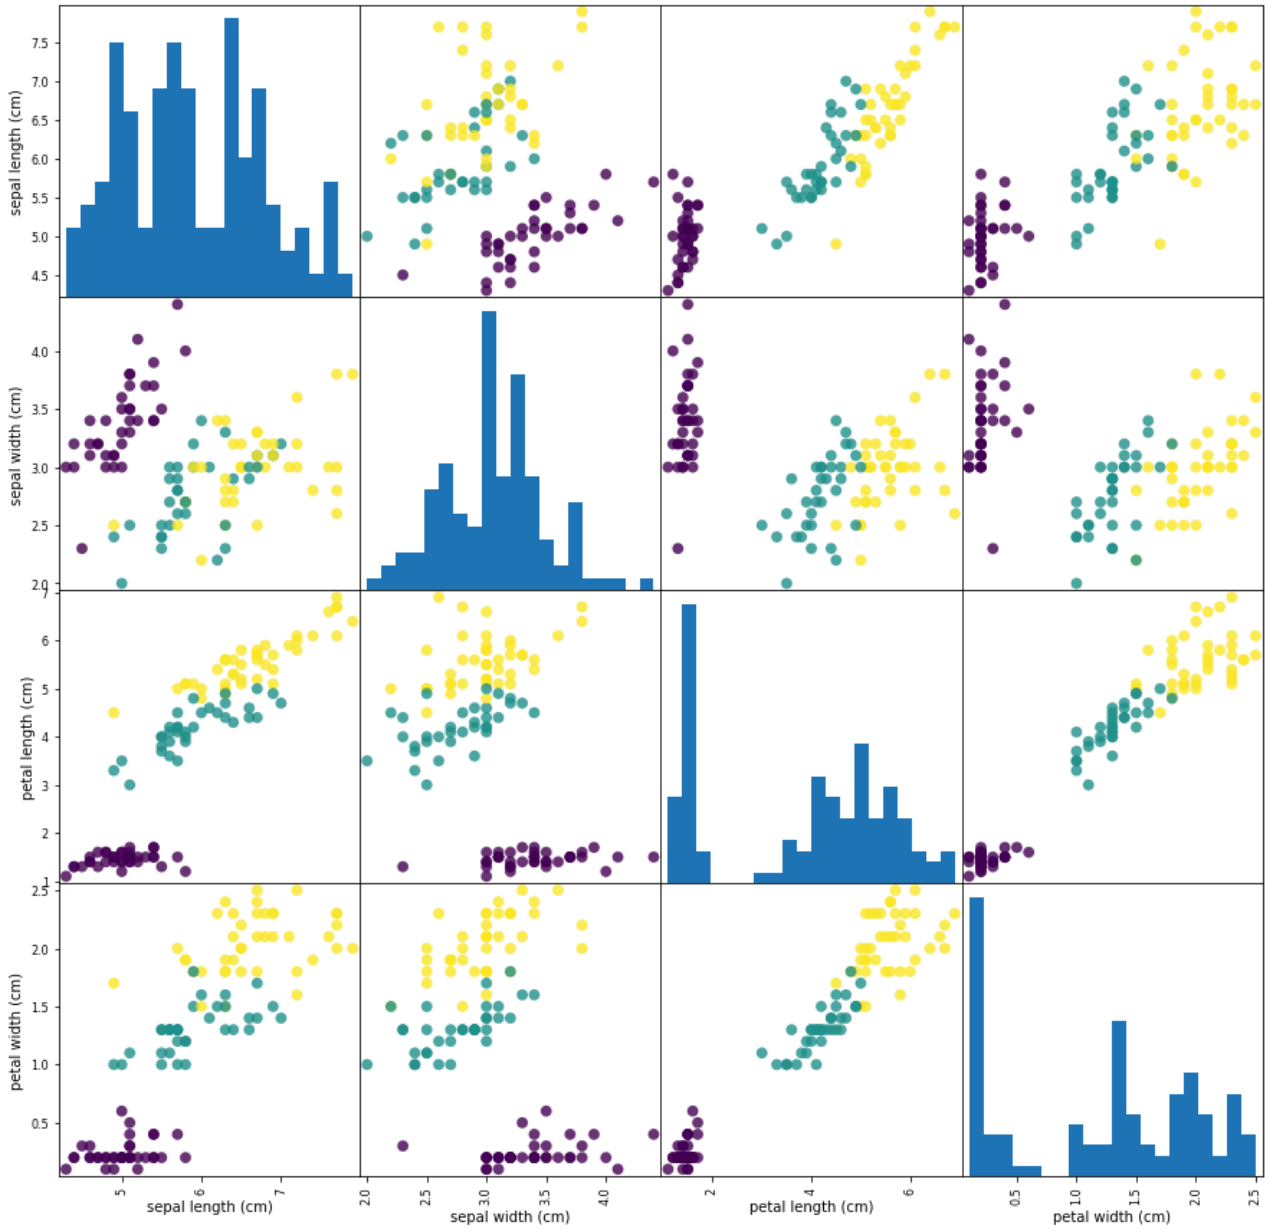


Pandas를 이용한 산점도 행렬 확인

In [ ]:
```
pd.plotting.scatter_matrix(iris_df, c=y_train,      # 색
                           figsize=(15,15),         # 크기
                           marker='o',              # 표시
                           hist_kwds={'bins':20},   # 막대의 개수
                           s=60,     # size
                           alpha=0.8 )  # 투명도
```

Out[ ]:
```
array([[<AxesSubplot:xlabel='sepal length (cm)', ylabel='sepal length (cm)'>,
        <AxesSubplot:xlabel='sepal width (cm)', ylabel='sepal length (cm)'>,
        <AxesSubplot:xlabel='petal length (cm)', ylabel='sepal length (cm)'>,
        <AxesSubplot:xlabel='petal width (cm)', ylabel='sepal length (cm)'>],
       [<AxesSubplot:xlabel='sepal length (cm)', ylabel='sepal width (cm)'>,
        <AxesSubplot:xlabel='sepal width (cm)', ylabel='sepal width (cm)'>,
```

```
  <AxesSubplot:xlabel='petal length (cm)', ylabel='sepal width (cm)'>,
  <AxesSubplot:xlabel='petal width (cm)', ylabel='sepal width (cm)'>],
 [<AxesSubplot:xlabel='sepal length (cm)', ylabel='petal length (cm)'>,
  <AxesSubplot:xlabel='sepal width (cm)', ylabel='petal length (cm)'>,
  <AxesSubplot:xlabel='petal length (cm)', ylabel='petal length (cm)'>,
  <AxesSubplot:xlabel='petal width (cm)', ylabel='petal length (cm)'>],
 [<AxesSubplot:xlabel='sepal length (cm)', ylabel='petal width (cm)'>,
  <AxesSubplot:xlabel='sepal width (cm)', ylabel='petal width (cm)'>,
  <AxesSubplot:xlabel='petal length (cm)', ylabel='petal width (cm)'>,
  <AxesSubplot:xlabel='petal width (cm)', ylabel='petal width (cm)'>]],
dtype=object)
```



07 첫번째 머신러닝 모델 만들기

- k-최근접 이웃(k-nearest neighbors, k-NN) 알고리즘 :
  - 훈련 데이터에서 새로운 데이터 포인트에 가장 가까운 'k개'의 이웃을 찾는다.
  - 이웃들의 클래스 중 빈도가 가장 높은 클래스를 예측값으로 사용

모델 만들기

In [ ]:
```
from sklearn.neighbors import KNeighborsClassifier
model = KNeighborsClassifier(n_neighbors=2)  # 2개의 이웃을 기준
```

모델 학습시키기

In [ ]:
```
model.fit(X_train, y_train)
```

Out[ ]:
```
KNeighborsClassifier(n_neighbors=2)
```

하나의 데이터로 예측해 보기

In [ ]:
```
X_new = np.array([[5, 2.9, 1, 0.2]])
```

In [ ]:
```
### 예측시키기
pred = model.predict(X_new)
pred_targetname = iris['target_names'][pred]
print("예측 : ", pred)
print("예측한 타깃의 이름: ", pred_targetname)
```

```
예측 :  [0]
예측한 타깃의 이름:  ['setosa']
```

08 내가 만든 모델 평가하기

In [ ]:
```
y_pred = model.predict(X_test)
print("예측값 :\n", y_pred)
```

```
예측값 :
 [2 1 0 2 0 2 0 1 1 1 2 1 1 1 1 0 1 1 0 0 2 1 0 0 2 0 0 1 1 0 2 1 0 2 2 1 0
 2]
```

In [ ]:
```
print("테스트 세트의 정확도 : {:.2f}".format(np.mean(y_pred == y_test)))
```

```
테스트 세트의 정확도 : 0.97
```

실습해 보기

- titanic 데이터 셋을 활용하여 knn 모델을 구현해 보자

REF

- sklearn score 매개변수 : https://scikit-learn.org/stable/modules/model_evaluation.html
- 구글 용어집 : https://developers.google.com/machine-learning/glossary/

History

- 내용 확인 및 업데이트 2021/10 v11