Kaggle 입문하기 - 데이터 분석 입문

Data Fields

필드명 설명

```
datetime hourly date + timestamp
   season 1 = spring, 2 = summer, 3 = fall, 4 = winter
   holiday whether the day is considered a holiday
workingday whether the day is neither a weekend nor holiday
            1: Clear, Few clouds, Partly cloudy, Partly cloudy
            2: Mist + Cloudy, Mist + Broken clouds, Mist + Few clouds, Mist
  weather
            3: Light Snow, Light Rain + Thunderstorm + Scattered clouds, Light Rain + Scattered clouds
            4: Heavy Rain + Ice Pallets + Thunderstorm + Mist, Snow + Fog
     temp temperature in Celsius (온도)
    atemp "feels like" temperature in Celsius (체감온도)
  humidity relative humidity (습도)
windspeed wind speed (바람속도)
    casual number of non-registered user rentals initiated (비가입자 사용유저)
 registered number of registered user rentals initiated (가입자 사용유저)
     count number of total rentals (전체 렌탈 대수)
```

```
In [10]:
```

```
import pandas as pd
import matplotlib.pyplot as plt ## seaborn 보다 고급 시각화 가능. but 코드 복잡
import seaborn as sns ## seaborn은 matplotlib보다 간단하게 사용 가능
```

```
In [12]: ▶
```

```
train = pd.read_csv("../bike/train.csv", parse_dates=['datetime'])
test = pd.read_csv("../bike/test.csv", parse_dates=['datetime'])
```

In [13]: ▶

```
col_names = [ 'season', 'holiday', 'workingday', 'weather' ]
i = 0
plt.figure(figsize=(12,10)) # 전체 그래프의 크기 지정

for name in col_names: # 컬럼명을 전달 리스트 수 만큼 반복 -> 4회
i = i + 1 # 숫자를 1씩 증가.
plt.subplot(2,2,i) # 2행 2열에 i번째 그래프 선택
sns.countplot(name, data=train) # i번째 그래프에 sns.countplot를 그리겠다.

plt.show() # 주피터에서 보여주지만, 다른곳(editor, pycharm)에서는 이걸 실행시켜야 한다.
```

C:\Users\toto\anaconda3\lib\site-packages\seaborn_decorators.py:36: Future\twilders\ning: Pass the following variable as a keyword arg: x. From version 0.12, the only valid positional argument will be `data`, and passing other arguments without an explicit keyword will result in an error or misinterpretation.

warnings.warn(

C:\Users\toto\anaconda3\lib\site-packages\seaborn_decorators.py:36: Future\text{Warning:} Pass the following variable as a keyword arg: x. From version 0.12, the only valid p ositional argument will be `data`, and passing other arguments without an explicit k eyword will result in an error or misinterpretation.

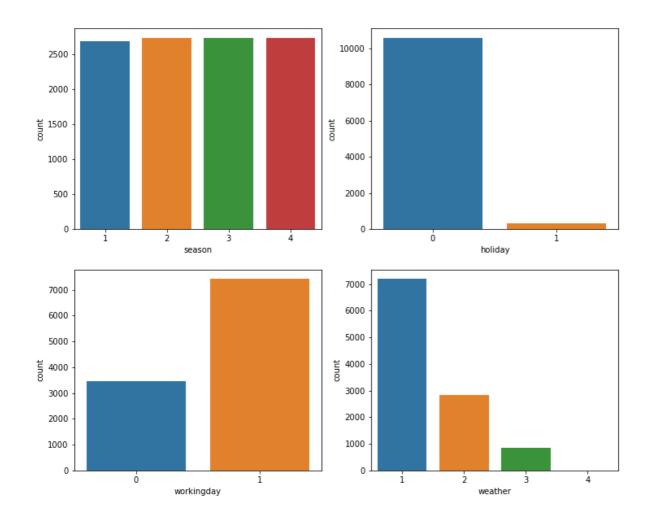
warnings.warn(

C:\Users\toto\anaconda3\lib\site-packages\seaborn_decorators.py:36: Future\anning: Pass the following variable as a keyword arg: x. From version 0.12, the only valid positional argument will be `data`, and passing other arguments without an explicit keyword will result in an error or misinterpretation.

warnings.warn(

C:\Users\toto\anaconda3\lib\site-packages\seaborn_decorators.py:36: Future\twarning: Pass the following variable as a keyword arg: x. From version 0.12, the only valid positional argument will be `data`, and passing other arguments without an explicit k eyword will result in an error or misinterpretation.

warnings.warn(



수치형 데이터 선택

```
In [14]:

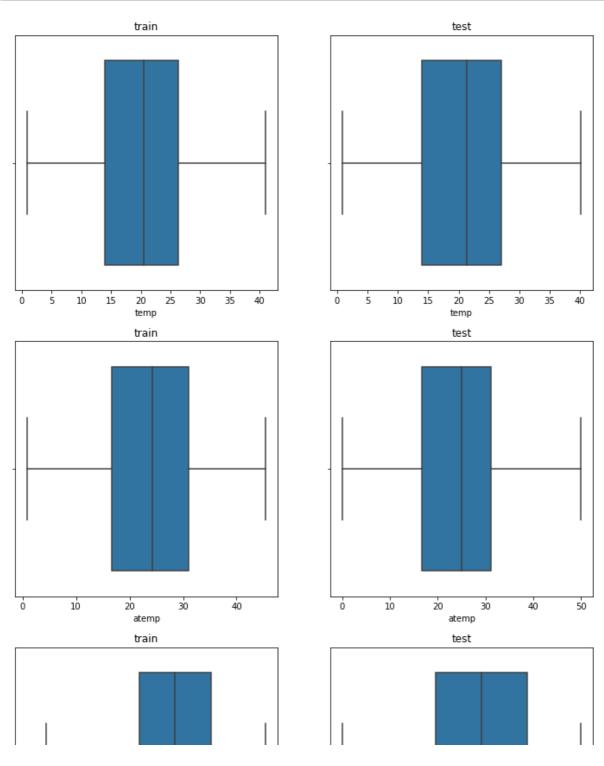
### temp, atemp, humidity, windspeed

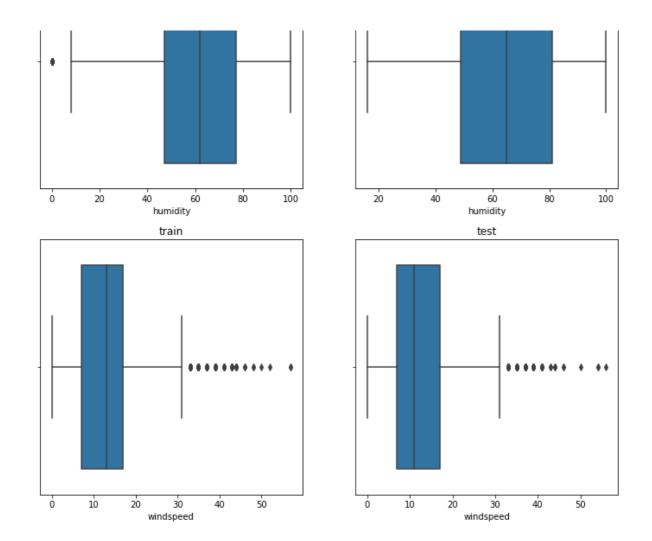
num_names = ['temp', 'atemp', 'humidity', 'windspeed']
train.columns
```

Out[14]:

In [16]:

```
# par(mfrow=c(2,2)) -> R
i = 0
plt.figure(figsize=(12,25)) # 전체 그래프의 크기 지정 (가로, 세로)
for name in num_names:
                        # 컬럼명을 전달 리스트 수 만큼 반복 -> 4회
   i = i + 1
                         # 숫자를 1씩 증가.
                            # 2행 2열에 i번째 그래프 선택
   plt.subplot(4,2,i*2-1)
   sns.boxplot(x=name, data=train) # i번째 그래프에 sns.countplot를 그리겠다.
   plt.title("train")
                          # 2행 2열에 i번째 그래프 선택
   plt.subplot(4,2,i*2)
   sns.boxplot(x=name, data=test) # i번째 그래프에 sns.countplot를 그리겠다.
   plt.title("test")
plt.show()
```





```
In [17]:
```

```
new_tr = train.copy() # 데이터 백업
new_test = test.copy()
new_tr.columns
```

Out[17]:

파생변수

In [18]:

```
## 더미변수, 파생변수 생성
new_tr['year'] = new_tr['datetime'].dt.year
new_tr.head()
```

Out[18]:

	datetime	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	casual
0	2011-01- 01 00:00:00	1	0	0	1	9.84	14.395	81	0.0	3
1	2011-01- 01 01:00:00	1	0	0	1	9.02	13.635	80	0.0	8
2	2011-01- 01 02:00:00	1	0	0	1	9.02	13.635	80	0.0	5
3	2011-01- 01 03:00:00	1	0	0	1	9.84	14.395	75	0.0	3
4	2011-01- 01 04:00:00	1	0	0	1	9.84	14.395	75	0.0	0

In [19]:

```
new_tr['month'] = new_tr['datetime'].dt.month
new_tr['day'] = new_tr['datetime'].dt.day
new_tr['hour'] = new_tr['datetime'].dt.hour
new_tr['minute'] = new_tr['datetime'].dt.minute
new_tr['second'] = new_tr['datetime'].dt.second
new_tr['dayofweek'] = new_tr['datetime'].dt.dayofweek
new_tr.head()
```

Out[19]:

	datetime	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	casual
0	2011-01- 01 00:00:00	1	0	0	1	9.84	14.395	81	0.0	3
1	2011-01- 01 01:00:00	1	0	0	1	9.02	13.635	80	0.0	8
2	2011-01- 01 02:00:00	1	0	0	1	9.02	13.635	80	0.0	5
3	2011-01- 01 03:00:00	1	0	0	1	9.84	14.395	75	0.0	3
4	2011-01- 01 04:00:00	1	0	0	1	9.84	14.395	75	0.0	0

In [20]:

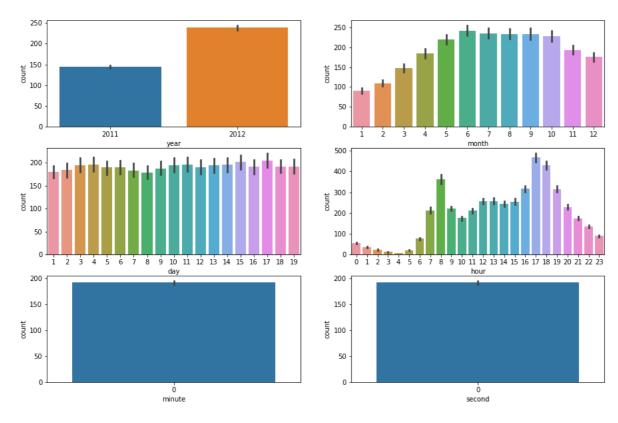
train.columns

Out[20]:

In [21]:

```
datetime_names = ['year', 'month', 'day', 'hour', 'minute', 'second']
i=0
plt.figure(figsize=(15,10))
for name in datetime_names:
    i = i + 1
    plt.subplot(3,2,i)
    sns.barplot(x=name, y='count', data=new_tr)

plt.show()
```



In [22]:

```
new_test['year'] = new_test['datetime'].dt.year
new_test['month'] = new_test['datetime'].dt.month
new_test['day'] = new_test['datetime'].dt.day
new_test['dayofweek'] = new_test['datetime'].dt.dayofweek
new_test['hour'] = new_test['datetime'].dt.hour
new_test['minute'] = new_test['datetime'].dt.minute
new_test['second'] = new_test['datetime'].dt.second
```

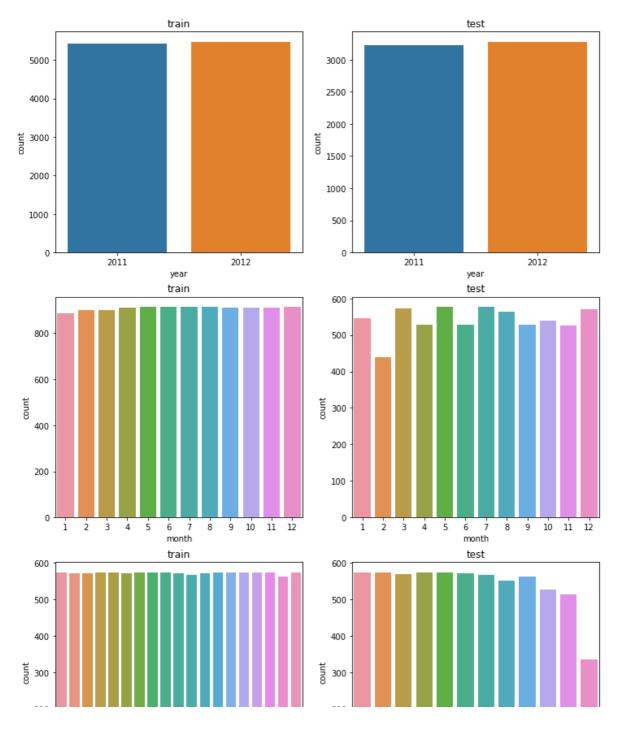
In [28]:

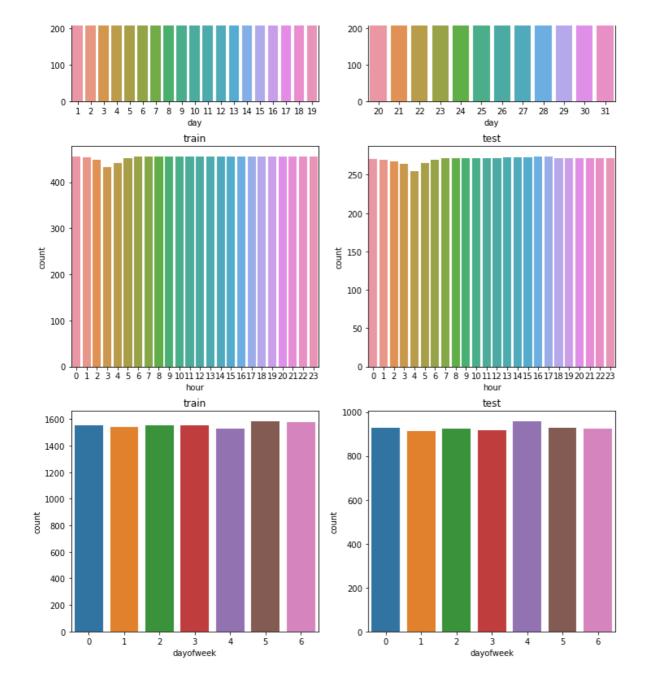
```
col_names = ['year','month','day','hour','dayofweek']
i = 0

plt.figure(figsize=(12,35)) ##전체 그래프 크기 지정

for name in col_names: ## 컬럼명으로 반복
i = i+1
plt.subplot(6,2,i) ##2행2열, i = 1,2,3,4 (왼쪽 상단부터 시계방향으로 순번 지정)
sns.countplot(x=name, data = new_tr)
plt.title('train')

i = i+1
plt.subplot(6,2,i) ##2행2열, i = 1,2,3,4 (왼쪽 상단부터 시계방향으로 순번 지정)
sns.countplot(x=name, data = new_test)
plt.show()
```





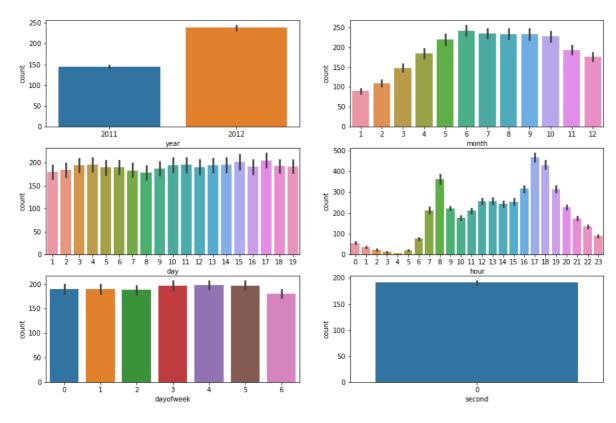
In [29]:

new_tr['dayofweek'] = new_tr['datetime'].dt.dayofweek # Monday=0, Sunday=6

In [30]:

```
datetime_names = ['year', 'month', 'day', 'hour', 'dayofweek', 'second']
i=0
plt.figure(figsize=(15,10))
for name in datetime_names:
    i = i + 1
    plt.subplot(3,2,i)
    sns.barplot(x=name, y='count', data=new_tr)

plt.show()
```



In [31]:

```
print(new_test.shape)
new_test[["datetime", "year", "month", "day", "hour", "minute", "second", "dayofweek"]].head()
```

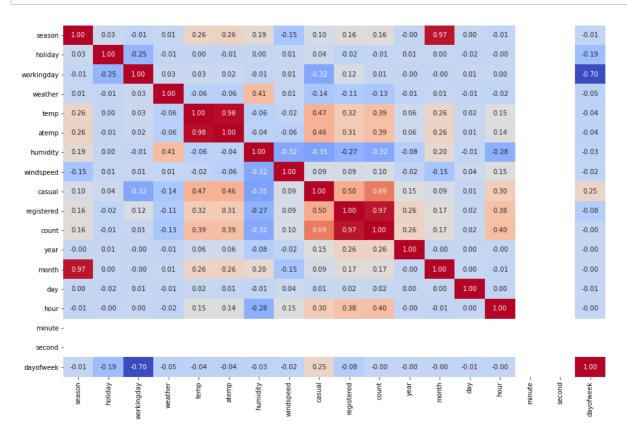
(6493, 16)

Out[31]:

	datetime	year	month	day	hour	minute	second	dayofweek
0	2011-01-20 00:00:00	2011	1	20	0	0	0	3
1	2011-01-20 01:00:00	2011	1	20	1	0	0	3
2	2011-01-20 02:00:00	2011	1	20	2	0	0	3
3	2011-01-20 03:00:00	2011	1	20	3	0	0	3
4	2011-01-20 04:00:00	2011	1	20	4	0	0	3

In [32]:

```
plt.figure(figsize=(15,10))
g = sns.heatmap(new_tr.corr(), annot=True, fmt=".2f", cmap="coolwarm", cbar=False)
```



```
In [36]:
feature_names = [ 'season', 'holiday', 'workingday', 'weather',
                 'temp', 'atemp', 'humidity', 'windspeed',
                 "year", "hour", "dayofweek"] # 공통 변수
X_tr_all = new_tr[feature_names] # 학습용 데이터 변수 선택
X_test_all = new_test[feature_names] # 테스트 데이터의 변수 선택
print(X_tr_all.head())
   season holiday workingday weather
                                       temp
                                             atemp humidity windspeed ₩
0
                                       9.84
                                            14.395
                                                          81
                                                                   0.0
       1
                0
                           0
                                    1
1
       1
                0
                           0
                                    1
                                       9.02
                                            13.635
                                                          80
                                                                   0.0
2
                0
                           0
                                       9.02
                                                          80
       1
                                    1
                                            13.635
                                                                   0.0
3
       1
                0
                           0
                                    1 9.84
                                            14.395
                                                          75
                                                                   0.0
4
       1
                ()
                           0
                                    1 9.84 14.395
                                                          75
                                                                   0.0
              dayofweek
  year hour
0
  2011
           0
                      5
  2011
1
           1
2
  2011
           2
                      5
                      5
3 2011
           3
                      5
4 2011
           4
In [37]:
                                                                                             M
label_name = 'count'
                                   # 렌탈 대수 (종속변수)
y_tr_all = new_tr[label_name]
                                   # 렌탈 대수 변수 값 선택
In [38]:
                                                                                             H
from sklearn.model_selection import train_test_split
In [39]:
                                                                                             M
X_train, X_test, y_train, y_test = train_test_split(X_tr_all,
                                                 y_tr_all,
                                                 test_size=0.3,
                                                 random_state=77)
In [40]:
                                                                                             Ы
from sklearn.linear_model import LinearRegression
model = LinearRegression() # 모델 객체 생성.
model.fit(X_train, y_train)
# 정확도 확인
print("학습용 세트 정확도: {:.3f}".format(model.score(X_train, y_train)))
print("테스트 세트 정확도: {:.3f}".format(model.score(X_test, y_test)))
```

학습용 세트 정확도: 0.391 테스트 세트 정확도: 0.377 In [41]:

```
from sklearn.tree import DecisionTreeRegressor

model = DecisionTreeRegressor() # 모델 객체 생성.

model.fit(X_train, y_train)

# 정확도 확인

print("학습용 세트 정확도: {:.3f}".format(model.score(X_train, y_train)))

print("테스트 세트 정확도: {:.3f}".format(model.score(X_test, y_test)))
```

학습용 세트 정확도: 1.000 테스트 세트 정확도: 0.891

In [42]:

```
from sklearn.ensemble import RandomForestRegressor # 앙상블(의사결정트리 확장판)

seed = 37
model = RandomForestRegressor(n_jobs=-1, random_state=seed) # 모델 객체 생성.
model.fit(X_train, y_train) # 모델 학습(공부가 되었다.)

# 정확도 확인
print("학습용 세트 정확도: {:.3f}".format(model.score(X_train, y_train)))
print("테스트 세트 정확도: {:.3f}".format(model.score(X_test, y_test)))
```

학습용 세트 정확도: 0.992 테스트 세트 정확도: 0.946

In [43]:

```
from sklearn.ensemble import GradientBoostingRegressor

seed = 37
model = GradientBoostingRegressor(random_state=seed) # 모델 객체 생성.
model.fit(X_train, y_train) # 모델 학습(공부가 되었다.)

# 정확도 확인
print("학습용 세트 정확도: {:.3f}".format(model.score(X_train, y_train)))
print("테스트 세트 정확도: {:.3f}".format(model.score(X_test, y_test)))
```

학습용 세트 정확도: 0.860 테스트 세트 정확도: 0.849 In [45]: ▶

```
sub = pd.read_csv("../bike/sampleSubmission.csv")
sub.head()
```

Out [45]:

	datetime	count
0	2011-01-20 00:00:00	0
1	2011-01-20 01:00:00	0
2	2011-01-20 02:00:00	0
3	2011-01-20 03:00:00	0
4	2011-01-20 04:00:00	0

In [46]: ▶

```
from sklearn.ensemble import RandomForestRegressor # 앙상블(의사결정트리 확장판)
seed = 37
model = RandomForestRegressor(n_jobs=-1, random_state=seed) # 모델 객체 생성.
model.fit(X_train, y_train) # 모델 학습(공부가 되었다.)
```

Out [46]:

RandomForestRegressor(n_jobs=-1, random_state=37)

```
In [47]: ▶
```

```
pred = model.predict(X_test_all) # 예측
sub['count'] = pred
sub.loc[sub['count'] < 0, 'count'] = 0
sub.head(3)
```

Out [47]:

	datetime	count
0	2011-01-20 00:00:00	11.75
1	2011-01-20 01:00:00	4.20
2	2011-01-20 02:00:00	4.78

In [48]:

```
# 처음 만는 제출용 csv 파일, 행번호를 없애기
sub.to_csv("third_sub.csv", index=False)
```

score: 0.43006

실습: 특성을 확대하면 어떨까?

In [49]:

```
from sklearn.preprocessing import MinMaxScaler from sklearn.preprocessing import PolynomialFeatures
```

```
In [50]:
```

	season	holiday	workingday	weather	temp	atemp	humidity	₩
10846	4	0	1	1	15.58	19.695	94	
8088	2	0	0	1	22.96	26.515	68	
9112	3	1	0	2	27.88	31.820	89	
5747	1	0	0	1	9.84	10.605	38	
8168	3	0	0	1	37.72	40.150	26	

```
windspeed year hour
                              dayofweek
         0.0000 2012
10846
                          8
                                      1
                          9
                                      6
8808
         11.0014 2012
         11.0014 2012
                                      0
9112
                          1
                                      5
         19.9995 2012
5747
                          15
8168
         19.9995 2012
                          17
                                      6
```

In [51]: ▶

In [52]:

```
In [53]:
                                                                                            H
from sklearn.ensemble import RandomForestRegressor # 앙상블(의사결정트리 확장판)
seed = 37
model = RandomForestRegressor(n_jobs=-1, random_state=seed) # 모델 객체 생성.
model.fit(X_train, y_train)
                                   # 모델 학습(공부가 되었다.)
# 정확도 확인
print("학습용 세트 정확도: {:.3f}".format(model.score(X_train, y_train)))
print("테스트 세트 정확도: {:.3f}".format(model.score(X_test, y_test)))
학습용 세트 정확도: 0.992
테스트 세트 정확도: 0.950
In [54]:
                                                                                            H
nor_X_test_all = scaler.transform(X_test_all)
ex_X_test = PolynomialFeatures(degree=2,
                             include_bias=False).fit_transform(nor_X_test_all)
In [55]:
pred = model.predict(ex_X_test) # 예측
sub['count'] = pred
sub.loc[sub['count'] < 0, 'count'] = 0</pre>
sub.head(3)
Out [55]:
           datetime count
0 2011-01-20 00:00:00
                    13.66
1 2011-01-20 01:00:00
                     5.08
2 2011-01-20 02:00:00
                     3.53
In [56]:
                                                                                            H
```

```
# 처음 만는 제출용 csv 파일, 행번호를 없애기 sub.to_csv("four_sub.csv", index=False)
```

score: 0.41328

대표적인 모델 xgboost 사용해 보기

```
In [57]:
import xgboost as xgb
```

xgb.DMatrix

• dense matrix, sparse matrix, local file로부터 DMatrix object 객체를 만든다.

```
In [58]:

# data_dmatrix = xgb.DMatrix(data=ex_X_tr,label=y_tr_all)

In [59]:

X_train, X_test, y_train, y_test = train_test_split(ex_X_tr, y_tr_all, test_size=0.2,
```

```
In [60]:
```

random_state=42)

```
# 기본 옵션 확인
xg_reg = xgb.XGBRegressor()
xg_reg
```

Out[60]:

```
XGBRegressor(base_score=None, booster=None, colsample_bylevel=None, colsample_bynode=None, colsample_bytree=None, gamma=None, gpu_id=None, importance_type='gain', interaction_constraints=None, learning_rate=None, max_delta_step=None, max_depth=None, min_child_weight=None, missing=nan, monotone_constraints=None, n_estimators=100, n_jobs=None, num_parallel_tree=None, random_state=None, reg_alpha=None, reg_lambda=None, scale_pos_weight=None, subsample=None, tree_method=None, validate_parameters=None, verbosity=None)
```

- learning_rate: 0~1사이의 값. 과적합을 방지하기 위한 단계 크기
- max_depth: 각각의 나무 모델의 최대 깊이
- subsample: 각 나무마다 사용하는 샘플 퍼센트, 낮은 값은 underfitting(과소적합)을 야기할 수 있음.
- colsample_bytree: 각 나무마다 사용하는 **feature 퍼센트**. High value can lead to overfitting.
- n estimators: 트리의 수(우리가 모델을 생성할)
- loss function(손실함수)결정.
- objective(목적함수)
 - reg:linear for regression problems(회귀 문제),
 - reg:logistic for classification problems with only decision(분류 문제),
 - binary:logistic for classification problems with probability.
- alpha : L1 규제에 대한 항

In [65]: ▶

Out[65]:

```
XGBRegressor(alpha=0.1, base_score=None, booster=None, colsample_bylevel=None, colsample_bynode=None, colsample_bytree=0.3, gamma=None, gpu_id=None, importance_type='gain', interaction_constraints=None, learning_rate=0.1, max_delta_step=None, max_depth=4, min_child_weight=None, missing=nan, monotone_constraints=None, n_estimators=100, n_jobs=None, num_parallel_tree=None, objective='reg:linear', random_state=None, reg_alpha=None, reg_lambda=None, scale_pos_weight=None, subsample=None, tree_method=None, validate_parameters=None, verbosity=None)
```

학습

In [66]: ▶

```
xg_reg.fit(X_train, y_train) # 모델 학습(공부가 되었다.)
```

[08:20:47] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa rederror.

Out [66]:

```
XGBRegressor(alpha=0.1, base_score=0.5, booster='gbtree', colsample_bylevel=1, colsample_bynode=1, colsample_bytree=0.3, gamma=0, gpu_id=-1, importance_type='gain', interaction_constraints='', learning_rate=0.1, max_delta_step=0, max_depth=4, min_child_weight=1, missing=nan, monotone_constraints='()', n_estimators=100, n_jobs=8, num_parallel_tree=1, objective='reg:linear', random_state=0, reg_alpha=0.100000001, reg_lambda=1, scale_pos_weight=1, subsample=1, tree_method='exact', validate_parameters=1, verbosity=None)
```

In [67]:

```
# 정확도 확인
print("학습용 세트 정확도: {:.3f}".format(xg_reg.score(X_train, y_train)))
print("테스트 세트 정확도: {:.3f}".format(xg_reg.score(X_test, y_test)))
```

학습용 세트 정확도: 0.945 테스트 세트 정확도: 0.933

실습

• 나무의 개수를 조정해 보면서 확인해 보자.

In [68]:

```
%%time
num_list = [100, 200, 300, 500, 1000, 1500]
for num in num_list:
   xg_reg = xgb.XGBRegressor(objective = reg:linear',
           colsample_bytree = 0.3, # 각나무마다 사용하는 feature 비율
           learning_rate = 0.1,
           max_depth = 3,
           alpha = 0.1,
           n_estimators = num)
   xg_reg.fit(X_train, y_train)
   print("학습용 세트 정확도: {:.3f}".format(xg_reg.score(X_train, y_train)))
   print("테스트 세트 정확도: {:.3f}".format(xg_reg.score(X_test, y_test)))
[08:20:50] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 세트 정확도: 0.912
테스트 세트 정확도: 0.901
[08:20:51] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 세트 정확도: 0.940
테스트 세트 정확도: 0.928
[08:20:52] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 세트 정확도: 0.950
테스트 세트 정확도: 0.936
[08:20:53] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 세트 정확도: 0.961
테스트 세트 정확도: 0.943
[08:20:55] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 세트 정확도: 0.973
테스트 세트 정확도: 0.950
[08:20:59] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 세트 정확도: 0.980
테스트 세트 정확도: 0.952
```

최종 모델

Wall time: 15.2 s

In [69]:

[08:21:06] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa rederror.

학습용 세트 정확도: 0.979 테스트 세트 정확도: 0.956

In [70]: ▶

```
In [71]: ▶
```

```
pred = xg_reg.predict(ex_X_test) # 예측
sub['count'] = pred
sub.loc[sub['count'] < 0, 'count'] = 0
sub.head(3)
```

Out [71]:

	datetime	count
0	2011-01-20 00:00:00	12.755984
1	2011-01-20 01:00:00	2.368304
2	2011-01-20 02:00:00	1.013963

In [72]: ▶

```
# 처음 만는 제출용 csv 파일, 행번호를 없애기
sub.to_csv("five_xgb_sub.csv", index=False)
```

(실습) Ir_rate와 max_depth를 조정해 가면서 확인해 보자.

score: 0.65533

• Ir rate=0.1, max depth = 4, 1000개 트리

score: 0.70240

• Ir rate=0.1, max depth = 3, 1500개 트리

score: 0.75037

• Ir_rate = 0.001, max_depth = 3, 1000개 트리

score: 0.57720

• Ir_rate = 0.05, max_depth = 5, 500개 트리

<u>In []:</u>