Kaggle 입문하기 - 데이터 분석 입문

- 다양한 모델을 활용해 봅니다.
- 특성 자동 선택 함수를 사용해 봅니다.
- xgboost 모델을 활용해 봅니다.
 - 다양한 파라미터에 대해 알아봅니다.

Data Fields

필드명 설명

```
datetime hourly date + timestamp
   season 1 = spring, 2 = summer, 3 = fall, 4 = winter
   holiday whether the day is considered a holiday
workingday whether the day is neither a weekend nor holiday
            1: Clear, Few clouds, Partly cloudy, Partly cloudy
            2: Mist + Cloudy, Mist + Broken clouds, Mist + Few clouds, Mist
  weather
            3: Light Snow, Light Rain + Thunderstorm + Scattered clouds, Light Rain + Scattered clouds
            4: Heavy Rain + Ice Pallets + Thunderstorm + Mist, Snow + Fog
     temp temperature in Celsius (온도)
    atemp
            "feels like" temperature in Celsius (체감온도)
  humidity relative humidity (습도)
windspeed wind speed (바람속도)
    casual number of non-registered user rentals initiated (비가입자 사용유저)
 registered number of registered user rentals initiated (가입자 사용유저)
     count number of total rentals (전체 렌탈 대수)
```

```
In [1]:
import pandas as pd

In [2]:
```

```
train = pd.read_csv("bike/train.csv", parse_dates=['datetime'])
test = pd.read_csv("bike/test.csv", parse_dates=['datetime'])
```

```
In [3]: ▶
```

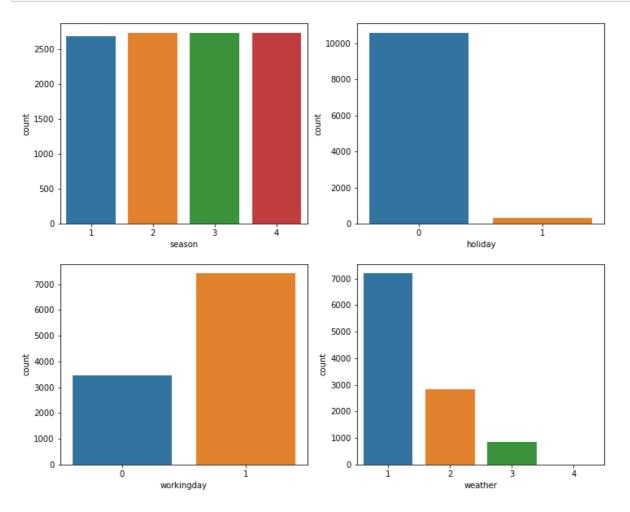
```
import matplotlib.pyplot as plt ## seaborn 보다 고급 시각화 가능. but 코드 복잡
import seaborn as sns ## seaborn은 matplotlib보다 간단하게 사용 가능
```

In [4]:

```
col_names = [ 'season', 'holiday', 'workingday', 'weather' ]
i = 0
plt.figure(figsize=(12,10)) # 전체 그래프의 크기 지정

for name in col_names: # 컬럼명을 전달 리스트 수 만큼 반복 -> 4회
i = i + 1 # 숫자를 1씩 증가.
plt.subplot(2,2,i) # 2행 2열에 i번째 그래프 선택
sns.countplot(x=name, data=train) # i번째 그래프에 sns.countplot를 그리겠다.

plt.show() # 주피터에서 보여주지만, 다른곳(editor, pycharm)에서는 이걸 실행시켜야 한다.
```



수치형 데이터 선택

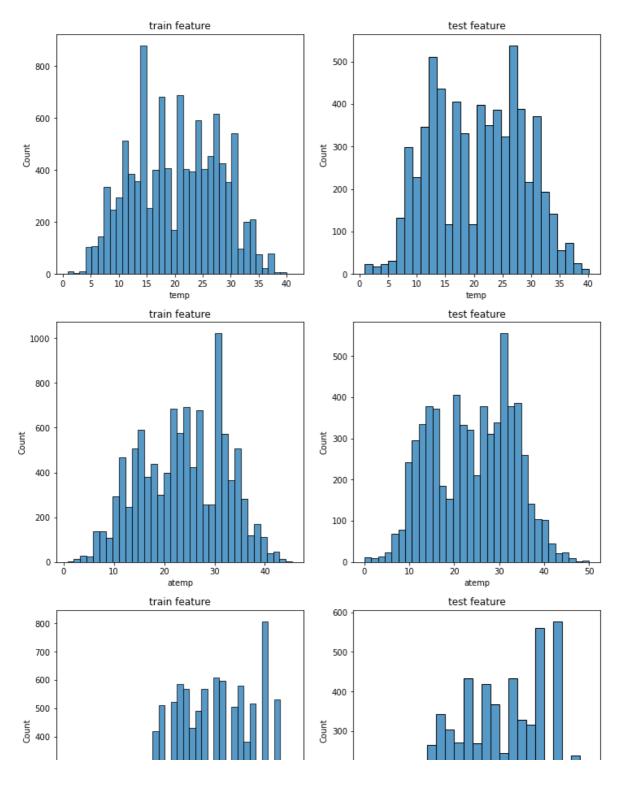
In [5]:

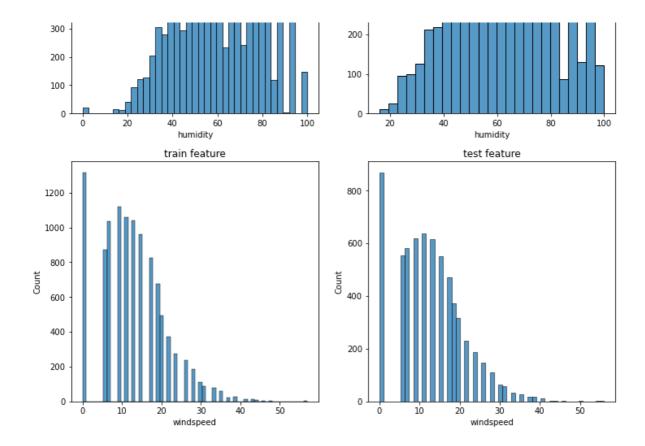
```
### temp, atemp, humidity, windspeed
num_names = ['temp', 'atemp', 'humidity', 'windspeed']
train.columns
```

Out[5]:

In [6]:

```
i = 0
plt.figure(figsize=(12,25))
                         # 전체 그래프의 크기 지정 (가로, 세로)
for name in num_names:
                                   전달 리스트 수 만큼 반복 -> 4회
   j = j + 1
                          # 숫자를 1씩 증가.
   plt.subplot(4,2,i*2-1)
                             # 2행 2열에 i번째 그래프 선택
   sns.histplot(x=name, data=train) # i번째 그래프에 sns.histplot를 그리겠다.
   plt.title("train feature")
   plt.subplot(4,2,i*2)
                           # 2행 2열에 i번째 그래프 선택
   sns.histplot(x=name, data=test) # i번째 그래프에 sns.histplot를 그리겠다.
   plt.title("test feature")
plt.show()
```





```
new_tr = train.copy() # 데이터 백업
new_test = test.copy()
new_tr.columns
```

Out[14]:

특징 추출 - 날짜 피처로부터 추출

In [15]:

```
## 더미변수, 파생변수 생성
new_tr['year'] = new_tr['datetime'].dt.year
new_tr.head()
```

Out[15]:

	datetime	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	casual
0	2011-01- 01 00:00:00	1	0	0	1	9.84	14.395	81	0.0	3
1	2011-01- 01 01:00:00	1	0	0	1	9.02	13.635	80	0.0	8
2	2011-01- 01 02:00:00	1	0	0	1	9.02	13.635	80	0.0	5
3	2011-01- 01 03:00:00	1	0	0	1	9.84	14.395	75	0.0	3
4	2011-01- 01 04:00:00	1	0	0	1	9.84	14.395	75	0.0	0

In [16]:

```
new_tr['month'] = new_tr['datetime'].dt.month
new_tr['day'] = new_tr['datetime'].dt.day
new_tr['hour'] = new_tr['datetime'].dt.hour
new_tr['minute'] = new_tr['datetime'].dt.minute
new_tr['second'] = new_tr['datetime'].dt.second
new_tr['dayofweek'] = new_tr['datetime'].dt.dayofweek
new_tr.head()
```

Out[16]:

	datetime	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	casual
0	2011-01- 01 00:00:00	1	0	0	1	9.84	14.395	81	0.0	3
1	2011-01- 01 01:00:00	1	0	0	1	9.02	13.635	80	0.0	8
2	2011-01- 01 02:00:00	1	0	0	1	9.02	13.635	80	0.0	5
3	2011-01- 01 03:00:00	1	0	0	1	9.84	14.395	75	0.0	3
4	2011-01- 01 04:00:00	1	0	0	1	9.84	14.395	75	0.0	0

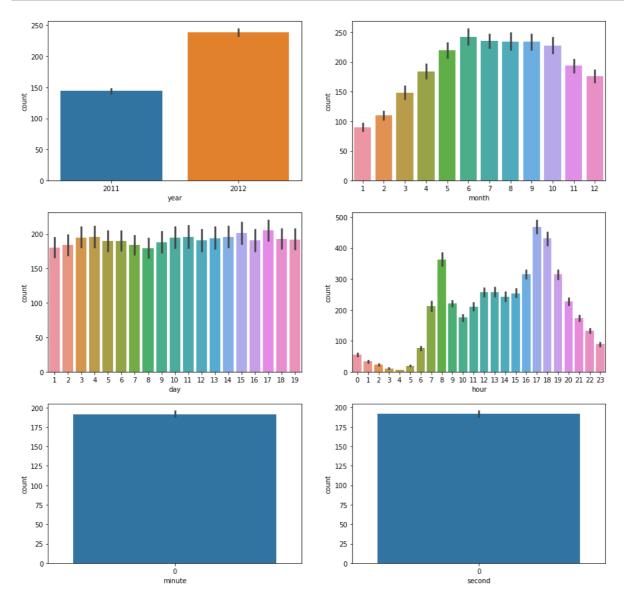
In [17]:

train.columns

Out[17]:

In [20]:

```
datetime_names = ['year', 'month', 'day', 'hour', 'minute', 'second']
plt.figure(figsize=(15,15))
for idx, name in enumerate(datetime_names):
    plt.subplot(3,2,idx+1)
    sns.barplot(x=name, y='count', data=new_tr)
plt.show()
```



In [21]:

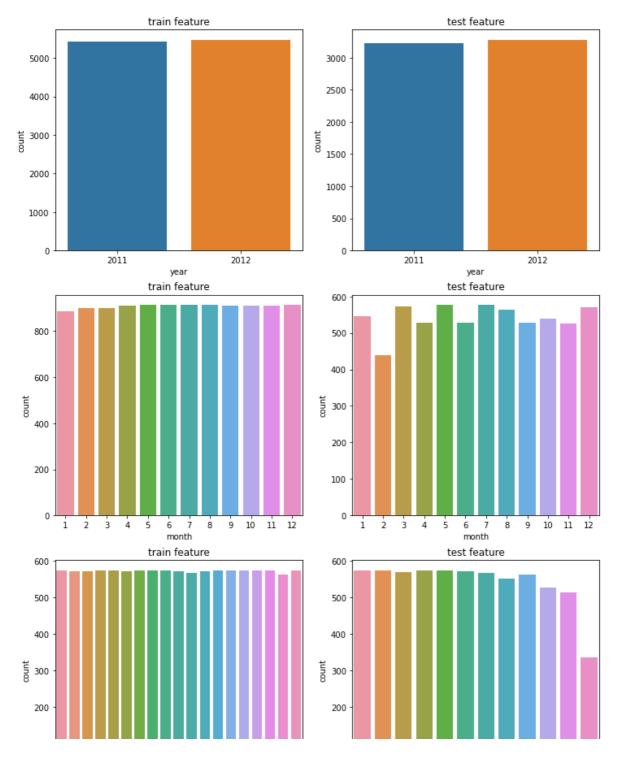
```
new_test['year'] = new_test['datetime'].dt.year
new_test['month'] = new_test['datetime'].dt.month
new_test['day'] = new_test['datetime'].dt.day
new_test['dayofweek'] = new_test['datetime'].dt.dayofweek
new_test['hour'] = new_test['datetime'].dt.hour
new_test['minute'] = new_test['datetime'].dt.minute
new_test['second'] = new_test['datetime'].dt.second
```

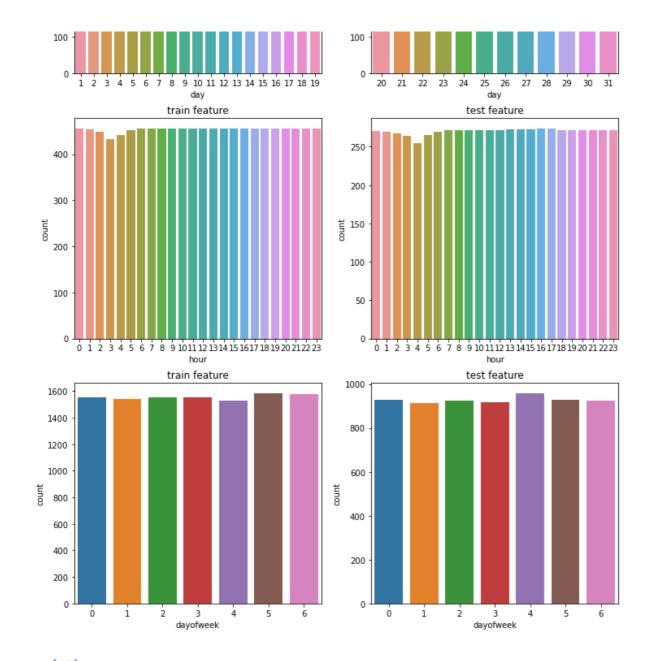
In [24]: ▶

```
col_names = ['year','month','day','hour','dayofweek']
i = 0
plt.figure(figsize=(12,35)) ##전체 그래프 크기 지정

for name in col_names: ## 컬럼명으로 반복
    i = i+1
    plt.subplot(6,2,i) ##2행2열, i = 1,2,3,4 (왼쪽 상단부터 시계방향으로 순번 지정)
    sns.countplot(x = name, data = new_tr)
    plt.title("train feature")

i = i+1
    plt.subplot(6,2,i) ##2행2열, i = 1,2,3,4 (왼쪽 상단부터 시계방향으로 순번 지정)
    sns.countplot(x = name, data = new_test)
    plt.title("test feature")
plt.show()
```



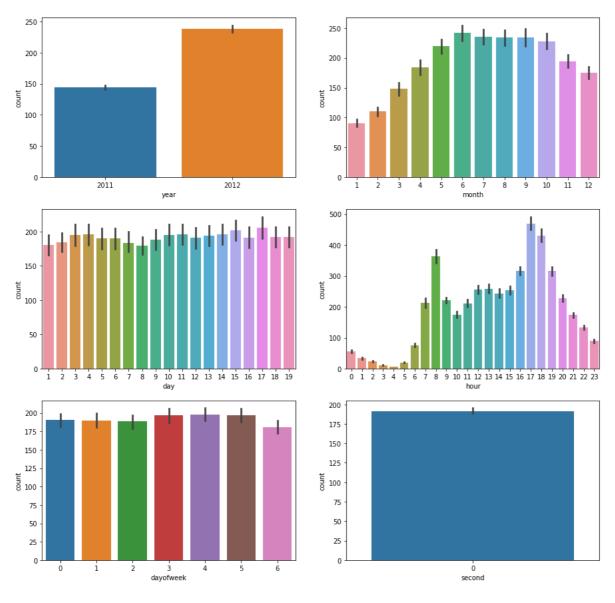


In [25]:

new_tr['dayofweek'] = new_tr['datetime'].dt.dayofweek # Monday=0, Sunday=6

In [26]:

```
datetime_names = ['year', 'month', 'day', 'hour', 'dayofweek', 'second']
i=0
plt.figure(figsize=(15,15))
for name in datetime_names:
    i = i + 1
    plt.subplot(3,2,i)
    sns.barplot(x=name, y='count', data=new_tr)
plt.show()
```



```
In [27]:
```

```
print(new_test.shape)
new_test[["datetime", "year", "month", "day", "hour", "minute", "second", "dayofweek"]].head()
```

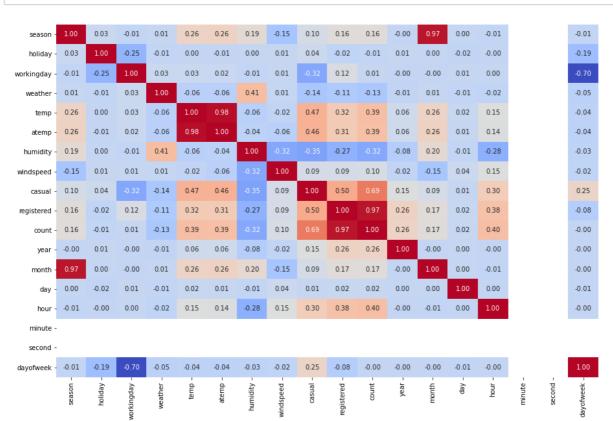
(6493, 16)

Out [27]:

	datetime	year	month	day	hour	minute	second	dayofweek
0	2011-01-20 00:00:00	2011	1	20	0	0	0	3
1	2011-01-20 01:00:00	2011	1	20	1	0	0	3
2	2011-01-20 02:00:00	2011	1	20	2	0	0	3
3	2011-01-20 03:00:00	2011	1	20	3	0	0	3
4	2011-01-20 04:00:00	2011	1	20	4	0	0	3

In [28]:

```
plt.figure(figsize=(15,10))
g = sns.heatmap(new_tr.corr(), annot=True, fmt=".2f", cmap="coolwarm", cbar=False)
```



```
In [29]:
feature_names = [ 'season', 'holiday', 'workingday', 'weather',
                 'temp', 'atemp', 'humidity', 'windspeed',
                 "year", "hour", "dayofweek"] # 공통 변수
X_tr_all = new_tr[feature_names] # 학습용 데이터 변수 선택
X_test_all = new_test[feature_names] # 테스트 데이터의 변수 선택
print(X_tr_all.head())
   season holiday workingday weather temp
                                             atemp humidity windspeed ₩
0
       1
                0
                           0
                                   1
                                      9.84
                                            14.395
                                                         81
                                                                  0.0
1
       1
                0
                           0
                                   1 9.02
                                            13.635
                                                         80
                                                                  0.0
2
                0
                           0
       1
                                   1 9.02
                                           13.635
                                                         80
                                                                  0.0
3
                0
                           0
                                   1 9.84 14.395
                                                         75
                                                                  0.0
       1
                0
                           0
                                                         75
4
       1
                                   1 9.84 14.395
                                                                  0.0
  year hour dayofweek
0 2011
           0
                     5
1 2011
           1
2
  2011
           2
                     5
           3
                     5
3 2011
4 2011
           4
                     5
In [30]:
                                                                                           M
label_name = 'count'
                                  # 렌탈 대수 (종속변수)
y_tr_all = new_tr[label_name]
                                  # 렌탈 대수 변수 값 선택
In [31]:
                                                                                           M
from sklearn.model_selection import train_test_split
In [32]:
                                                                                           H
```

y_tr_all, test_size=0.3, random_state=77)

X_train, X_test, y_train, y_test = train_test_split(X_tr_all,

In [33]:

```
from sklearn.linear_model import LinearRegression

model = LinearRegression() # 모델 객체 생성.

model.fit(X_train, y_train)

pred = model.predict(X_test)

# 결정계수 확인

print("학습용 데이터 결정계수: {:.3f}".format(model.score(X_train, y_train)))

print("테스트 데이터 결정계수: {:.3f}".format(model.score(X_test, y_test)))

# MSE(mean squared error) 확인

mse_val = ( (pred - y_test) ** 2 ).sum() / len(pred)

print("mse value : {:.3f}".format(mse_val))
```

학습용 데이터 결정계수: 0.391 테스트 데이터 결정계수: 0.377 mse value : 20134.965

In [34]: ▶

```
from sklearn.tree import DecisionTreeRegressor

model = DecisionTreeRegressor() # 모델 객체 생성.

model.fit(X_train, y_train)

pred = model.predict(X_test)

# 결정계수 확인

print("학습용 데이터 결정계수: {:.3f}".format(model.score(X_train, y_train)))

print("테스트 데이터 결정계수: {:.3f}".format(model.score(X_test, y_test)))

# MSE(mean squared error) 확인

mse_val = ( (pred - y_test) ** 2 ).sum() / len(pred)

print("mse value : {:.3f}".format(mse_val))
```

학습용 데이터 결정계수: 1.000 테스트 데이터 결정계수: 0.897

mse value : 3339.917

In [35]:

```
from sklearn.ensemble import RandomForestRegressor # 앙상블(의사결정트리 확장판)

seed = 37

model = RandomForestRegressor(n_jobs=-1, random_state=seed) # 모델 객체 생성.

model.fit(X_train, y_train) # 모델 학습(공부가 되었다.)

pred = model.predict(X_test)

# 결정계수 확인

print("학습용 데이터 결정계수: {:.3f}".format(model.score(X_train, y_train)))

print("테스트 데이터 결정계수: {:.3f}".format(model.score(X_test, y_test)))

# MSE(mean squared error) 확인

mse_val = ((pred - y_test) ** 2 ).sum() / len(pred)

print("mse value : {:.3f}".format(mse_val))
```

학습용 데이터 결정계수: 0.992 테스트 데이터 결정계수: 0.946

mse value : 1752.403

In [36]:

```
from sklearn.ensemble import GradientBoostingRegressor

seed = 37

model = GradientBoostingRegressor(random_state=seed) # 모델 객체 생성.

model.fit(X_train, y_train) # 모델 학습(공부가 되었다.)

pred = model.predict(X_test)

# 결정계수 확인

print("학습용 데이터 결정계수: {:.3f}".format(model.score(X_train, y_train)))

print("테스트 데이터 결정계수: {:.3f}".format(model.score(X_test, y_test)))

# MSE(mean squared error) 확인

mse_val = ((pred - y_test) ** 2 ).sum() / len(pred)

print("mse value : {:.3f}".format(mse_val))
```

학습용 데이터 결정계수: 0.860 테스트 데이터 결정계수: 0.849

mse value : 4892.054

In [37]: ▶

```
sub = pd.read_csv("bike/sampleSubmission.csv")
sub.head()
```

Out [37]:

	datetime	count
0	2011-01-20 00:00:00	0
1	2011-01-20 01:00:00	0
2	2011-01-20 02:00:00	0
3	2011-01-20 03:00:00	0
4	2011-01-20 04:00:00	0

```
In [38]:
```

```
from sklearn.ensemble import RandomForestRegressor # 앙상블(의사결정트리 확장판)
seed = 37
model = RandomForestRegressor(n_jobs=-1, random_state=seed) # 모델 객체 생성.
model.fit(X_train, y_train) # 모델 학습(공부가 되었다.)
```

Out[38]:

RandomForestRegressor(n_jobs=-1, random_state=37)

```
In [39]: ▶
```

```
pred = model.predict(X_test_all) # 예측
sub['count'] = pred
sub.loc[sub['count'] < 0, 'count'] = 0
sub.head(3)
```

Out[39]:

	datetime	count	
0	2011-01-20 00:00:00	11.75	
1	2011-01-20 01:00:00	4.20	
2	2011-01-20 02:00:00	4.78	

In [40]: ▶

```
# 처음 만는 제출용 csv 파일, 행번호를 없애기 sub.to_csv("third_sub.csv", index=False)
```

score: 0.43006

실습: PolynomialFeatures를 사용하여 특징을 추가 생성해 보자.

```
In [41]:
```

```
from sklearn.preprocessing import MinMaxScaler from sklearn.preprocessing import PolynomialFeatures
```

In [42]:

```
season holiday workingday
                                weather
                                          temp
                                                 atemp humidity windspeed ₩
0
        1
                 0
                             0
                                       1
                                         9.84
                                                14.395
                                                              81
                                                                        0.0
1
        1
                 0
                             0
                                       1
                                         9.02
                                                13.635
                                                              80
                                                                         0.0
2
        1
                 0
                             0
                                       1
                                         9.02
                                                13.635
                                                              80
                                                                        0.0
3
        1
                 0
                             0
                                       1
                                         9.84
                                                14.395
                                                              75
                                                                         0.0
                 0
                             0
                                                              75
4
        1
                                       1 9.84
                                                14.395
                                                                        0.0
```

```
dayofweek
   year
        hour
 2011
            0
                       5
0
1
  2011
            1
                       5
                       5
2
 2011
            2
                       5
            3
3
  2011
4 2011
            4
                       5
```

In [43]: ▶

```
In [44]: ▶
```

```
In [45]:
                                                                                             H
from sklearn.ensemble import RandomForestRegressor # 앙상블(의사결정트리 확장판)
seed = 37
model = RandomForestRegressor(n_jobs=-1, random_state=seed) # 모델 객체 생성.
                                    # 무델 학습
model.fit(X_train, y_train)
pred = model.predict(X_test)
# 결정계수 확인
print("학습용 데이터 결정계수: {:.3f}".format(model.score(X_train, y_train)))
print("테스트 데이터 결정계수: {:.3f}".format(model.score(X_test, y_test)))
# MSE(mean squared error) 확인
mse\_val = ((pred - y\_test) ** 2).sum() / len(pred)
print("mse value : {:.3f}".format(mse_val))
학습용 데이터 결정계수: 0.992
테스트 데이터 결정계수: 0.950
mse value : 1659.031
In [46]:
                                                                                             H
nor_X_test_all = scaler.transform(X_test_all)
ex_X_test = PolynomialFeatures(degree=2,
                             include_bias=False).fit_transform(nor_X_test_all)
In [47]:
                                                                                             И
pred = model.predict(ex_X_test) # 예측
sub['count'] = pred
sub.loc[sub['count'] < 0, 'count'] = 0</pre>
sub.head(3)
Out [47]:
            datetime count
0 2011-01-20 00:00:00
                    13.66
1 2011-01-20 01:00:00
                     5.08
2 2011-01-20 02:00:00
                     3.53
In [48]:
                                                                                             H
```

score: 0.41328

sub.to_csv("four_sub.csv", index=False)

다양한 특징 중에 모델을 활용한 중요한 특징을 선택해 보자.

```
In [49]:
import warnings
warnings.filterwarnings(action='ignore')
from sklearn.feature_selection import SelectPercentile, f_classif
from sklearn.feature_selection import SelectFromModel
from sklearn.ensemble import RandomForestRegressor
In [50]:
select = SelectFromModel(RandomForestRegressor(random_state=37),
                                          threshold="0.1 * median")
select.fit(X_train, y_train)
Out [50]:
SelectFromModel(estimator=RandomForestRegressor(random_state=37),
              threshold='0.1 * median')
In [51]:
                                                                                         M
X_train_I1 = select.transform(X_train)
X_{test_{11}} = select.transform(X_{test_{11}})
X_train_I1.shape, X_test_I1.shape
Out [51]:
((8708, 68), (2178, 68))
In [52]:
### 어떤 특성이 선택되었는지 확인
mask = select.get_support()
print(mask)
plt.matshow(mask.reshape(1, -1), cmap='gray_r')
plt.xlabel("특성 번호")
False True
            True
                  True True True True True
                                             True
                                                  True False False
False
       True
            True
                  True False False False
                                             True
                                                  True True True
 True
       True
            True
                  True True True True True
                                            True
                                                  True True True
 True
       True
            True
                  True
                       True
                            True True True True True True
       True
            True
                       True
                             True True True True True True
 True
                  True
      True
                       True]
                 True
 True
            True
Out [52]:
Text(0.5, 0, '특성 번호')
```

```
In [53]:
seed = 37
model = RandomForestRegressor(n_jobs=-1, random_state=seed) # 모델 객체 생성.
                                     # 모델 학습(공부가 되었다.)
model.fit(X_train_l1, y_train)
pred = model.predict(X_test_l1)
# 결정계수 확인
print("학습용 세트 결정계수: {:.3f}".format(model.score(X_train_I1, y_train)))
print("테스트 세트 결정계수: {:.3f}".format(model.score(X_test_I1, y_test)))
mse_val = ((pred - y_test)**2).sum() / len(pred)
print("MSE: {:.3f}".format( mse val ))
학습용 세트 결정계수: 0.992
테스트 세트 결정계수: 0.950
MSE: 1644.395
In [54]:
                                                                                          M
X_test_l1_all = select.transform(ex_X_test)
X_test_l1_all.shape
Out [54]:
(6493, 68)
In [55]:
                                                                                          H
pred = model.predict(X_test_|1_a||)
sub['count'] = pred
sub.loc[ sub['count'] <0 , 'count' ] =0</pre>
sub.to_csv('five_sub.csv', index=False)
전 제출 점수에 비해 약간 더 향상되었다.
대표적인 모델 xgboost 사용해 보기
In [56]:
                                                                                          M
import xgboost as xgb
In [62]:
### xgb.DMatrix
# * dense matrix, sparse matrix, local file로부터 DMatrix object 객체를 만든다.
# data_dmatrix = xgb.DMatrix(data=ex_X_tr, label=y_tr_all)
In [63]:
X_train, X_test, y_train, y_test = train_test_split(ex_X_tr,
                                                y_tr_all,
                                                test_size=0.2.
                                                random_state=42)
```

In [64]:

기본 옵션 확인

xg_reg = xgb.XGBRegressor()

xg_reg

Out [64]:

XGBRegressor(base_score=None, booster=None, colsample_bylevel=None, colsample_bynode=None, colsample_bytree=None, gamma=None, gpu_id=None, importance_type='gain', interaction_constraints=None, learning_rate=None, max_delta_step=None, max_depth=None, min_child_weight=None, missing=nan, monotone_constraints=None, n_estimators=100, n_jobs=None, num_parallel_tree=None, random_state=None, reg_alpha=None, reg_lambda=None, scale_pos_weight=None, subsample=None, tree_method=None, validate_parameters=None, verbosity=None)

사이킷런 기반 파라미터 설명

• 기본값은 사이킷런 기반 기본값

파라마터명	설명	사이킷런 기본값(파이썬기반)
learning_rate(or eta)	0~1사이의 값. 과적합을 방지하기 위한 학습률 값	기본값 : 0.1(0.3)
n_estimators(or num_boost_rounds)	트리의 수	기본값 100(10)
max_depth	각각의 나무 모델의 최대 깊이	기본값 3(6)
subsample	각 나무마다 사용하는 데이터 샘플 비율 낮은 값은 underfitting(과소적합)을 야기할 수 있음.	기본값 : 1
colsample_bytree	각 나무마다 사용하는 feature 비율 . High value can lead to overfitting.	기본값 : 1
reg_alpha(or alpha)	L1 규제에 대한 항 피처가 많을 수록 적용을 검토한다.	기본값 : 0
reg_lambda(or lambda)	L2 규제의 적용 값. 피처의 개수가 많을 경우 적용 검토	기본값 : 1
scale_pos_weight	불균형 데이터셋의 균형 유지	기본값 : 1

학습 태스크 파라미터

파라마터명 설명

사이킷런 기본값(파이썬기반)

reg:linear for regression problems(회귀 문제), objective(목적함수) reg:logistic for classification problems with only decision(분류 문제),

binary:logistic for classification problems with probability.(이진 분류)

In [73]:

feature_names = ['season', 'holiday', 'workingday', 'weather', 'temp', 'atemp', 'humidity', 'windspeed', "year", "hour", "dayofweek"] # 공통 변수

X_tr_all = new_tr[feature_names] # 학습용 데이터 변수 선택

```
season holiday workingday weather
                                                atemp humidity windspeed ₩
                                         temp
0
                 0
                                         9.84
                                               14.395
                                                             81
                                                                        0.0
        1
                             0
                                      1
                 0
                             0
                                                             80
                                                                        0.0
1
        1
                                      1
                                         9.02
                                               13.635
2
                 0
                             0
                                         9.02
                                               13.635
                                                             80
                                                                        0.0
        1
                                      1
3
                                                             75
        1
                 0
                             0
                                      1 9.84
                                               14.395
                                                                        0.0
4
        1
                 ()
                             0
                                      1 9.84 14.395
                                                             75
                                                                        0.0
```

X_test_all = new_test[feature_names] # 테스트 데이터의 변수 선택

```
year hour
              dayofweek
0 2011
           0
                      5
  2011
           1
1
                      5
2
 2011
           2
                      5
3 2011
           3
                      5
4 2011
           4
```

print(X_tr_all.head())

In [79]:

Out [79]:

```
((10886, 11), (10886, 77))
```

In [80]: ▶

In [81]:

Out[81]:

```
XGBRegressor(alpha=0.1, base_score=None, booster=None, colsample_bylevel=None, colsample_bynode=None, colsample_bytree=0.3, gamma=None, gpu_id=None, importance_type='gain', interaction_constraints=None, learning_rate=0.1, max_delta_step=None, max_depth=4, min_child_weight=None, missing=nan, monotone_constraints=None, n_estimators=100, n_jobs=None, num_parallel_tree=None, objective='reg:linear', random_state=None, reg_alpha=None, reg_lambda=None, scale_pos_weight=None, subsample=None, tree_method=None, validate_parameters=None, verbosity=None)
```

학습

In [82]: ▶

```
xg_reg.fit(X_train, y_train) # 모델 학습(공부가 되었다.)
```

[23:47:42] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa rederror.

Out [82]:

```
XGBRegressor(alpha=0.1, base_score=0.5, booster='gbtree', colsample_bylevel=1, colsample_bynode=1, colsample_bytree=0.3, gamma=0, gpu_id=-1, importance_type='gain', interaction_constraints='', learning_rate=0.1, max_delta_step=0, max_depth=4, min_child_weight=1, missing=nan, monotone_constraints='()', n_estimators=100, n_jobs=8, num_parallel_tree=1, objective='reg:linear', random_state=0, reg_alpha=0.100000001, reg_lambda=1, scale_pos_weight=1, subsample=1, tree_method='exact', validate_parameters=1, verbosity=None)
```

In [83]:

```
# 결정계수 확인
print("학습용 데이터 결정계수: {:.3f}".format(xg_reg.score(X_train, y_train)))
print("테스트 데이터 결정계수: {:.3f}".format(xg_reg.score(X_test, y_test)))
```

학습용 데이터 결정계수: 0.942 테스트 데이터 결정계수: 0.931

실습

• 나무의 개수를 조정해 보면서 확인해 보자.

```
%%time
num_list = [100, 200, 300, 500, 1000, 1500, 2000, 3000]
for num in num_list:
   xg_reg = xgb.XGBRegressor(objective = reg:linear,
           colsample_bytree = 0.3, # 각나무마다 사용하는 feature 비율
           learning_rate = 0.1,
           max_depth = 3,
           alpha = 0.1.
           n_estimators = num)
   xg_reg.fit(X_train, y_train)
   pred = xg_reg.predict(X_test)
   # 결정계수 확인
   print("학습용 데이터 결정계수: {:.3f}".format(xg_reg.score(X_train, y_train)))
   print("테스트 데이터 결정계수: {:.3f}".format(xg_reg.score(X_test, y_test)))
   # MSE(mean squared error) 확인
   mse_val = ((pred - y_test) ** 2).sum() / len(pred)
   print("mse value : {:.3f}".format(mse_val))
[23:49:24] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 데이터 결정계수: 0.907
테스트 데이터 결정계수: 0.899
mse value : 3347.659
[23:49:24] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 데이터 결정계수: 0.937
테스트 데이터 결정계수: 0.926
mse value : 2447.874
[23:49:25] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 데이터 결정계수: 0.947
테스트 데이터 결정계수: 0.934
mse value : 2170.976
[23:49:26] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 데이터 결정계수: 0.959
테스트 데이터 결정계수: 0.943
mse value : 1886.819
[23:49:28] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 데이터 결정계수: 0.972
테스트 데이터 결정계수: 0.950
mse value : 1652.617
[23:49:31] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 데이터 결정계수: 0.979
테스트 데이터 결정계수: 0.952
mse value : 1599.291
```

```
[23:49:36] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa rederror.
학습용 데이터 결정계수: 0.983
테스트 데이터 결정계수: 0.952
mse value : 1569.143
[23:49:43] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa rederror.
학습용 데이터 결정계수: 0.988
테스트 데이터 결정계수: 0.953
mse value : 1549.574
Wall time: 31.6 s
```

최종 모델

In [88]:

[23:49:58] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa rederror.

학습용 세트 정확도: 0.998 테스트 세트 정확도: 0.959

In [89]:

```
ex_X_test = PolynomialFeatures(degree=2, include_bias=False).fit_transform(X_test_all)
```

```
In [90]:
```

```
pred = xg_reg.predict(ex_X_test) # 예측
sub['count'] = pred
sub.loc[sub['count'] < 0, 'count'] = 0
sub.head(3)
```

Out [90]:

	datetime	count
0	2011-01-20 00:00:00	16.996292
1	2011-01-20 01:00:00	0.554334
2	2011-01-20 02:00:00	0.000000

In [91]:

처음 만는 제출용 csv 파일, 행번호를 없애기 sub.to_csv("five_xgb_sub.csv", index=False)

• 제출 스코어: 0.59553

파라미터를 변경해 가며 실습해보기 - 아래 각각의 경우에 대한 score확인해 보기

- Ir_rate=0.1, max_depth = 4, 1000개 트리
- Ir_rate=0.1, max_depth = 3, 1500개 트리
- Ir_rate = 0.001, max_depth = 3, 1000개 트리
- Ir_rate = 0.05, max_depth = 5, 500개 트리

History

• 2021-10 update v12

교육용으로 작성된 것으로 배포 및 복제시에 사전 허가가 필요합니다.

Copyright 2021 LIM Co. all rights reserved.