Kaggle 입문하기 - 데이터 분석 입문

- 특성 자동 선택 함수를 사용해 봅니다.
- 다양한 모델을 활용해 봅니다.

Data Fields

```
필드명 설명
```

```
datetime hourly date + timestamp
   season 1 = spring, 2 = summer, 3 = fall, 4 = winter
   holiday whether the day is considered a holiday
workingday whether the day is neither a weekend nor holiday
            1: Clear, Few clouds, Partly cloudy, Partly cloudy
  weather
            2: Mist + Cloudy, Mist + Broken clouds, Mist + Few clouds, Mist
            3: Light Snow, Light Rain + Thunderstorm + Scattered clouds, Light Rain + Scattered clouds
            4: Heavy Rain + Ice Pallets + Thunderstorm + Mist, Snow + Fog
     temp temperature in Celsius (온도)
    atemp "feels like" temperature in Celsius (체감온도)
  humidity relative humidity (습도)
windspeed wind speed (바람속도)
    casual number of non-registered user rentals initiated (비가입자 사용유저)
 registered number of registered user rentals initiated (가입자 사용유저)
     count number of total rentals (전체 렌탈 대수)
```

```
In [75]:

import pandas as pd
```

```
In [76]:
```

```
train = pd.read_csv("bike/train.csv", parse_dates=['datetime'])
test = pd.read_csv("bike/test.csv", parse_dates=['datetime'])
```

```
In [77]:
```


```
import matplotlib.pyplot as plt ## seaborn 보다 고급 시각화 가능. but 코드 복잡
import seaborn as sns ## seaborn은 matplotlib보다 간단하게 사용 가능
```

In [78]: ▶

```
col_names = [ 'season', 'holiday', 'workingday', 'weather' ]
i = 0
plt.figure(figsize=(12,10)) # 전체 그래프의 크기 지정

for name in col_names: # 컬럼명을 전달 리스트 수 만큼 반복 -> 4회
i = i + 1 # 숫자를 1씩 증가.
plt.subplot(2,2,i) # 2행 2열에 i번째 그래프 선택
sns.countplot(x=name, data=train) # i번째 그래프에 sns.countplot를 그리겠다.

plt.show() # 주피터에서 보여주지만, 다른곳(editor, pycharm)에서는 이걸 실행시켜야 한다.
```



수치형 데이터 선택


In [79]:


```
### temp, atemp, humidity, windspeed
num_names = ['temp', 'atemp', 'humidity', 'windspeed']
train.columns
```

Out [79]:

In [80]:

```
i = 0
plt.figure(figsize=(12,25))
                         # 전체 그래프의 크기 지정 (가로, 세로)
for name in num_names:
                          # 컬럼명을 전달 리스트 수 만큼 반복 -> 4회
   i = i + 1
                         # 숫자를 1씩 증가.
   plt.subplot(4,2,i*2-1)
                             # 2행 2열에 i번째 그래프 선택
   sns.histplot(x=name, data=train) # i번째 그래프에 sns.histplot를 그리겠다.
   plt.title("train feature")
   plt.subplot(4,2,i*2)
                           # 2행 2열에 i번째 그래프 선택
   sns.histplot(x=name, data=test) # i번째 그래프에 sns.histplot를 그리겠다.
   plt.title("test feature")
plt.show()
```





```
new_tr = train.copy() # 데이터 백업
new_test = test.copy()
new_tr.columns
```

Out[81]:

특징 추출 - 날짜 피처로부터 추출

In [82]:

```
## 더미변수, 파생변수 생성
new_tr['year'] = new_tr['datetime'].dt.year
new_tr.head()
```

Out[82]:

	datetime	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	casual
0	2011-01- 01 00:00:00	1	0	0	1	9.84	14.395	81	0.0	3
1	2011-01- 01 01:00:00	1	0	0	1	9.02	13.635	80	0.0	8
2	2011-01- 01 02:00:00	1	0	0	1	9.02	13.635	80	0.0	5
3	2011-01- 01 03:00:00	1	0	0	1	9.84	14.395	75	0.0	3
4	2011-01- 01 04:00:00	1	0	0	1	9.84	14.395	75	0.0	0

```
In [83]:
```

```
new_tr['month'] = new_tr['datetime'].dt.month
new_tr['day'] = new_tr['datetime'].dt.day
new_tr['hour'] = new_tr['datetime'].dt.hour
new_tr['minute'] = new_tr['datetime'].dt.minute
new_tr['second'] = new_tr['datetime'].dt.second
new_tr['dayofweek'] = new_tr['datetime'].dt.dayofweek
new_tr.head()
```

Out[83]:

	datetime	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	casual
0	2011-01- 01 00:00:00	1	0	0	1	9.84	14.395	81	0.0	3
1	2011-01- 01 01:00:00	1	0	0	1	9.02	13.635	80	0.0	8
2	2011-01- 01 02:00:00	1	0	0	1	9.02	13.635	80	0.0	5
3	2011-01- 01 03:00:00	1	0	0	1	9.84	14.395	75	0.0	3
4	2011-01- 01 04:00:00	1	0	0	1	9.84	14.395	75	0.0	0

In [84]:


train.columns

Out [84]:

In [85]: ▶

```
datetime_names = ['year', 'month', 'day', 'hour', 'minute', 'second']
i=0
plt.figure(figsize=(15,10))
for name in datetime_names:
    i = i + 1
    plt.subplot(3,2,i)
    sns.barplot(x=name, y='count', data=new_tr)

plt.show()
```



In [86]:

```
new_test['year'] = new_test['datetime'].dt.year
new_test['month'] = new_test['datetime'].dt.month
new_test['day'] = new_test['datetime'].dt.day
new_test['dayofweek'] = new_test['datetime'].dt.dayofweek
new_test['hour'] = new_test['datetime'].dt.hour
new_test['minute'] = new_test['datetime'].dt.minute
new_test['second'] = new_test['datetime'].dt.second
```

In [87]:


```
col_names = ['year', 'month', 'day', 'hour', 'dayofweek']
i = 0

plt.figure(figsize=(12,20)) ##전체 그래프 크기 지정

for name in col_names: ## 컬럼명으로 반복
    i = i+1
    plt.subplot(6,2,i) ##2행2열, i = 1,2,3,4 (왼쪽 상단부터 시계방향으로 순번 지정)
    sns.countplot(x = name, data = new_tr)

i = i+1
    plt.subplot(6,2,i) ##2행2열, i = 1,2,3,4 (왼쪽 상단부터 시계방향으로 순번 지정)
    sns.countplot(x = name, data = new_test)

plt.show()
```




In [88]: ►

new_tr['dayofweek'] = new_tr['datetime'].dt.dayofweek # Monday=0, Sunday=6

In [89]:

```
datetime_names = ['year', 'month', 'day', 'hour', 'dayofweek', 'second']
i=0
plt.figure(figsize=(15,10))
for name in datetime_names:
    i = i + 1
    plt.subplot(3,2,i)
    sns.barplot(x=name, y='count', data=new_tr)

plt.show()
```



In [94]: ▶

```
print(new_test.shape)
new_test[["datetime", "year", "month", "day", "hour", "minute", "second", "dayofweek"]].head()
```


(6493, 16)

Out [94]:

	datetime	year	month	day	hour	minute	second	dayofweek
0	2011-01-20 00:00:00	2011	1	20	0	0	0	3
1	2011-01-20 01:00:00	2011	1	20	1	0	0	3
2	2011-01-20 02:00:00	2011	1	20	2	0	0	3
3	2011-01-20 03:00:00	2011	1	20	3	0	0	3
4	2011-01-20 04:00:00	2011	1	20	4	0	0	3

In [95]: ▶

plt.figure(figsize=(15,10))
g = sns.heatmap(new_tr.corr(), annot=True, fmt=".2f", cmap="coolwarm", cbar=False)



```
In [96]:
feature_names = [ 'season', 'holiday', 'workingday', 'weather',
                 'temp', 'atemp', 'humidity', 'windspeed',
                 "year", "hour", "dayofweek"] # 공통 변수
X_tr_all = new_tr[feature_names] # 학습용 데이터 변수 선택
X_test_all = new_test[feature_names] # 테스트 데이터의 변수 선택
print(X_tr_all.head())
   season holiday workingday weather
                                      temp
                                            atemp humidity windspeed ₩
0
       1
                0
                           0
                                      9.84 14.395
                                                         81
                                                                  0.0
                                   1
1
       1
                0
                           0
                                   1 9.02
                                            13.635
                                                         80
                                                                  0.0
2
                0
                                                         80
                                                                  0.0
       1
                           0
                                   1 9.02
                                            13.635
3
                0
                           0
                                   1 9.84
                                            14.395
                                                         75
                                                                  0.0
       1
4
       1
                0
                           0
                                   1 9.84 14.395
                                                         75
                                                                  0.0
              dayofweek
   year hour
0
  2011
           0
                     5
                     5
  2011
1
           1
                     5
2 2011
           2
                     5
3 2011
           3
                     5
4 2011
           4
In [97]:
                                                                                           H
label_name = 'count'
                                   # 렌탈 대수 (종속변수)
                                  # 렌탈 대수 변수 값 선택
y_tr_all = new_tr[label_name]
In [98]:
                                                                                           H
```

```
from sklearn.model_selection import train_test_split

In [99]:
```

In [100]:

```
from sklearn.linear_model import LinearRegression
model = LinearRegression() # 모델 객체 생성.
model.fit(X_train, y_train)
pred = model.predict(X_test)
# 결정계수 확인
print("학습용 데이터 결정계수: {:.3f}".format(model.score(X_train, y_train)))
print("테스트 데이터 결정계수: {:.3f}".format(model.score(X_test, y_test)))
# MSE(mean squared error) 확인
mse\_val = ( (pred - y\_test) ** 2 ).sum() / len(pred)
print("mse value : {:.3f}".format(mse_val))
```

학습용 데이터 결정계수: 0.391 테스트 데이터 결정계수: 0.377

mse value : 20134.965

In [101]: M

```
from sklearn.tree import DecisionTreeRegressor
model = DecisionTreeRegressor() # 모델 객체 생성.
model.fit(X_train, y_train)
pred = model.predict(X_test)
# 결정계수 확인
print("학습용 데이터 결정계수: {:.3f}".format(model.score(X_train, y_train)))
print("테스트 데이터 결정계수: {:.3f}".format(model.score(X_test, y_test)))
# MSE(mean squared error) 확인
mse\_val = ((pred - y\_test) ** 2).sum() / len(pred)
print("mse value : {:.3f}".format(mse_val))
```

학습용 데이터 결정계수: 1.000 테스트 데이터 결정계수: 0.897

mse value : 3325.572

In [102]:

```
from sklearn.ensemble import RandomForestRegressor # 앙상블(의사결정트리 확장판)

seed = 37

model = RandomForestRegressor(n_jobs=-1, random_state=seed) # 모델 객체 생성.

model.fit(X_train, y_train) # 모델 학습(공부가 되었다.)

pred = model.predict(X_test)

# 결정계수 확인

print("학습용 데이터 결정계수: {:.3f}".format(model.score(X_train, y_train)))

print("테스트 데이터 결정계수: {:.3f}".format(model.score(X_test, y_test)))

# MSE(mean squared error) 확인

mse_val = ((pred - y_test) ** 2).sum() / len(pred)

print("mse value : {:.3f}".format(mse_val))
```

학습용 데이터 결정계수: 0.992 테스트 데이터 결정계수: 0.946

mse value : 1752.403

In [103]: ▶

```
from sklearn.ensemble import GradientBoostingRegressor

seed = 37
model = GradientBoostingRegressor(random_state=seed) # 모델 객체 생성.
model.fit(X_train, y_train) # 모델 학습(공부가 되었다.)
pred = model.predict(X_test)

# 결정계수 확인
print("학습용 데이터 결정계수: {:.3f}".format(model.score(X_train, y_train)))
print("테스트 데이터 결정계수: {:.3f}".format(model.score(X_test, y_test)))

# MSE(mean squared error) 확인
mse_val = ((pred - y_test) ** 2).sum() / len(pred)
print("mse value : {:.3f}".format(mse_val))
```

학습용 데이터 결정계수: 0.860 테스트 데이터 결정계수: 0.849

mse value : 4892.054

In [104]: ▶

```
sub = pd.read_csv("bike/sampleSubmission.csv")
sub.head()
```

Out [104]:

	uatetime	Count
0	2011-01-20 00:00:00	0
1	2011-01-20 01:00:00	0
2	2011-01-20 02:00:00	0
3	2011-01-20 03:00:00	0
4	2011-01-20 04:00:00	0

In [105]: ▶

```
from sklearn.ensemble import RandomForestRegressor # 앙상블(의사결정트리 확장판)
seed = 37
model = RandomForestRegressor(n_jobs=-1, random_state=seed) # 모델 객체 생성.
model.fit(X_train, y_train) # 모델 학습(공부가 되었다.)
```

Out[105]:

RandomForestRegressor(n_jobs=-1, random_state=37)

In [106]: ▶

```
pred = model.predict(X_test_all) # 예측
sub['count'] = pred
sub.loc[sub['count'] < 0, 'count'] = 0
sub.head(3)
```

Out[106]:

0	2011-01-20 00:00:00	11.75
1	2011-01-20 01:00:00	4.20
2	2011-01-20 02:00:00	4.78

datetime count

In [107]:

```
# 처음 만는 제출용 csv 파일, 행번호를 없애기 sub.to_csv("third_sub.csv", index=False)
```

score: 0.43006

실습: 특징 상호작용으로 특징을 더 생성해 보자.

```
In [108]:
```

```
from sklearn.preprocessing import MinMaxScaler from sklearn.preprocessing import PolynomialFeatures
```

In [109]:

```
season holiday workingday weather
                                         temp
                                                atemp humidity windspeed ₩
0
        1
                 0
                             0
                                      1
                                         9.84
                                               14.395
                                                              81
                                                                        0.0
1
        1
                 0
                             0
                                      1
                                         9.02
                                               13.635
                                                              80
                                                                        0.0
2
        1
                 0
                             0
                                      1
                                         9.02
                                               13.635
                                                              80
                                                                        0.0
3
        1
                 0
                             0
                                      1
                                         9.84
                                               14.395
                                                              75
                                                                        0.0
                 0
                             0
                                                              75
4
        1
                                      1 9.84
                                               14.395
                                                                        0.0
```

```
dayofweek
   year hour
0 2011
            0
                       5
1
  2011
            1
                       5
                       5
2 2011
            2
                       5
            3
3 2011
4 2011
            4
                       5
```

In [110]:

```
In [111]:
```

```
X_train, X_test, y_train, y_test = train_test_split(ex_X_tr,
	y_tr_all,
	test_size=0.2,
	random_state=42)
```

```
In [113]:
                                                                                             H
from sklearn.ensemble import RandomForestRegressor # 앙상블(의사결정트리 확장판)
seed = 37
model = RandomForestRegressor(n_jobs=-1, random_state=seed) # 모델 객체 생성.
                                    # 무델 학습
model.fit(X_train, y_train)
pred = model.predict(X_test)
# 결정계수 확인
print("학습용 데이터 결정계수: {:.3f}".format(model.score(X_train, y_train)))
print("테스트 데이터 결정계수: {:.3f}".format(model.score(X_test, y_test)))
# MSE(mean squared error) 확인
mse\_val = ((pred - y\_test) ** 2).sum() / len(pred)
print("mse value : {:.3f}".format(mse_val))
학습용 데이터 결정계수: 0.992
테스트 데이터 결정계수: 0.950
mse value : 1659.031
In [114]:
                                                                                             H
nor_X_test_all = scaler.transform(X_test_all)
ex_X_test = PolynomialFeatures(degree=2,
                             include_bias=False).fit_transform(nor_X_test_all)
In [115]:
                                                                                             И
pred = model.predict(ex_X_test) # 예측
sub['count'] = pred
sub.loc[sub['count'] < 0, 'count'] = 0</pre>
sub.head(3)
Out [115]:
            datetime count
0 2011-01-20 00:00:00
                    13.66
1 2011-01-20 01:00:00
                     5.08
2 2011-01-20 02:00:00
                     3.53
In [116]:
                                                                                             H
```

score: 0.41328

sub.to_csv("four_sub.csv", index=False)

다양한 특징 중에 모델을 활용한 중요한 특징을 선택해 보자.

```
In [117]:
import warnings
warnings.filterwarnings(action='ignore')
from sklearn.feature_selection import SelectPercentile, f_classif
from sklearn.feature_selection import SelectFromModel
from sklearn.ensemble import RandomForestRegressor
In [118]:
select = SelectFromModel(RandomForestRegressor(random_state=37),
                                          threshold="0.1 * median")
select.fit(X_train, y_train)
Out[118]:
SelectFromModel(estimator=RandomForestRegressor(random_state=37),
              threshold='0.1 * median')
In [119]:
                                                                                       M
X_train_l1 = select.transform(X_train)
X_test_I1 = select.transform(X_test)
X_train_I1.shape, X_test_I1.shape
Out[119]:
((8708, 68), (2178, 68))
In [120]:
### 어떤 특성이 선택되었는지 확인
mask = select.get_support()
print(mask)
plt.matshow(mask.reshape(1, -1), cmap='gray_r')
plt.xlabel("특성 번호")
False True
            True
                 True True True True True
                                            True
                                                 True False False
False
      True
            True
                 True False False False
                                            True
                                                 True True True
 True
      True
            True
                 True True True True True True True True
 True
       True
            True
                 True
                       True
                            True True True True True True
       True
            True
                 True
                       True
                            True True True True True True
 True
                      True]
                 True
 True
      True
            True
Out[120]:
Text(0.5, 0, '특성 번호')
```

```
In [121]:
seed = 37
model = RandomForestRegressor(n_jobs=-1, random_state=seed) # 모델 객체 생성.
                                      # 모델 학습(공부가 되었다.)
model.fit(X_train_l1, y_train)
pred = model.predict(X_test_l1)
# 결정계수 확인
print("학습용 세트 결정계수: {:.3f}".format(model.score(X_train_I1, y_train)))
print("테스트 세트 결정계수: {:.3f}".format(model.score(X_test_I1, y_test)))
mse_val = ((pred - y_test)**2).sum() / len(pred)
print("MSE : {:.3f}".format( mse_val ))
학습용 세트 결정계수: 0.992
테스트 세트 결정계수: 0.950
MSE: 1644.395
In [122]:
                                                                                            M
X_test_l1_all = select.transform(ex_X_test)
X_test_l1_all.shape
Out[122]:
(6493, 68)
In [123]:
                                                                                            H
pred = model.predict(X_test_|1_a||)
sub['count'] = pred
sub.loc[ sub['count'] <0 , 'count' ] =0</pre>
sub.to_csv('five_sub.csv', index=False)
```

전 제출 점수에 비해 약간 더 향상되었다.

대표적인 모델 xgboost 사용해 보기

```
In [61]:

import xgboost as xgb
```

xgb.DMatrix

dense matrix, sparse matrix, local file로부터 DMatrix object 객체를 만든다.

```
In [62]:
# data_dmatrix = xgb.DMatrix(data=ex_X_tr, |abe|=y_tr_a||)
```

In [64]:

In [65]: ▶

```
# 기본 옵션 확인
xg_reg = xgb.XGBRegressor()
xg_reg
```

Out [65]:

```
XGBRegressor(base_score=None, booster=None, colsample_bylevel=None, colsample_bynode=None, colsample_bytree=None, gamma=None, gpu_id=None, importance_type='gain', interaction_constraints=None, learning_rate=None, max_delta_step=None, max_depth=None, min_child_weight=None, missing=nan, monotone_constraints=None, n_estimators=100, n_jobs=None, num_parallel_tree=None, random_state=None, reg_alpha=None, reg_lambda=None, scale_pos_weight=None, subsample=None, tree_method=None, validate_parameters=None, verbosity=None)
```

- learning rate: 0~1사이의 값. 과적합을 방지하기 위한 단계 크기
- max_depth: 각각의 나무 모델의 최대 깊이
- subsample: 각 나무마다 사용하는 샘플 퍼센트, 낮은 값은 underfitting(과소적합)을 야기할 수 있음.
- colsample bytree: 각 나무마다 사용하는 **feature 퍼센트**. High value can lead to overfitting.
- n_estimators: 트리의 수(우리가 모델을 생성할)
- loss function(손실함수)결정.
- objective(목적함수)
 - reg:linear for regression problems(회귀 문제),
 - reg:logistic for classification problems with only decision(분류 문제),
 - binary:logistic for classification problems with probability.
- alpha : L1 규제에 대한 항

In [66]:

Out [66]:

```
XGBRegressor(alpha=0.1, base_score=None, booster=None, colsample_bylevel=None, colsample_bynode=None, colsample_bytree=0.3, gamma=None, gpu_id=None, importance_type='gain', interaction_constraints=None, learning_rate=0.1, max_delta_step=None, max_depth=4, min_child_weight=None, missing=nan, monotone_constraints=None, n_estimators=100, n_jobs=None, num_parallel_tree=None, objective='reg:linear', random_state=None, reg_alpha=None, reg_lambda=None, scale_pos_weight=None, subsample=None, tree_method=None, validate_parameters=None, verbosity=None)
```

학습

In [67]: ▶

```
xg_reg.fit(X_train, y_train) # 모델 학습(공부가 되었다.)
```

[15:54:22] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa rederror.

Out [67]:

```
XGBRegressor(alpha=0.1, base_score=0.5, booster='gbtree', colsample_bylevel=1, colsample_bynode=1, colsample_bytree=0.3, gamma=0, gpu_id=-1, importance_type='gain', interaction_constraints='', learning_rate=0.1, max_delta_step=0, max_depth=4, min_child_weight=1, missing=nan, monotone_constraints='()', n_estimators=100, n_jobs=8, num_parallel_tree=1, objective='reg:linear', random_state=0, reg_alpha=0.100000001, reg_lambda=1, scale_pos_weight=1, subsample=1, tree_method='exact', validate_parameters=1, verbosity=None)
```

In [68]:

```
# 결정계수 확인
print("학습용 데이터 결정계수: {:.3f}".format(model.score(X_train, y_train)))
print("테스트 데이터 결정계수: {:.3f}".format(model.score(X_test, y_test)))
```

학습용 데이터 결정계수: 0.992 테스트 데이터 결정계수: 0.950

실습

• 나무의 개수를 조정해 보면서 확인해 보자.

```
%%time
num_list = [100, 200, 300, 500, 1000, 1500]
for num in num_list:
   xg_reg = xgb.XGBRegressor(objective = reg:linear,
           colsample_bytree = 0.3, # 각나무마다 사용하는 feature 비율
           learning_rate = 0.1,
           max_depth = 3,
           alpha = 0.1.
           n_estimators = num)
   xg_reg.fit(X_train, y_train)
   pred = xg_reg.predict(X_test)
   # 결정계수 확인
   print("학습용 데이터 결정계수: {:.3f}".format(model.score(X_train, y_train)))
   print("테스트 데이터 결정계수: {:.3f}".format(model.score(X_test, y_test)))
   # MSE(mean squared error) 확인
   mse_val = ((pred - y_test) ** 2).sum() / len(pred)
   print("mse value : {:.3f}".format(mse_val))
[15:55:09] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 데이터 결정계수: 0.992
테스트 데이터 결정계수: 0.950
mse value : 3257.375
[15:55:09] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 데이터 결정계수: 0.992
테스트 데이터 결정계수: 0.950
mse value : 2368.006
[15:55:10] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 데이터 결정계수: 0.992
테스트 데이터 결정계수: 0.950
mse value : 2104.320
[15:55:12] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 데이터 결정계수: 0.992
테스트 데이터 결정계수: 0.950
mse value : 1865.287
[15:55:14] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 데이터 결정계수: 0.992
테스트 데이터 결정계수: 0.950
mse value : 1647.236
[15:55:18] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 데이터 결정계수: 0.992
테스트 데이터 결정계수: 0.950
```

mse value : 1582.021 Wall time: 15.3 s

최종 모델

```
In [70]:
                                                                                               H
xg_reg = xgb.XGBRegressor(objective = 'reg:linear',
           colsample_bytree = 0.3, # 각나무마다 사용하는 feature 비율
           learning rate = 0.05.
           max_depth = 5,
           alpha = 0.1,
           n_estimators = 500)
xg_reg.fit(X_train, y_train)
print("학습용 세트 정확도: {:.3f}".format(xg_reg.score(X_train, y_train)))
print("테스트 세트 정확도: {:.3f}".format(xg_reg.score(X_test, y_test)))
[15:55:34] WARNING: C:/Users/Administrator/workspace/xgboost-win64_release_1.4.0/sr
c/objective/regression_obj.cu:171: reg:linear is now deprecated in favor of reg:squa
rederror.
학습용 세트 정확도: 0.979
테스트 세트 정확도: 0.956
In [71]:
                                                                                               H
nor_X_test_all = scaler.transform(X_test_all)
ex_X_test = PolynomialFeatures(degree=2,
                              include_bias=False).fit_transform(nor_X_test_all)
In [72]:
                                                                                               H
pred = xg_reg.predict(ex_X_test)
                                  # 예측
sub['count'] = pred
sub.loc[sub['count'] < 0, 'count'] = 0</pre>
sub.head(3)
Out[72]:
            datetime
                        count
0 2011-01-20 00:00:00 12.755984
1 2011-01-20 01:00:00
                     2.368304
2 2011-01-20 02:00:00
                     1.013963
In [73]:
                                                                                               M
# 처음 만는 제출용 csv 파일, 행번호를 없애기
```

다양한 실습해보기 - 아래 각각의 경우에 대한 score확인해 보기

• Ir rate=0.1, max depth = 4, 1000개 트리

sub.to_csv("five_xgb_sub.csv", index=False)

- Ir_rate=0.1, max_depth = 3, 1500개 트리
- Ir_rate = 0.001, max_depth = 3, 1000개 트리

• Ir_rate = 0.05, max_depth = 5, 500개 트리

History

• 2021-10 update v12

교육용으로 작성된 것으로 배포 및 복제시에 사전 허가가 필요합니다.
Copyright 2021 LIM Co. all rights reserved.