> 📚 참고: 이 실습은 『파이썬 라이브러리를 활용한 머신러닝』(안드레아스 뮐러·세라 가이도 지음, 박해선 옮김, 한빛미디어) 예제와 저자의 `mglearn` 패키지(BSD 라이선스)를 바탕으로 합니다.

> 🛠️ **2026.10 수정본 (v11)** — 원본: ch03_04_02_차원축소(2)_PCA_얼굴예제.ipynb
>
> 주성분 그림을 그릴 때 쓰는 `image_shape`가 노트북 뒤쪽에서야 만들어져서 에러가 났어요. 처음 쓰는 셀에서 먼저 정의하도록 한 줄 추가했습니다. 한글 폰트 설정은 윈도우 경로 대신 `koreanize-matplotlib`로 바꿨어요.

CH03 비지도학습 - PCA 얼굴 예제

학습 내용

- 사람 얼굴 이미지 데이터 셋을 이용한 PCA 예제 실습

목차

01 왜 비지도학습을 사용하는가?
02. 사람 얼굴 이미지 데이터 셋을 이용한 PCA 예제 실습
03. 모델 구축하기

01 왜 비지도학습을 사용하는가?

목차로 이동하기

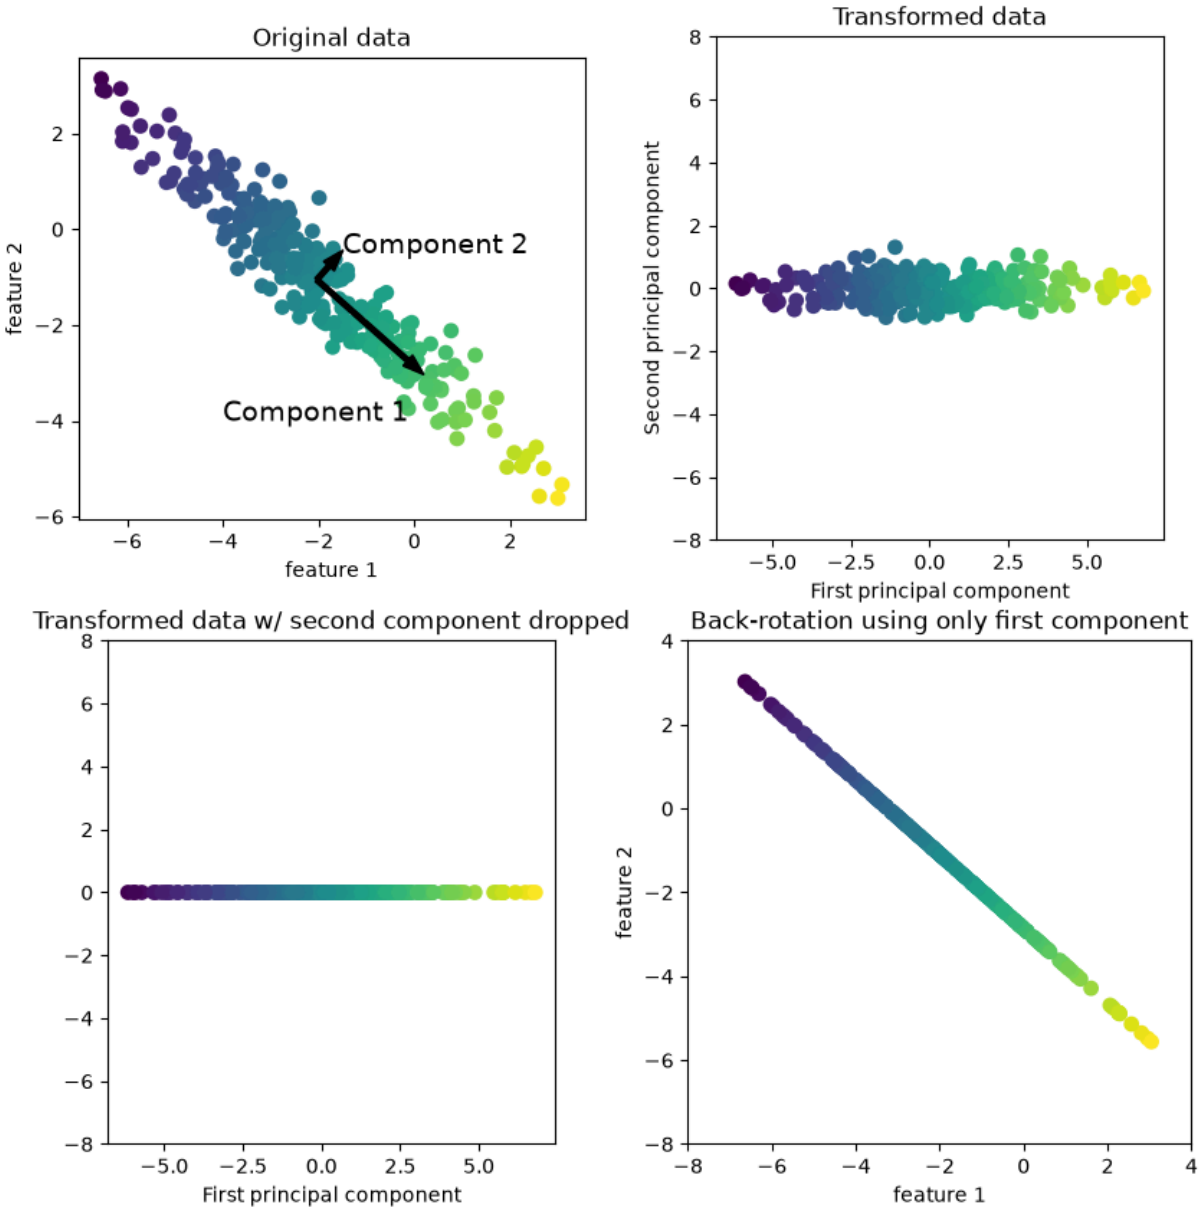
```
가. 시각화한다.
나. 데이터를 많은 feature를 몇개의 압축적인 feature(특성)으로 줄인다.
다. 추가적인 처리(주로 지도학습에 이용하기 위해)
```

In [1]:
```
import mglearn

print(mglearn.__version__)
```

```
0.1.9
```

In [2]:
```
mglearn.plots.plot_pca_illustration()
```



02. 사람 얼굴 이미지 데이터 셋을 이용한 PCA 예제 실습

목차로 이동하기

LFW(Labeled Faces in the Wild)데이터 셋에서 얼굴 이미지에서 특성 추출

- 데이터 셋 : 데이터 셋 :
  - 매사추세츠 애머스트 주립대학교의 비전랩에서 생성 http://vis-www.cs.umass.edu/lfw를 참고
  - 인터넷에서 내려 받은 유명 인사들의 얼굴 이미지. 2000년 초반 정치인, 가수, 배우, 운동선수들의 얼굴을 포함.
  - 총 62명의 얼굴. 3023개의 이미지

- 이미지의 크기 87 x 65

In [3]:
```
from sklearn.datasets import fetch_lfw_people
import matplotlib.pyplot as plt
import numpy as np
from sklearn.model_selection import train_test_split
import sklearn

print(sklearn.__version__)
```

```
1.9.1
```

- 얼굴 이미지는 각 사람당 최소 20장의 이미지
- 데이터 다운로드시 에러 발생시,
- [해결] colab 등의 개발 환경 바꾸기, 버전 체크 등

In [4]:
```
people = fetch_lfw_people(min_faces_per_person=20, resize=0.7) # 컬러 이미지는

print(people.keys())
print("각 이미지당 장수 ", np.bincount(people.target))

print("이미지 행렬 ", people.images.shape)
print("어떤 사람들인가? " , people.target_names)      # 총 62명
print("한장의 이미지 크기 : ", people.images[0].shape )
```

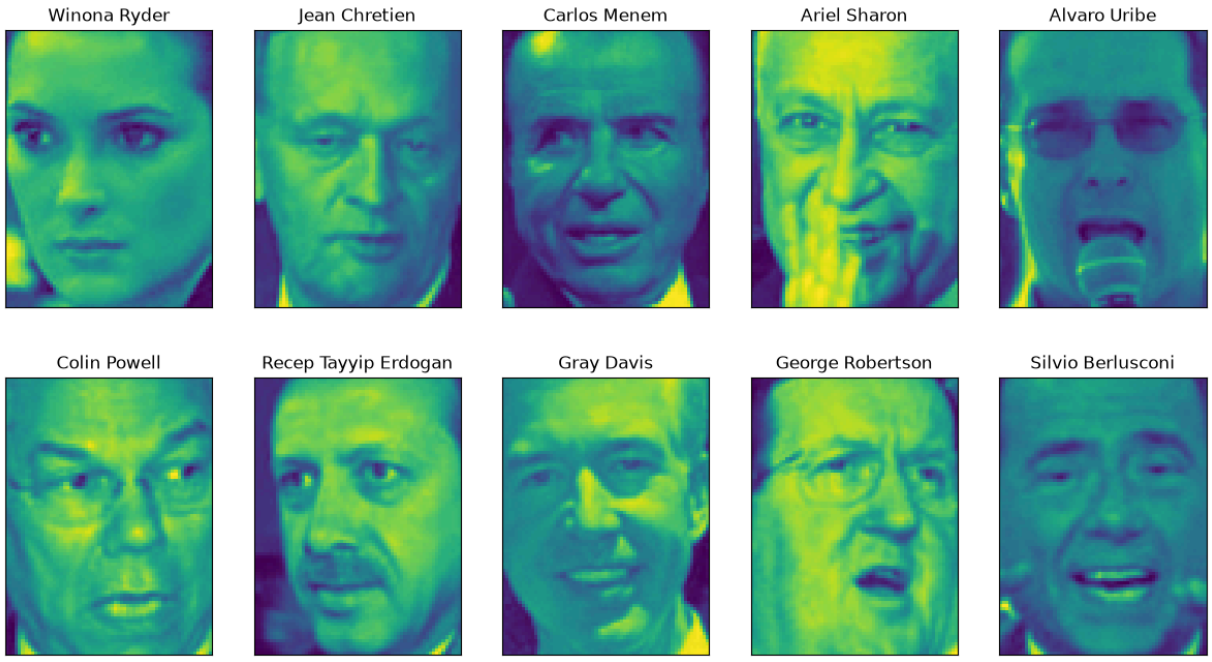
```
dict_keys(['data', 'images', 'target', 'target_names', 'DESCR'])
각 이미지당 장수  [ 39  35  21  36  20  77  42  24  29  21 236  31 121  22 530 1
09  44  26
  30  22  39  71  20  28  52  55  21  42  21  24  20  53  31  23  28  60
  32  41  22  41  48  29  33  20  22  37  20  22  30  27  32  26  23  52
  33  23  25  33 144  32  49  24]
이미지 행렬  (3023, 87, 65)
어떤 사람들인가?  ['Alejandro Toledo' 'Alvaro Uribe' 'Amelie Mauresmo' 'Andre Ag
assi'
 'Angelina Jolie' 'Ariel Sharon' 'Arnold Schwarzenegger'
 'Atal Bihari Vajpayee' 'Bill Clinton' 'Carlos Menem' 'Colin Powell'
 'David Beckham' 'Donald Rumsfeld' 'George Robertson' 'George W Bush'
 'Gerhard Schroeder' 'Gloria Macapagal Arroyo' 'Gray Davis'
 'Guillermo Coria' 'Hamid Karzai' 'Hans Blix' 'Hugo Chavez' 'Igor Ivanov'
 'Jack Straw' 'Jacques Chirac' 'Jean Chretien' 'Jennifer Aniston'
 'Jennifer Capriati' 'Jennifer Lopez' 'Jeremy Greenstock' 'Jiang Zemin'
 'John Ashcroft' 'John Negroponte' 'Jose Maria Aznar'
 'Juan Carlos Ferrero' 'Junichiro Koizumi' 'Kofi Annan' 'Laura Bush'
 'Lindsay Davenport' 'Lleyton Hewitt' 'Luiz Inacio Lula da Silva'
 'Mahmoud Abbas' 'Megawati Sukarnoputri' 'Michael Bloomberg' 'Naomi Watts'
 'Nestor Kirchner' 'Paul Bremer' 'Pete Sampras' 'Recep Tayyip Erdogan'
 'Ricardo Lagos' 'Roh Moo-hyun' 'Rudolph Giuliani' 'Saddam Hussein'
 'Serena Williams' 'Silvio Berlusconi' 'Tiger Woods' 'Tom Daschle'
 'Tom Ridge' 'Tony Blair' 'Vicente Fox' 'Vladimir Putin' 'Winona Ryder']
한장의 이미지 크기 :  (87, 65)
```

- 인터넷에 따라 약간의 시간이 소요됨.

얼굴 이미지 10개 확인해보기

In [5]:
```
fig, axes = plt.subplots(2, 5, figsize=(15,8),
                         subplot_kw= {'xticks':(), 'yticks':() })

for target, image, ax in zip(people.target, people.images, axes.ravel() ):
    ax.imshow(image) # 이미지 표시
    ax.set_title(people.target_names[target]) # 이미지별 이름
```



이미지 크기

In [6]:
```
print("이미지 크기:", people.images.shape)
print("클래스 개수:", len(people.target_names))
```

```
이미지 크기: (3023, 87, 65)
클래스 개수: 62
```

각 사람의 이미지는 몇장씩 있는가?

In [7]:
```
# 타깃 값의 각각의 데이터 개수
counts = np.bincount(people.target)
print( counts )
print("최소 : {}, 최대 : {}".format(np.min(counts), np.max(counts)))
```

```
[ 39  35  21  36  20  77  42  24  29  21 236  31 121  22 530 109  44  26
  30  22  39  71  20  28  52  55  21  42  21  24  20  53  31  23  28  60
  32  41  22  41  48  29  33  20  22  37  20  22  30  27  32  26  23  52
  33  23  25  33 144  32  49  24]
최소 : 20, 최대 : 530
```

In [8]:
```
people.target_names
```

Out[8]:
```
array(['Alejandro Toledo', 'Alvaro Uribe', 'Amelie Mauresmo',
       'Andre Agassi', 'Angelina Jolie', 'Ariel Sharon',
       'Arnold Schwarzenegger', 'Atal Bihari Vajpayee', 'Bill Clinton',
       'Carlos Menem', 'Colin Powell', 'David Beckham', 'Donald Rumsfeld',
       'George Robertson', 'George W Bush', 'Gerhard Schroeder',
       'Gloria Macapagal Arroyo', 'Gray Davis', 'Guillermo Coria',
       'Hamid Karzai', 'Hans Blix', 'Hugo Chavez', 'Igor Ivanov',
       'Jack Straw', 'Jacques Chirac', 'Jean Chretien',
       'Jennifer Aniston', 'Jennifer Capriati', 'Jennifer Lopez',
       'Jeremy Greenstock', 'Jiang Zemin', 'John Ashcroft',
       'John Negroponte', 'Jose Maria Aznar', 'Juan Carlos Ferrero',
       'Junichiro Koizumi', 'Kofi Annan', 'Laura Bush',
       'Lindsay Davenport', 'Lleyton Hewitt', 'Luiz Inacio Lula da Silva',
       'Mahmoud Abbas', 'Megawati Sukarnoputri', 'Michael Bloomberg',
       'Naomi Watts', 'Nestor Kirchner', 'Paul Bremer', 'Pete Sampras',
       'Recep Tayyip Erdogan', 'Ricardo Lagos', 'Roh Moo-hyun',
       'Rudolph Giuliani', 'Saddam Hussein', 'Serena Williams',
       'Silvio Berlusconi', 'Tiger Woods', 'Tom Daschle', 'Tom Ridge',
       'Tony Blair', 'Vicente Fox', 'Vladimir Putin', 'Winona Ryder'],
      dtype='<U25')
```

In [9]:
```
### 타깃(사람)의 이름과 각 사람별 데이터 개수 출력.
for i, (count, name) in enumerate( zip(counts, people.target_names) ):
    print("{0:25} {1:3}".format(name, count), end= '    ')
    if (i + 1) % 3 == 0:
        print()
```

```
Alejandro Toledo           39   Alvaro Uribe              35   Amelie Maure
smo            21
Andre Agassi               36   Angelina Jolie            20   Ariel Sharon
77
Arnold Schwarzenegger      42   Atal Bihari Vajpayee      24   Bill Clinton
29
Carlos Menem               21   Colin Powell             236   David Beckha
m              31
Donald Rumsfeld           121   George Robertson          22   George W Bus
h             530
Gerhard Schroeder         109   Gloria Macapagal Arroyo   44   Gray Davis
26
Guillermo Coria            30   Hamid Karzai              22   Hans Blix
39
Hugo Chavez                71   Igor Ivanov               20   Jack Straw
28
Jacques Chirac             52   Jean Chretien             55   Jennifer Ani
ston           21
Jennifer Capriati          42   Jennifer Lopez            21   Jeremy Green
stock          24
Jiang Zemin                20   John Ashcroft             53   John Negropo
nte            31
Jose Maria Aznar           23   Juan Carlos Ferrero       28   Junichiro Ko
izumi          60
Kofi Annan                 32   Laura Bush                41   Lindsay Dave
nport          22
Lleyton Hewitt             41   Luiz Inacio Lula da Silva 48   Mahmoud Abba
s              29
Megawati Sukarnoputri      33   Michael Bloomberg         20   Naomi Watts
22
Nestor Kirchner            37   Paul Bremer               20   Pete Sampras
22
Recep Tayyip Erdogan       30   Ricardo Lagos             27   Roh Moo-hyun
32
Rudolph Giuliani           26   Saddam Hussein            23   Serena Willi
ams            52
Silvio Berlusconi          33   Tiger Woods               23   Tom Daschle
25
Tom Ridge                  33   Tony Blair               144   Vicente Fox
32
Vladimir Putin             49   Winona Ryder              24
```

In [10]:

```python
### 타깃(사람)의 이름과 각 사람별 데이터 개수 출력.(2사람, 1줄에)
for i, (count, name) in enumerate(zip(counts, people.target_names)):
    print("{0:5}, {1:25}".format(count, name), end="   ")
    if (i + 1) % 2 == 0:
        print()
```

```
 39, Alejandro Toledo                35, Alvaro Uribe
 21, Amelie Mauresmo                 36, Andre Agassi
 20, Angelina Jolie                  77, Ariel Sharon
 42, Arnold Schwarzenegger           24, Atal Bihari Vajpayee
 29, Bill Clinton                    21, Carlos Menem
236, Colin Powell                    31, David Beckham
121, Donald Rumsfeld                 22, George Robertson
530, George W Bush                  109, Gerhard Schroeder
 44, Gloria Macapagal Arroyo         26, Gray Davis
 30, Guillermo Coria                 22, Hamid Karzai
 39, Hans Blix                       71, Hugo Chavez
 20, Igor Ivanov                     28, Jack Straw
 52, Jacques Chirac                  55, Jean Chretien
 21, Jennifer Aniston                42, Jennifer Capriati
 21, Jennifer Lopez                  24, Jeremy Greenstock
 20, Jiang Zemin                     53, John Ashcroft
 31, John Negroponte                 23, Jose Maria Aznar
 28, Juan Carlos Ferrero             60, Junichiro Koizumi
 32, Kofi Annan                      41, Laura Bush
 22, Lindsay Davenport               41, Lleyton Hewitt
 48, Luiz Inacio Lula da Silva       29, Mahmoud Abbas
 33, Megawati Sukarnoputri           20, Michael Bloomberg
 22, Naomi Watts                     37, Nestor Kirchner
 20, Paul Bremer                     22, Pete Sampras
 30, Recep Tayyip Erdogan            27, Ricardo Lagos
 32, Roh Moo-hyun                    26, Rudolph Giuliani
 23, Saddam Hussein                  52, Serena Williams
 33, Silvio Berlusconi               23, Tiger Woods
 25, Tom Daschle                     33, Tom Ridge
144, Tony Blair                      32, Vicente Fox
 49, Vladimir Putin                  24, Winona Ryder
```

- George W Bush 등의 이미지는 많기 때문에 이 데이터를 그대로 이용하며 편중이 생길 수 있어,
- 사람마다 이미지의 개수가 차이가 있어,데이터가 편중되는 것을 막기 위해 각 사람당 50개 이미지만 추출

한 사람당 최대 50개씩 데이터를 추출하기 위해..

- 전체 이미지수에 False로 매핑
- 각 사람의 순서대로 50개씩, True로 값을 지정.

In [11]:
```
people.target.shape
```

Out[11]:
```
(3023,)
```

In [12]:
```
nums = people.target.shape  # 얼굴 이미지 사람(숫자).
mask = np.zeros(nums, dtype=np.bool)
mask
```

Out[12]:
```
array([False, False, False, ..., False, False, False], shape=(3023,))
```

In [13]:
```
# 중복값을 제외한 값을 표시
np.unique(people.target)
```

Out[13]:
```
array([ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13, 14, 15, 16,
       17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32, 33,
       34, 35, 36, 37, 38, 39, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49, 50,
       51, 52, 53, 54, 55, 56, 57, 58, 59, 60, 61])
```

In [14]:
```
# 각 사람별 50명씩 선택
nums = np.unique(people.target)

for target in nums:
    mask[np.where(people.target==target)[0][:50]] = 1 # 각 사람별 50장 선택

# 전체 데이터의 1로 되어 있는 것을 가져오기
X_people = people.data[mask]
y_people = people.target[mask]

# 0 ~ 255 사이의 흑백 이미지의 픽셀 값을 0~1 스케일로 조정.
# (옮긴이) MinMaxScaler를 적용하는 것과 거의 같습니다.
X_people = X_people / 255.
print(X_people.shape)
```

```
(2063, 5655)
```

03. 모델 구축하기

목차로 이동하기

주어진 데이터를 이용해서 지도학습 모델에 적용시켜보자.

- 분류하려는 얼굴과 가장 비슷한 얼굴 이미지를 찾으려는 1-최근접 이웃 분류기

In [15]:
```
from sklearn.neighbors import KNeighborsClassifier
X_train, X_test, y_train, y_test = train_test_split(
        X_people, y_people, stratify=y_people, random_state=0)

# 이웃 개수를 한 개로 하여 KNeightborsClassifier 모델을 만든다.
knn = KNeighborsClassifier(n_neighbors=1)
knn.fit(X_train, y_train)
print("1-최근접 이웃의 테스트 세트 점수:{:.2f}".format(knn.score(X_test, y_test)))
```

```
1-최근접 이웃의 테스트 세트 점수:0.22
```

- 클래스 62개를 분류하는 문제에서 나쁜 결과는 아니지만, 그렇다고 좋은 결과도 아님

PCA를 이용해서 87 x 65(=5655)의 특징을 갖는 성분을 100개의 주성분으로 추출.

In [16]:
```
from sklearn.decomposition import PCA
```

In [17]:
```
# 화이트닝 옵션은 PCA변환을 할 때 이 표준편차를 나누어 적용.
# PCA 변환은 데이터의 평균을 0으로 만들어주므로
# 화이트닝을 적용하는 것은 PCA변환한 뒤에 StandardScaler를 적용하는 것과 같다.
pca = PCA(n_components=100, whiten=True, random_state=0).fit(X_train)
X_train_pca = pca.transform(X_train)
X_test_pca = pca.transform(X_test)

print("X_train_pca.shape:", X_train_pca.shape)
print("X_test_pca.shape:", X_test_pca.shape)
```

```
X_train_pca.shape: (1547, 100)
X_test_pca.shape: (516, 100)
```

- 새로운 데이터는 처음 100개의 주성분에 해당되는 특성을 가짐.
- 이 데이터를 사용하여 1-최근접 이웃 분류기로 이미지를 분류

In [18]:
```
knn = KNeighborsClassifier(n_neighbors=1)
knn.fit(X_train_pca, y_train)

print("테스트 정확도 : {:.2f}".format(knn.score(X_test_pca, y_test)))
```

```
테스트 정확도 : 0.30
```

- 모델의 정확도가 23%에서 31%로 향상

주성분 이미지 확인

- 주성분이 나타내는 것은 입력 데이터 공간에서의 어떤 방향이다.
- 입력 차원은 87 x 65 = 5655

한글 보이도록 설정

In [19]:
```
# 한글 폰트 설정 (코랩·윈도우·맥 공통)  # 2026.10 수정: 윈도우 폰트 경로 하드코딩 대신 공통 설
%pip install -q koreanize-matplotlib setuptools
import setuptools  # 2026.10 수정: Python 3.12+엔 distutils가 없어 koreanize-ma
import koreanize_matplotlib  # 나눔고딕을 matplotlib 기본 폰트로 등록
```

각각의 주성분 그래프로 확인해 보기

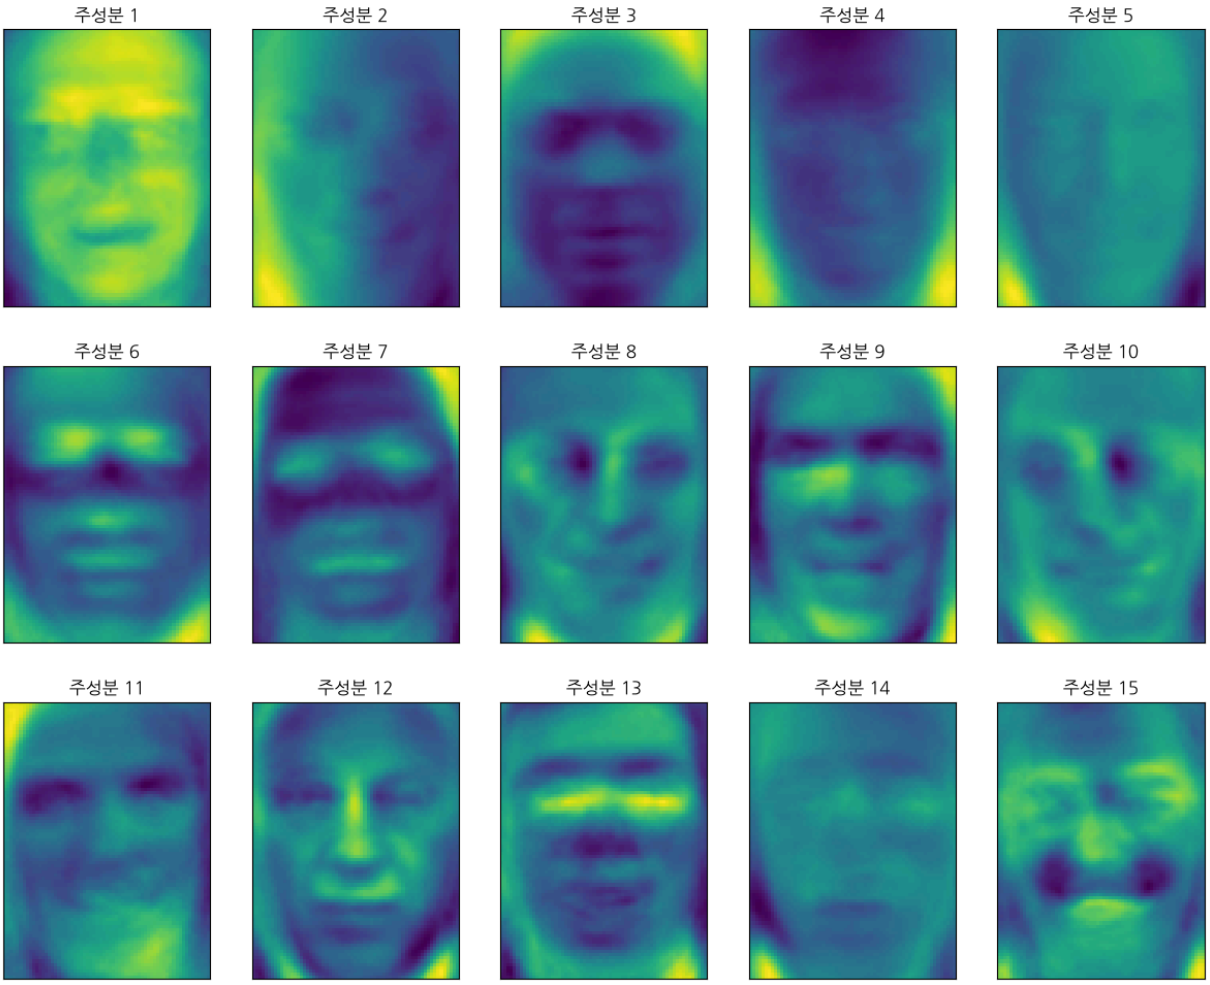
In [20]:
```
image_shape = people.images[0].shape   # 2026.10 수정: 아래쪽 셀에서야 만들던 image
print("pca.components_.shape ", pca.components_.shape)

fig, axes = plt.subplots(3, 5, figsize=(15,12),
                         subplot_kw={'xticks':(), 'yticks':() })

for i, (component, ax) in enumerate(zip(pca.components_, axes.ravel())):
```

```
    ax.imshow(component.reshape(image_shape), cmap="viridis")
    ax.set_title("주성분 {}".format((i+1)))
```

```
pca.components_.shape  (100, 5655)
```

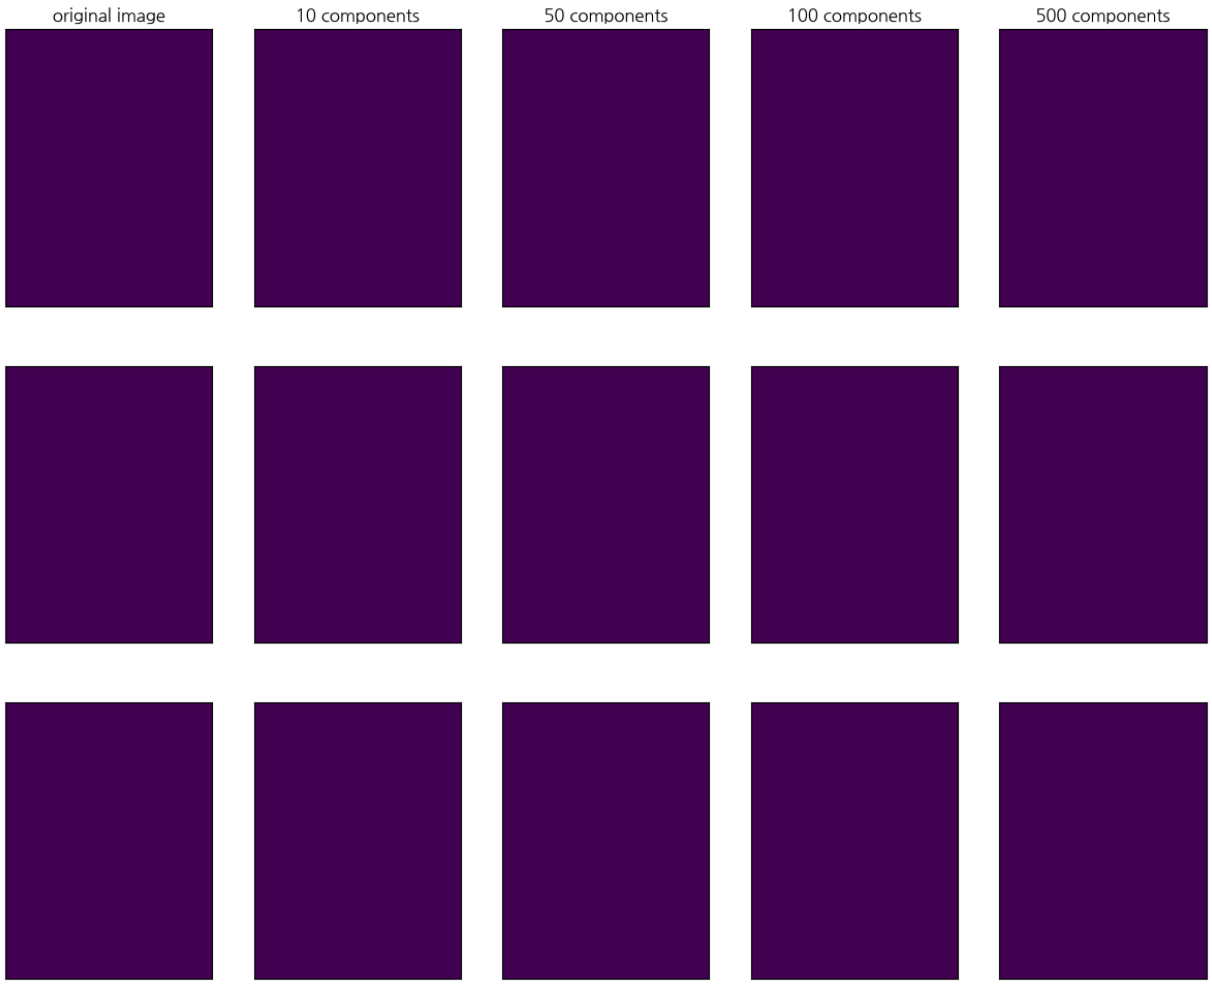


- 이 주성분을 전부 이해할 수 없다.
  - 첫번째 주성분은 **얼굴과 배경의 명암 차이**를 기록한 것.
  - 두번째 주성분은 오른쪽과 왼쪽 조명의 차이를 담고 있는 것.
- PCA 모델은 픽셀을 기반으로 하므로 얼굴의 배치와 조명이 두 이미지에 얼마나 비슷한지 판단하는 데 큰 영향을 준다.

주성분의 일부를 사용하여 이미지 재구성

- 몇 개의 주성분으로 데이터를 줄이고 원래 공간으로 되돌릴 수 있음.

In [21]:
```
mglearn.plots.plot_pca_faces(X_train, X_test, image_shape)
```



- 주성분을 10개만 사용했을 땐, 얼굴의 각도, 조명 같은 이미지의 기본 요소만 나타남.
- 주성분이 더 많이 사용되면 될 수록 이미지가 더욱 상세해짐.

In [22]:
```
from matplotlib.offsetbox import OffsetImage, AnnotationBbox

image_shape = people.images[0].shape
plt.figure(figsize=(20, 3))
ax = plt.gca()

imagebox = OffsetImage(people.images[0], zoom=2, cmap="gray")
ab = AnnotationBbox(imagebox, (.05, 0.4), pad=0.0, xycoords='data')
ax.add_artist(ab)

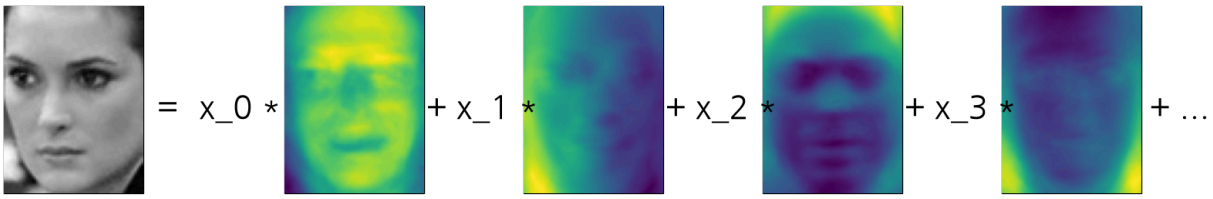
for i in range(4):
    imagebox = OffsetImage(pca.components_[i].reshape(image_shape), zoom=2,
                           cmap="viridis")

    ab = AnnotationBbox(imagebox, (.285 + .2 * i, 0.4),
                        pad=0.0, xycoords='data')
    ax.add_artist(ab)
    if i == 0:
        plt.text(.155, .3, 'x_{} *'.format(i), fontdict={'fontsize': 30})
    else:
        plt.text(.145 + .2 * i, .3, '+ x_{} *'.format(i),
```

```
                  fontdict={'fontsize': 30})

plt.text(.95, .3, '+ ...', fontdict={'fontsize': 30})

plt.rc('text')
plt.text(.12, .3, '=', fontdict={'fontsize': 30})
plt.axis("off")
plt.show()
plt.close()
plt.rc('text')
```



그외.

- NMF 알고리즘
  - 유용한 특성을 뽑기 위한 또 다른 비지도 학습 알고리즘
  - PCA와 비슷하고 차원 축소에도 사용이 가능합니다.

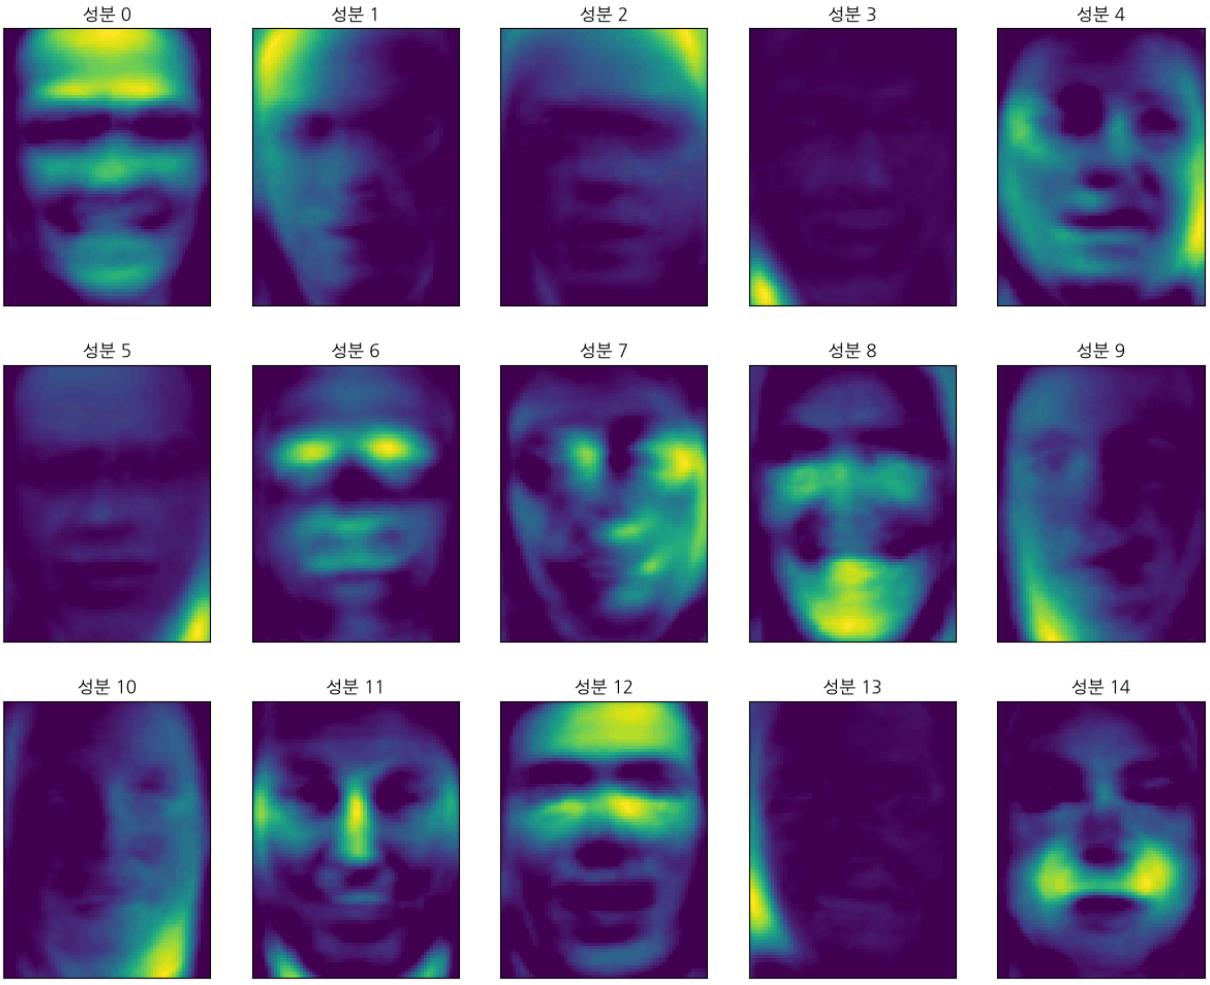
- PCA에서는 데이터의 분산이 크고, 수직인 성분을 찾았다면,
  - NMF는 음수가 아닌 성분과 계수 값을 찾는다.
- NMF에서는 차원 감소 기법이다.
- NMF(Non-negative Matrix Factorization) - 비음수 행렬 분해
  - **NMF는 하나의 객체 정보를 행렬 V가 보통 두 개의 음수를 포함하지 않는 행렬 W와 H로 분해**하여 의미 있는 특징을 추출하는 기법.
  - NMF의 목적은 **공통 특징만을 가지고 정보를 줄이는 것**이다.
  - NMF는 행렬 인수 분해 알고리즘 중의 하나이다.
  - 컴퓨터 시각 처리나 문서 분류, 음파 분석 등에 널리 사용된다.
  - 새로운 특징 셋이 어떻게 원본 데이터와 관계를 가지는지 확인이 가능하다.
  - 즉 주성분과 계수가 모두 0보다 크거나 같아야 함.
  - 음수가 아닌 주성분과 계수의 가중치 합은 음수가 되지 않으므로 당연하게 이 방식은 음수가 아닌 특성을 가진 데이터에만 적용 가능
- 이 기능은 여러 사람의 목소리가 담긴 오디오 트랙이나 여러 악기로 이뤄진 음악처럼 독립된 소스를 추가하여 만들어진 데이터에 특히 유용합니다.

In [23]:
```
from sklearn.decomposition import NMF
nmf = NMF(n_components=15, random_state=0)
nmf.fit(X_train)
```

```
X_train_nmf = nmf.transform(X_train)
X_test_nmf = nmf.transform(X_test)

fig, axes = plt.subplots(3, 5, figsize=(15, 12),
                         subplot_kw={'xticks': (), 'yticks': ()})
for i, (component, ax) in enumerate(zip(nmf.components_, axes.ravel())):
    ax.imshow(component.reshape(image_shape))
    ax.set_title("성분 {}".format(i))
```

```
.../site-packages/sklearn/decomposition/_nmf.py:1723: ConvergenceWarning: Ma
ximum number of iterations 200 reached. Increase it to improve convergence.
  warnings.warn(
```

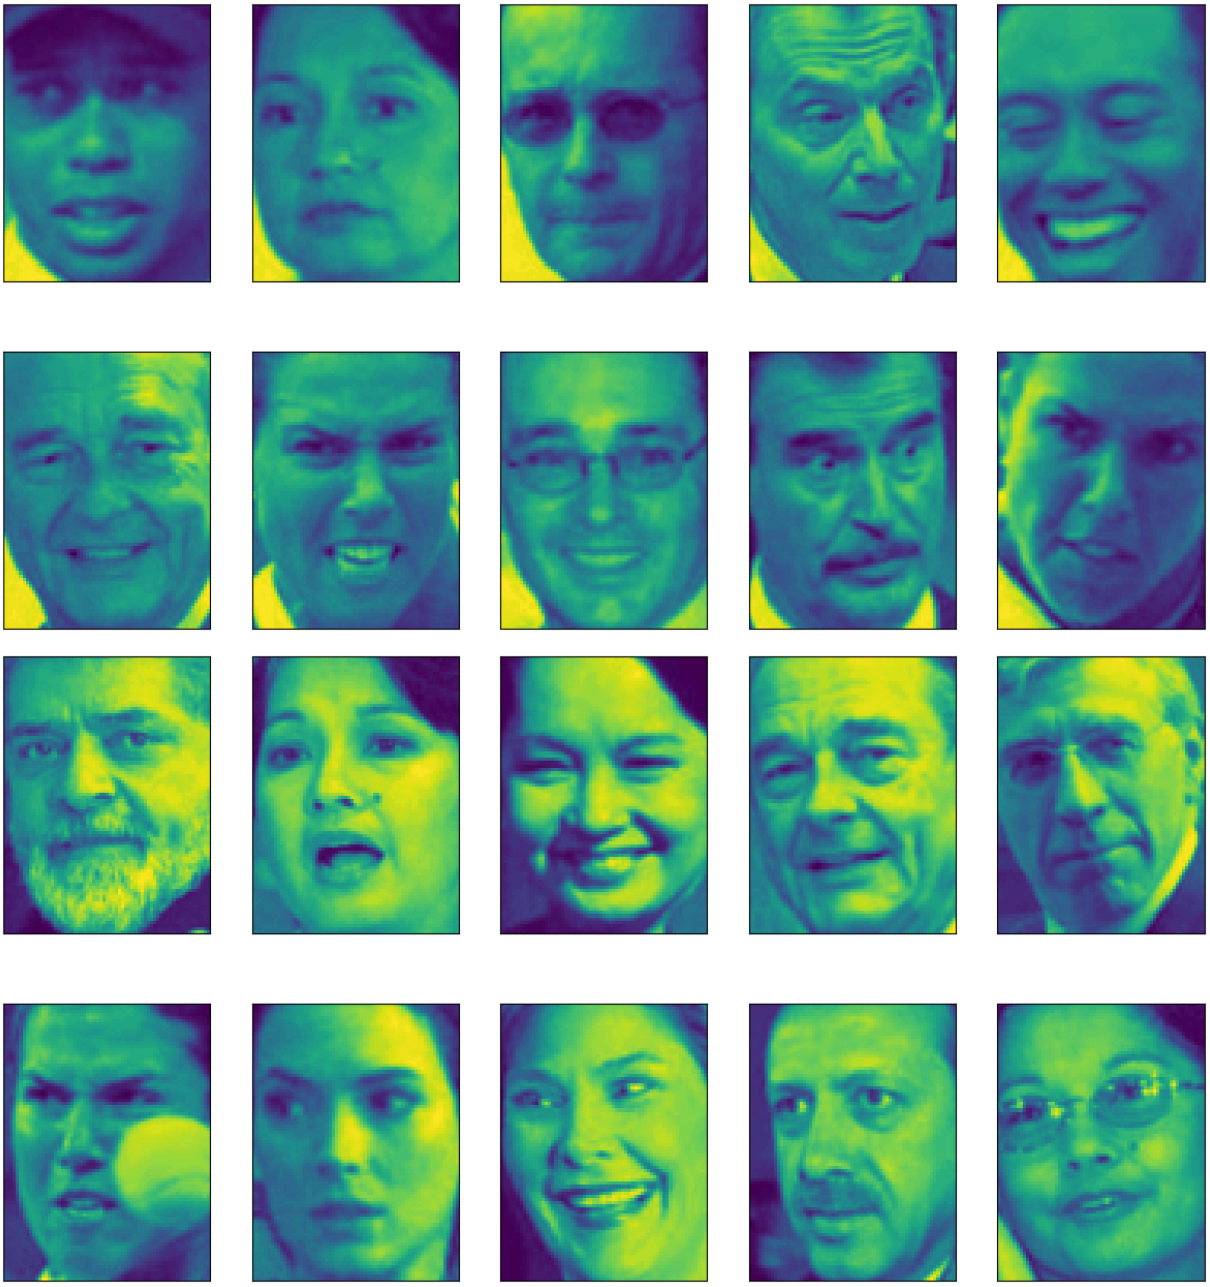


- NMF보다 PCA사용시에 품질이 좋다.
- NMF는 데이터 인코딩과 재구성보다 데이터의 패턴을 찾는데 활용

In [24]:
```
compn = 3
# 4번째 성분으로 정렬하여 처음 10개 이미지를 출력합니다
inds = np.argsort(X_train_nmf[:, compn])[::-1]
fig, axes = plt.subplots(2, 5, figsize=(15, 8),
                         subplot_kw={'xticks': (), 'yticks': ()})
for i, (ind, ax) in enumerate(zip(inds, axes.ravel())):
    ax.imshow(X_train[ind].reshape(image_shape))

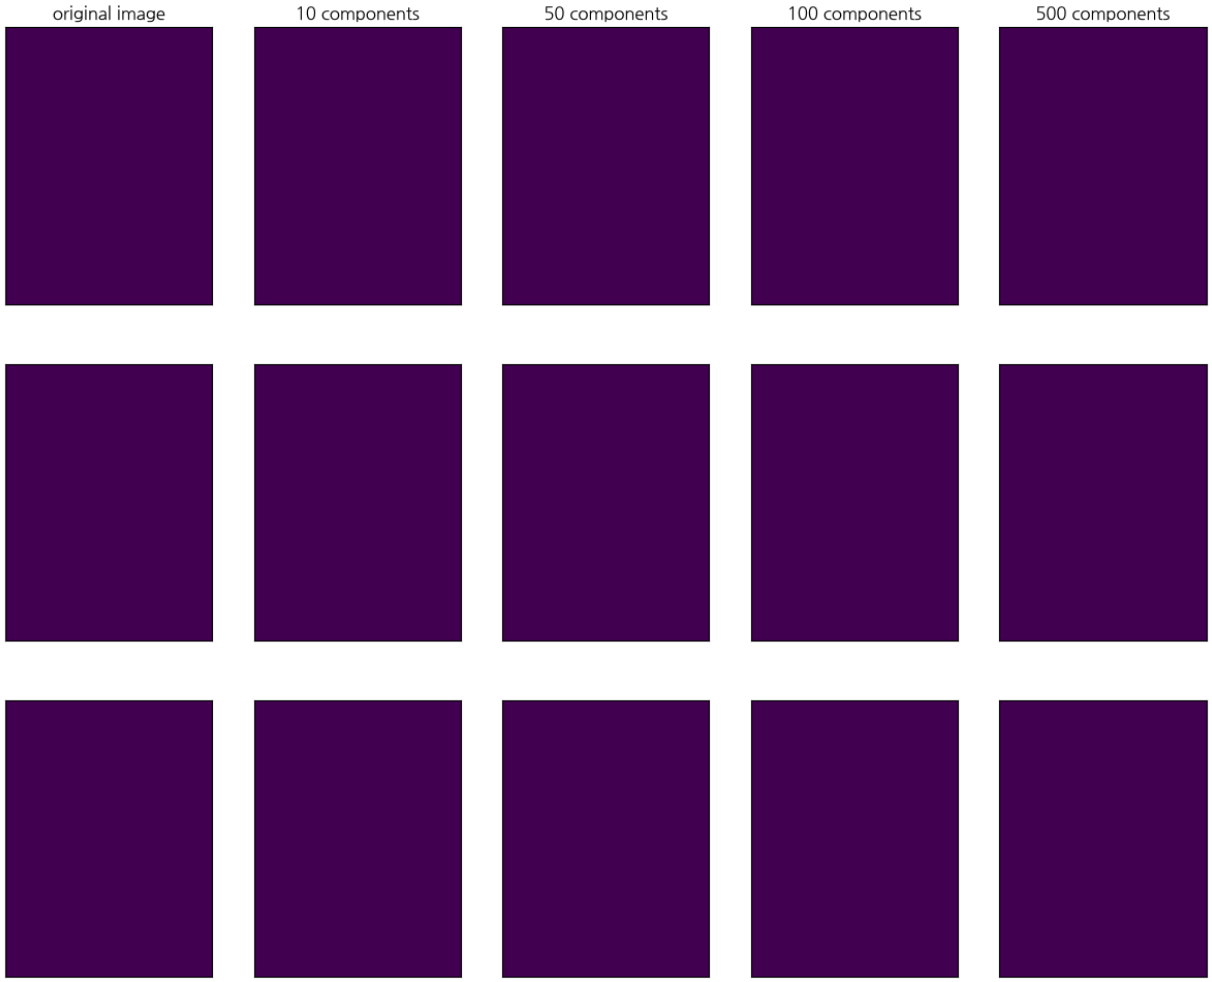
compn = 7
```

```
# 8번째 성분으로 정렬하여 처음 10개 이미지를 출력합니다
inds = np.argsort(X_train_nmf[:, compn])[::-1]
fig, axes = plt.subplots(2, 5, figsize=(15, 8),
                         subplot_kw={'xticks': (), 'yticks': ()})
for i, (ind, ax) in enumerate(zip(inds, axes.ravel())):
    ax.imshow(X_train[ind].reshape(image_shape))
```



- 성분 3은 오른쪽으로 얼굴이 돌아감.
- 성분 7은 왼쪽으로 얼굴이 돌아감.

In [25]:
```
mglearn.plots.plot_nmf_faces(X_train, X_test, image_shape)
```


original image
10 components
50 components
100 components
500 components