평가지표와 이를 활용한 그래프

학습 내용

- 정밀도 재현율을 구하는 함수를 알아본다.
- Tprate, Fprate를 구하는 함수를 알아본다.
- 정밀도, 재현율 그래프를 확인해 본다.
- Tprate, Fprate의 그래프를 확인해 본다.(ROC 커브)
- ROC커브를 구하고 AUC에 대해 이해해본다.

한글 사전 설정

```
In [20]: | ### 한글
         import matplotlib
         from matplotlib import font_manager, rc
         font_loc = "C:/Windows/Fonts/malgunbd.ttf"
         font_name = font_manager.FontProperties(fname=font_loc).get_name()
         matplotlib.rc('font', family=font_name)
```

정밀도 재현율 곡선을 이용하여 성능을 판단해 보기

```
from sklearn.svm import SVC
 from sklearn.model_selection import train_test_split
 import matplotlib.pyplot as plt
 import numpy as np
```

정밀도(x)와 재현율(y) - ROC 커브 확인해 보기

• precision recall curve() 메서드 이용

```
In [22]: from mglearn.datasets import make_blobs
          X, y = make\_blobs(n\_samples=(400, 50),
                            centers=2, cluster_std=[7.0, 2],
                            random_state=22)
          print(X.shape, y.shape)
```

(450, 2) (450,)

C:\Users\front\angleanaconda3\lib\site-packages\sklearn\utils\deprecation.py:86: Future\arn ing: Function make_blobs is deprecated; Please import make_blobs directly from scikit-

warnings.warn(msg, category=FutureWarning)

```
X_train, X_test, y_train, y_test = train_test_split(X, y,
                                                     random_state=0)
 svc = SVC(gamma=.05).fit(X_train, y_train)
```

```
In [24]:
        pred = svc.predict(X_test)
         from sklearn.metrics import classification_report
         print(classification_report(y_test, pred))
```

	precision	recall	f1-score	support
0	0.97 0.35	0.89 0.67	0.93 0.46	104 9
accuracy macro avg	0.66	0.78	0.88 0.70	113 113

weighted avg

0.92

0.88

0.89

113

정밀도 재현율 곡선 확인

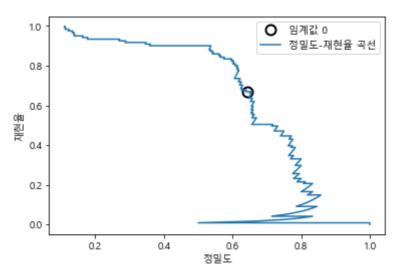
```
from sklearn.metrics import precision_recall_curve
          precision, recall, thresholds = precision_recall_curve(
                                       y_test, svc.decision_function(X_test))
          # 부드러운 곡선을 위해 데이터 포인트 수를 늘립니다
          X, y = \text{make\_blobs}(n_\text{samples} = (4000, 500),
                             centers=2,
                             cluster_std=[7.0, 2],
                             random_state=22)
          print(X.shape, y.shape)
          X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=0)
          (4500. 2) (4500.)
         C:\Users\front\angleanaconda3\lib\site-packages\sklearn\utils\deprecation.py:86: Future\arn
          ing: Function make_blobs is deprecated; Please import make_blobs directly from scikit-
          learn
           warnings.warn(msg, category=FutureWarning)
          plt.scatter(X[:,0], X[:,1],
                       C = y,
                       cmap=plt.cm.autumn, s=60, edgecolors='k') # plt.cm.Blues, RdYIGn, BrBG,
Out[27]: <matplotlib.collections.PathCollection at 0x2094211de50>
         C:\Users\front\anaconda3\lib\site-packages\matplotlib\backends\backend_agg.py:238: Run
         timeWarning: Glyph 8722 missing from current font.
            font.set_text(s, 0.0, flags=flags)
         C:\Users\front\anaconda3\lib\site-packages\matplotlib\backends\backend_agg.py:201: Run
          timeWarning: Glyph 8722 missing from current font.
            font.set_text(s, 0, flags=flags)
           20
           10
           0
          □10
          I20
                       πż0
                                □10
              П30
                                                   10
                                          0
                                                            20
          svc = SVC(gamma=.05).fit(X_train, y_train)
```

```
pred = svc.decision_function(X_test) # 0의 값을 기준으로 분포
print(pred[0:10])
[-1.12256809 0.86782231 -0.14655591 -1.11330437 -1.11378355 -1.14388862
-0.89066641 -0.99969575 -1.21851181 -1.25254411
precision, recall, thresholds = precision_recall_curve(
                                           v_test, pred)
```

```
# 0에 가까운 임계값을 찾습니다
close_zero = np.argmin(np.abs(thresholds))
print(close_zero)
plt.plot(precision[close_zero],
        recall[close_zero], 'o',
        markersize=10.
        label="임계값 0"
        fillstyle="none", c='k', mew=2)
plt.plot(precision, recall, label="정밀도-재현율 곡선")
plt.xlabel("정밀도")
plt.ylabel("재현율")
plt.legend(loc="best")
```

964

<matplotlib.legend.Legend at 0x20942191b80>



- 재현율(recall, sensitivity-민감도, Tprate)
 - 실제 양성 데이터를 양성으로 잘 예측
 - TP/(TP + FN)
- FPRate
 - 실제 음성(0) 데이터를 음성으로 잘 예측
 - 1-특이도(TN/(FP + TN))
 - FP/(FP + TN)

정밀도

\begin{equation} \text{정밀도(precision)} = \frac{\text{잘 예측(TP)}}{ \text{예측을 양성으로 한 것 전체(TP+FP) } } \end{equation}

재현율(recall, 민감도, TPR)

\begin{equation} \text{민감도(recall, 재현율)} = \frac{\text{잘 예측(TP)}}{ \text{실제 값이 양성인 것 전체(TP+FN) } \end{equation}

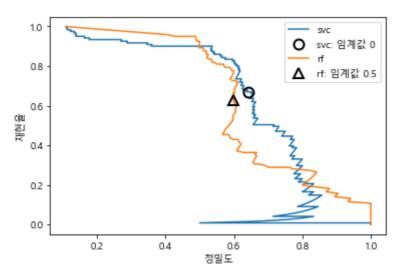
랜덤 포레스트를 이용한 정밀도-재현율의 커브

```
from sklearn.ensemble import RandomForestClassifier
In [30]:
          rf = RandomForestClassifier(n_estimators=100, random_state=0, max_features=2)
          rf.fit(X_train, y_train)
```

```
pred = rf.predict_proba(X_test)[:, 1]
         pred
Out[30]: array([0., 0.35, 0.7, ..., 0., 0., 0.])
         # RandomForestClassifier는 decision_function 대신 predict_proba를 제공합니다.
         precision_rf, recall_rf, thresholds_rf = precision_recall_curve(
                                                 y_test, pred)
         # SVC모델 그래프
         plt.plot(precision, recall, label="svc")
         plt.plot(precision[close_zero],
                  recall[close_zero], 'o',
                  markersize=10,
                  label="svc: 임계값 0",
                  fillstyle="none",
                  c = 'k',
                  mew=2)
         # 랜덤포레스트 그래프
         plt.plot(precision_rf, recall_rf, label="rf")
         close_default_rf = np.argmin( np.abs(thresholds_rf - 0.5) )
         print(close_default_rf)
         plt.plot(precision_rf[close_default_rf], recall_rf[close_default_rf], '^', c='k',
                  markersize=10, label="rf: 임계값 0.5", fillstyle="none", mew=2)
         plt.xlabel("정밀도")
```

<matplotlib.legend.Legend at 0x20942211490>

plt.ylabel("재현율") plt.legend(loc="best")



- 극단적인 부분, 재현율이 매우 높거나, 정밀도가 매우 높을 때는 랜덤포레스트가 더 낫다.
- 정밀도 0.7부분에서는 SVC가 좋음

```
from sklearn.metrics import f1_score
In [32]:
         rf_f1score = f1_score(y_test, rf.predict(X_test) )
         svc_f1score = f1_score(y_test, svc.predict(X_test))
         print("랜덤 포레스트의 f1_score: {:.3f}".format(rf_f1score))
         print("svc의 f1_score: {:.3f}".format(svc_f1score))
```

랜덤 포레스트의 f1_score: 0.610

svc의 f1_score: 0.656

```
from sklearn.metrics import average_precision_score
## 확률 예측
rf_pro = rf.predict_proba(X_test)[:, 1]
svc_dcfun = svc.decision_function(X_test)
ap_rf = average_precision_score(y_test, rf_pro)
ap_svc = average_precision_score(y_test, svc_dcfun)
print("랜덤 포레스트의 평균 정밀도: {:.3f}".format(ap_rf))
print("svc의 평균 정밀도: {:.3f}".format(ap_svc))
```

랜덤 포레스트의 평균 정밀도: 0.660 svc의 평균 정밀도: 0.666

ROC 곡선

- ROC 곡선은 여러 임계값에서 분류기의 특성을 분석하는데 널리 사용되는 도구.
- ROC 곡선은 분류기의 모든 임계값을 고려
- 앞의 그래프의 x는 정밀도, y가 재현율(TPR)이었다면
 - ROC곡선은 x는 (False Positive rate), y를 재현율을(True Positive rate)로 한것.

ROC 와 AUC

- y축은 Tprate(재현율, 민감도), x축은 Fprate라고 한다.
- FPrate는 1-특이도와 같다
- FPrate는 실제 음성인 데이터 중에 양성으로 예측하여 틀린 것의 비율

\begin{equation} \text{FPRate} = \frac{\text{틀린 예측(FP)}}{ \text{실제 값이 음성인것 전체(FP + TN) } \end{equation}

```
from sklearn.metrics import roc_curve
In [34]:
         fpr, tpr, thresholds = roc_curve(y_test, svc.decision_function(X_test))
```

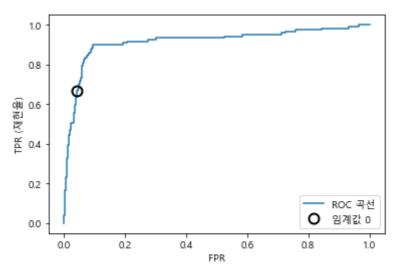
임계값에 따른 각각의 Fprate, Tprate를 구하기

```
In [35]: fpr.shape, tpr.shape, thresholds
Out[35]: ((121,),
          (121,)
          array([ 2.4675732 , 1.4675732 , 1.44543522, 1.3883083 , 1.36399692,
                  1.32045274, 1.30793345, 1.27362292, 1.26639366, 1.26549139,
                  1.26218681, 1.23639476, 1.23272763, 1.23268814, 1.21274253,
                  1.18867389, 1.17585471, 1.15089351, 1.14644476, 1.11697474,
                  1.11164916, 1.07039562, 1.0618427, 1.02737422, 1.0221831
                  0.92622847, 0.92061278, 0.91871812, 0.91025922, 0.82556742,
                  0.80058895, 0.78826384, 0.76431489, 0.73658061, 0.70361806,
                  0.63202742, 0.61868639, 0.58699872, 0.47424583, 0.43174875,
                  0.42161182, 0.41674789, 0.41170002, 0.41068324, 0.40404247,
                  0.39698761, 0.37952465, 0.37283557, 0.36963527, 0.23779958,
                  0.210375 , 0.19734035, 0.16642743, 0.08952996, 0.06954494,
                  0.0431748 , -0.04779208 , -0.06239381 , -0.08749885 , -0.09744136 ,
                 -0.11308646, -0.13793376, -0.14655591, -0.16681464, -0.23766011,
                 -0.26421748, -0.28671312, -0.35207398, -0.35960512, -0.36357768,
                 -0.38686615, -0.42239029, -0.43253037, -0.44822521, -0.50217567,
                 -0.50567587, \; -0.5180301 \;\; , \; -0.5297265 \;\; , \; -0.53771063, \; -0.54150651,
                 -0.58261387, -0.60168198, -0.64087279, -0.66798219, -0.72601863,
                 -0.74522837, -0.76985051, -0.7837385, -0.89066641, -0.90555299,
                 -0.91428783, -0.92168496, -0.94995579, -0.96549528, -0.96757492,
                 -0.97822999, -1.02946706, -1.02966988, -1.03764999, -1.03768168,
                 -1.08420087, -1.08576068, -1.1047158, -1.10500358, -1.12097238,
```

```
-1.12114269, -1.13095237, -1.13145208, -1.16822306, -1.16860214,
-1.17301962, -1.17324742, -1.19024128, -1.19055089, -1.22841838,
-1.2288246 , -1.28439408, -1.28869488, -1.41801331, -1.42644669,
-1.95625342]))
```

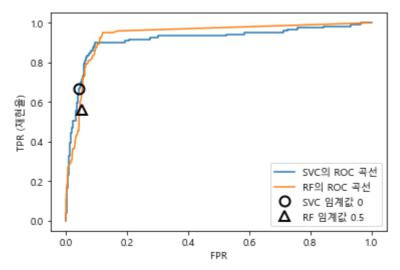
```
plt.plot(fpr, tpr, label="ROC 곡선")
plt.xlabel("FPR")
plt.ylabel("TPR (재현율)")
# 임계값이 0 근처의 임계값을 찾습니다
close_zero = np.argmin(np.abs(thresholds))
plt.plot(fpr[close_zero], tpr[close_zero], 'o', markersize=10,
        label="임계값 0", fillstyle="none", c='k', mew=2)
plt.legend(loc=4)
```

Out[36]: <matplotlib.legend.Legend at 0x2094224dbe0>



```
from sklearn.metrics import roc_curve
fpr_rf, tpr_rf, thresholds_rf = roc_curve(y_test, rf.predict_proba(X_test)[:, 1])
plt.plot(fpr, tpr, label="SVC의 ROC 곡선")
plt.plot(fpr_rf, tpr_rf, label="RF의 ROC 곡선")
plt.xlabel("FPR")
plt.ylabel("TPR (재현율)")
plt.plot(fpr[close_zero], tpr[close_zero], 'o', markersize=10,
         label="SVC 임계값 0", fillstyle="none", c='k', mew=2)
close_default_rf = np.argmin(np.abs(thresholds_rf - 0.5))
plt.plot(fpr_rf[close_default_rf], tpr[close_default_rf], '^', markersize=10,
         label="RF 임계값 0.5", fillstyle="none", c='k', mew=2)
plt.legend(loc=4)
```

Out[37]: <matplotlib.legend.Legend at 0x209420313a0>



```
from sklearn.metrics import roc_auc_score
rf_auc = roc_auc_score(y_test, rf.predict_proba(X_test)[:, 1])
svc_auc = roc_auc_score(y_test, svc.decision_function(X_test))
print("랜덤 포레스트의 AUC: {:.3f}".format(rf_auc))
print("SVC의 AUC: {:.3f}".format(svc_auc))
```

랜덤 포레스트의 AUC: 0.937 SVC의 AUC: 0.916

REF

plt.cm.___: https://chrisalbon.com/python/basics/set_the_color_of_a_matplotlib/