MACHINE LEARNING BASICS · CHAPTER 01-02

머신러닝(Machine Learning) 기본 파이썬과 첫 모델 만들기

문제 이해 · 파이썬 라이브러리 · 데이터 나누기 · 첫 모델

v14 · 2026.10

ⓒ 2026. DJ all rights reserved.

목 차

01 **머신러닝 문제와 데이터 이해**
먼저 확인할 여섯 가지 질문

02 **왜 파이썬인가?**
범용 언어 · 라이브러리 · 대화형 실행

03 **파이썬 기본 라이브러리**
pandas · NumPy · 시각화 · scikit-learn

04 **붓꽃(Iris) 데이터셋**
샘플 · 특성 · 레이블 · 클래스

05 **학습 데이터와 테스트 데이터**
나누는 이유와 전체 흐름

06 **첫 머신러닝 모델 만들기**
scikit-learn 코드 5단계

07 **데이터에 대해 가장 먼저 할 일**
문제 확인 · 결측치·이상치 · 시각화

\+ **정리**
한 장으로 보는 머신러닝 기본

ⓒ 2026. DJ all rights reserved.

01

머신러닝 문제와 데이터 이해

모델보다 먼저, 데이터와 풀어야 할 과제를 이해한다

01 머신러닝 문제와 데이터 이해하기

머신러닝에서 가장 중요한 과정: 데이터와 풀어야 할 과제를 먼저 이해하기

A

원하는 답

어떤 질문에 답하고 싶은가? 가진 데이터로 그 답을 얻을 수 있는가?

B

문제 정의

내 질문을 머신러닝 문제(분류·회귀 등)로 어떻게 표현할까?

C

데이터의 양

문제를 풀기에 충분한 데이터를 모았는가?

D

특성

어떤 특성을 쓰며, 그 특성으로 좋은 예측을 할 수 있는가?

E

성과 측정

만든 모델의 성과를 무엇으로, 어떻게 측정할 것인가?

F

활용과 연결

만든 모델을 다른 시스템이나 제품과 어떻게 연결할 것인가?

ⓒ 2026. DJ all rights reserved.

02

왜 파이썬인가?

머신러닝에서 파이썬을 가장 많이 쓰는 이유

02 왜 파이썬인가?

데이터 분석부터 서비스까지 한 언어로

범용 프로그래밍 언어

- 데이터 분석, 자동화, 웹까지 한 언어로 할 수 있다
- 문법이 쉬워 입문자가 배우기 좋다

풍부한 라이브러리

- 데이터 처리·통계·시각화·자연어·이미지 처리 도구가 이미 준비돼 있다
- 대부분 무료 오픈소스다

대화형 실행

- Jupyter Notebook, Google Colab에서 한 줄씩 실행하고 결과를 바로 본다
- 실험하고 고치기 쉽다

서비스로 확장

- 만든 모델을 웹 서비스(Flask, FastAPI)나 프로그램으로 배포할 수 있다
- GUI 프로그램도 만들 수 있다

ⓒ 2026. DJ all rights reserved.

03

파이썬 기본 라이브러리

pandas · NumPy · SciPy · matplotlib · seaborn · scikit-learn

03 파이썬 기본 라이브러리

머신러닝 작업 흐름으로 보는 라이브러리 지도

① 데이터 불러오기·정리

pandas

CSV·엑셀을 읽어 표(DataFrame)로 다룬다

→

② 수치 계산

NumPy · SciPy

배열 연산, 선형대수, 과학 계산

→

③ 시각화

matplotlib · seaborn

그래프로 데이터를 살펴본다

→

④ 머신러닝

scikit-learn

분류·회귀·군집 모델 학습과 평가

→

⑤ 딥러닝

PyTorch · TensorFlow

신경망 모델 (이후 과정에서)

그 밖에 plotly(인터랙티브 그래프) · folium(지도 시각화) · Jupyter / Colab(실습 환경)

이 과정의 중심 pandas로 데이터를 준비하고 scikit-learn으로 모델을 만든다

ⓒ 2026. DJ all rights reserved.

03 파이썬 기본 라이브러리

NumPy · SciPy — 계산을 위한 라이브러리

NumPy — 배열 계산

- 다차원 배열(ndarray)이 기본 데이터 구조
- 배열의 모든 원소는 같은 자료형이어야 한다
- 선형대수, 푸리에 변환, 난수 생성 같은 수학 함수 제공

```
import numpy as np
a = np.array([[1, 2], [3, 4]])
a.shape        # (2, 2)
```

SciPy — 과학 계산

- 최적화, 신호 처리, 통계 분포 같은 과학 계산 함수 모음
- 고성능 선형대수 기능
- scipy.sparse: 대부분이 0인 큰 행렬(희소 행렬)을 적은 메모리로 저장

```
from scipy import sparse
m = sparse.eye(1000)
m.nnz          # 1000 (0이 아닌 값)
```

ⓒ 2026. DJ all rights reserved.

03 파이썬 기본 라이브러리

pandas · matplotlib · seaborn — 표 데이터와 시각화

pandas — 표 데이터 다루기

- 기본 구조는 표 모양의 DataFrame
- NumPy와 달리 열마다 자료형이 달라도 된다
- CSV, 엑셀, SQL 등 다양한 파일을 읽고 쓴다

```
import pandas as pd
df = pd.read_csv("iris.csv")
df.head()      # 앞의 5행 보기
```

matplotlib · seaborn — 시각화

- matplotlib: 파이썬의 대표 그래프 라이브러리
- seaborn: 적은 코드로 세련된 통계 그래프
- 그래프로 보면 숫자만으로는 안 보이던 패턴이 보인다

```
import seaborn as sns
sns.pairplot(df, hue="species")
# 특성끼리의 관계를 한 번에
```

ⓒ 2026. DJ all rights reserved.

03 파이썬 기본 라이브러리

scikit-learn · 딥러닝 라이브러리 · 실습 환경

scikit-learn

- 분류·회귀·군집 알고리즘과 데이터 나누기·평가 도구를 한곳에
- 모든 모델을 fit() → predict() 같은 방식으로 쓴다

```
model.fit(X, y)
model.predict(X_new)
```

딥러닝 라이브러리

- PyTorch, TensorFlow·Keras
- 이미지·음성·텍스트 같은 비정형 데이터에 주로 쓴다
- 이후 딥러닝 과정에서 다룬다

실습 환경

- Python 3.11 이상 권장 (Python 2는 2020년에 지원 종료)
- Google Colab: 설치 없이 브라우저에서 바로 실습
- 내 컴퓨터: Anaconda로 주요 라이브러리를 한 번에 설치

참고 mglearn은 책 『파이썬 라이브러리를 활용한 머신러닝』의 예제 그림용 도구입니다. 이 과정에서는 matplotlib·seaborn으로 직접 그립니다.

ⓒ 2026. DJ all rights reserved.

04

붓꽃(Iris) 데이터셋

150송이 · 특성 4개 · 품종 3종으로 배우는 머신러닝 용어

04 붓꽃(Iris) 데이터셋

머신러닝 입문에서 가장 많이 쓰는 데이터셋



setosa **virginica** **versicolor**

사진 출처: Wikimedia Commons (CC 라이선스)

150	4	3
샘플 (붓꽃 송이)	특성 (측정값)	품종 (클래스)

특성 꽃받침 길이·너비, 꽃잎 길이·너비 (단위 cm)

레이블 품종 3종, 품종마다 50송이씩

문제 유형 측정값으로 품종을 맞히는 분류 문제

```
from sklearn.datasets import load_iris
iris = load_iris()
iris.data.shape      # (150, 4)  → 샘플 150개 × 특성 4개
```

ⓒ 2026. DJ all rights reserved.

04 붓꽃(Iris) 데이터셋

붓꽃으로 이해하는 머신러닝 용어

	뜻	붓꽃 데이터에서는
샘플 (sample)	데이터셋의 한 행. 데이터 포인트라고도 한다	**붓꽃 한 송이**
특성 (feature)	예측에 쓰는 입력 값	**꽃받침·꽃잎의 길이와 너비 4개**
레이블 (label)	샘플 하나에 대한 정답 출력	**이 꽃의 품종**
클래스 (class)	레이블이 될 수 있는 값의 범주	**setosa · versicolor · virginica**
학습 (training)	데이터로 예측 모델을 만드는 과정	**`model.fit(X, y)`**

ⓒ 2026. DJ all rights reserved.

05

학습 데이터와 테스트 데이터

왜 나누고, 어떻게 나누는가

05 학습 데이터와 테스트 데이터

모델을 공정하게 평가하려면 데이터를 나눈다

학습 데이터 (train set)

- 모델을 학습시킬 때 사용한다
- 입력(X_train)과 정답(y_train)을 함께 보며 규칙을 찾는다

테스트 데이터 (test set)

- 학습에는 쓰지 않고 평가에만 사용한다 (홀드아웃 세트)
- 처음 보는 데이터도 잘 맞히는지 확인한다

scikit-learn train_test_split 기본값 (붓꽃 150송이 기준)

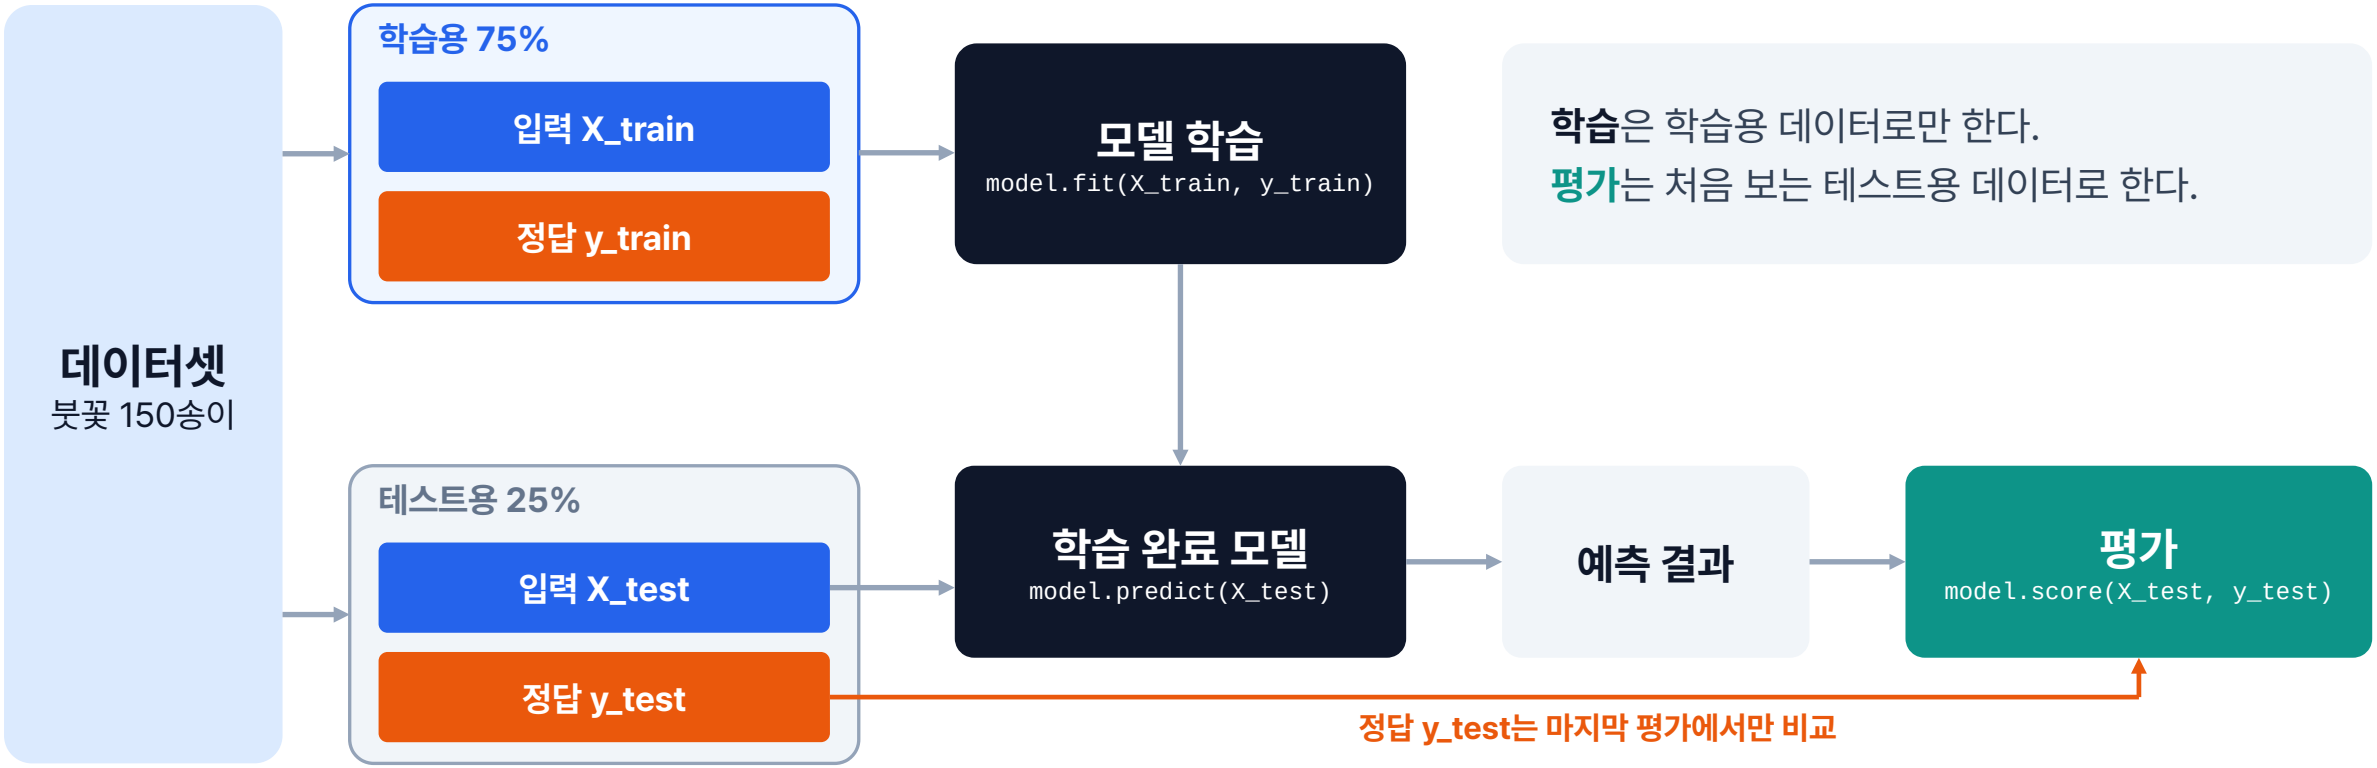


왜 나눌까? 학습에 쓴 데이터로 평가하면 이미 외운 답을 맞히는 셈이라, 처음 보는 데이터에서의 실제 성능을 알 수 없다.

ⓒ 2026. DJ all rights reserved.

05 학습 데이터와 테스트 데이터

데이터 나누기부터 평가까지의 흐름



학습은 학습용 데이터로만 한다.
평가는 처음 보는 테스트용 데이터로 한다.

ⓒ 2026. DJ all rights reserved.

06

첫 머신러닝 모델 만들기

scikit-learn 코드 5단계로 붓꽃 품종 맞히기

06 첫 머신러닝 모델 만들기

붓꽃 품종을 맞히는 KNN 분류 모델 — 코드 5단계

```
from sklearn.datasets import load_iris                  from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
```

1 데이터 불러오기

```
iris = load_iris()
```

2 데이터 나누기

```
X_train, X_test, y_train, y_test = train_test_split(
    iris.data, iris.target, random_state=42)
```

3 모델 고르기

```
model = KNeighborsClassifier(n_neighbors=3)
```

4 학습하기

```
model.fit(X_train, y_train)
```

5 평가하기

```
model.score(X_test, y_test)    # 1.0
```

실행 결과

1.0

테스트 38송이를 모두 맞힘 (정확도 100%)

`random_state=42`
실행할 때마다 같은 결과가 나오도록 나누는 방법을 고정

다음 시간 KNN이 어떻게 품종을 맞히는지 자세히 본다

ⓒ 2026. DJ all rights reserved.

07

데이터에 대해 가장 먼저 할 일

모델을 만들기 전에 확인할 세 가지

07 데이터에 대해 가장 먼저 할 일

모델을 만들기 전에 확인할 세 가지

1

머신러닝으로 풀 문제인가?

- 규칙이 단순하면 일반 프로그램이 더 낫다
- 예측할 대상(레이블)과 충분한 데이터가 있는지 확인한다

붓꽃: 품종을 맞히는 분류 문제

2

빠진 값, 이상한 값은 없나?

- 결측치: 비어 있는 값
- 이상치: 상식적인 범위를 벗어난 값
- 찾아서 지우거나 채운다

```
df.isnull().sum()
df.describe()
```

3

그래프로 데이터를 알아가기

- 분포와 특성 사이의 관계를 먼저 본다
- 이것을 데이터 탐색(EDA)이라고 한다

```
sns.pairplot(df, hue="species")
```

© 2026. DJ all rights reserved.

정리 한 장으로 보는 머신러닝 기본

먼저 데이터와 과제를 이해한다

무엇을 예측할지, 데이터가 충분한지,
성과를 어떻게 잴지 먼저 정한다.

파이썬 라이브러리

pandas(표) · NumPy(계산) · matplotlib/seaborn(시각화)
scikit-learn(머신러닝) · PyTorch/TensorFlow(딥러닝)

데이터는 나눠서 평가한다

학습 데이터로 학습하고, 테스트 데이터로 평가한다.
train_test_split 기본값: 학습 75% · 테스트 25%

첫 모델 5단계

불러오기 → 나누기 → 모델 고르기 → fit() → score()
붓꽃 KNN 모델의 테스트 정확도: 1.0

REF 참고 자료

더 공부하고 싶다면

참고 자료

- [책] 파이썬 라이브러리를 활용한 머신러닝 (안드레아스 뮐러·세라 가이도 지음, 박해선 옮김, 한빛미디어)
- [책] 머신러닝 인 파이썬
- [책] 머신러닝 라이브러리
- 구글 머신러닝 용어집 — developers.google.com/machine-learning/glossary
- scikit-learn 공식 문서 — scikit-learn.org

ⓒ 2026. DJ all rights reserved.