머신러닝(Machine Learning)

지도학습 알아보기(knn, linear regression)

01 History

No	version	날짜	내용
1	ver 1.11	2020-05-14	의사결정 트리 부분 변경
2	ver 1.12	2020-09-10	내용 업데이트
3	ver 1.13	2020-10-23	결정계수 추가
4	ver 1.13	2020-12-02	릿지, 랏소 회귀 내용 추가
5			
6			
7			

목 차

01 머신러닝(Machine Learning)

▶ 머신러닝(Machine Learning)은 지도학습과 비지도학습으로 나누어진다.

▶ 지도학습은 예측하려는 값이 존재하는 것이고, 비지도학습은 존재하지 않는다.

▶ 지도학습은 다시 회귀(regression)과 분류(classification)으로 나누어진다.

01 머신러닝(Machine Learning) - 지도학습

- 머신러닝 방법 중의 하나.
- 지도학습은 입력과 출력 샘플 데이터가 있다.
- 비지도학습은 입력이 있고 출력 샘플 데이터가 없다.

01 머신러닝(Machine Learning)

▶ 분류는 미리 정의된, 가능성 있는 여러 클래스 레이블(class label)중 하나를 예측

▶ 두 개의 클래스로 분류하는 이진 분류(binary classification)

- 예/아니오 또는 생존/사망 등으로 분류
- 이진 분류에서 한 클래스를 양성(positive) 클래스, 다른 하나를 음성(negative) 클래스라고 한다.

▶ 셋 이상의 클래스로 분류하는 다중 분류(multiclass classification)

01 머신러닝(Machine Learning)

▶ 모델이 처음보는 데이터에 대해 정확하게 예측할 수 있으면 이를 훈련 세트에서
테스트 세트로 **일반화(generalization)**되었다고 함.

▶ 가진 정보를 너무 사용해서 너무 복잡한 모델을 만드는 것을 **과대적합(overfitting)**이라 한다.
모델이 훈련 세트의 각 샘플에 가깝게 맞춰져서 새로운 데이터에 일반화 되기 어려울 때 발생.

▶ 반대로 너무 간단한 모델이 선택되는 것을 과소 적합(underfitting)라고 한다.

02 k-최근접 이웃(k-Nearest Neighbors)

▶ 가장 가까운 훈련 데이터 포인트를 찾아 이를 예측에 활용한다. (분류의 경우)

▶ 새로운 데이터는 해당 거리안의 데이터가 가장 많이 있는 클래스로 분류하게 된다.(분류)

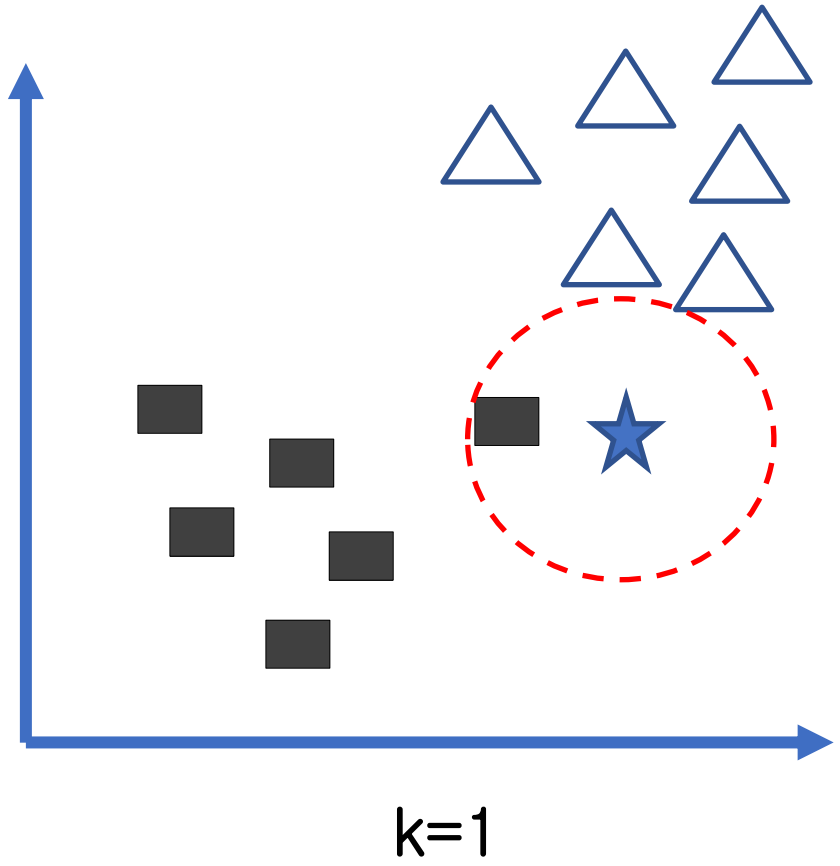

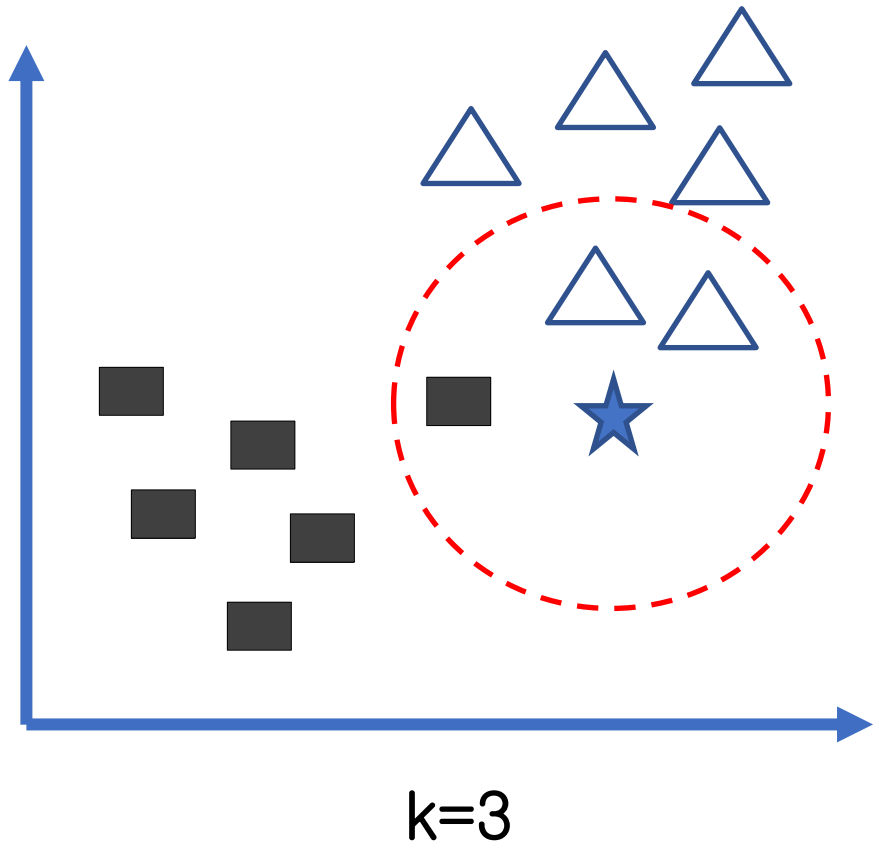

02 k-최근접 이웃(k-Nearest Neighbors)

▶ 가장 가까운 훈련 데이터 포인트를 찾아 이를 예측에 활용한다. (회귀의 경우)

▶ 새로운 데이터는 해당 거리안의 k개 데이터가 예측하는 목표변수의 값의 평균으로 예측하게 된다. (회귀의 경우)

▶ 이웃 간의 거리를 계산할 때 **특성마다 값의 범위가 다를 경우**, 범위가 작은 특성에 영향을 받는다. 따라서 k-NN 알고리즘을 사용할 때는 특성들이 **같은 스케일을 갖도록 정규화**하는 것이 일반적이다.

02 k-최근접 이웃(k-Nearest Neighbors)

▶ 가장 가까운 훈련 데이터 포인트를 찾아 이를 예측에 활용한다. (회귀의 경우)

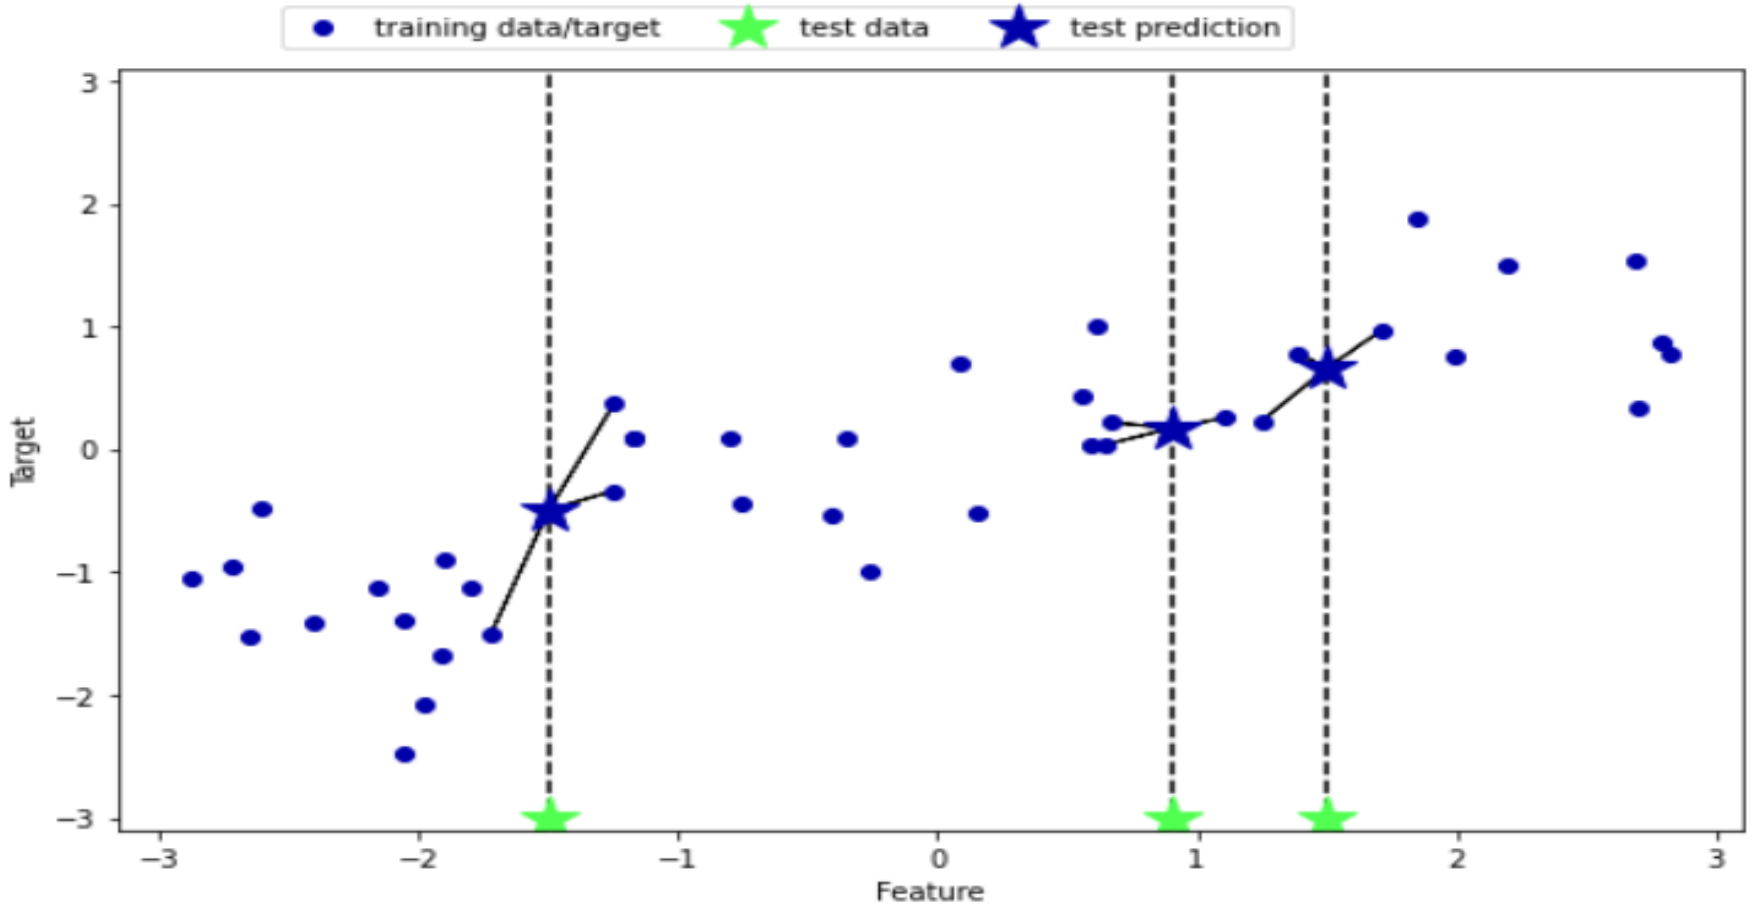

k=3의 경우

02 k-최근접 이웃(k-Nearest Neighbors)

▶ k의 값에 따른 결정 경계(decision boundary)

새로운 데이터가 어느 값으로 분류될지 결정되는 경계를 말한다.

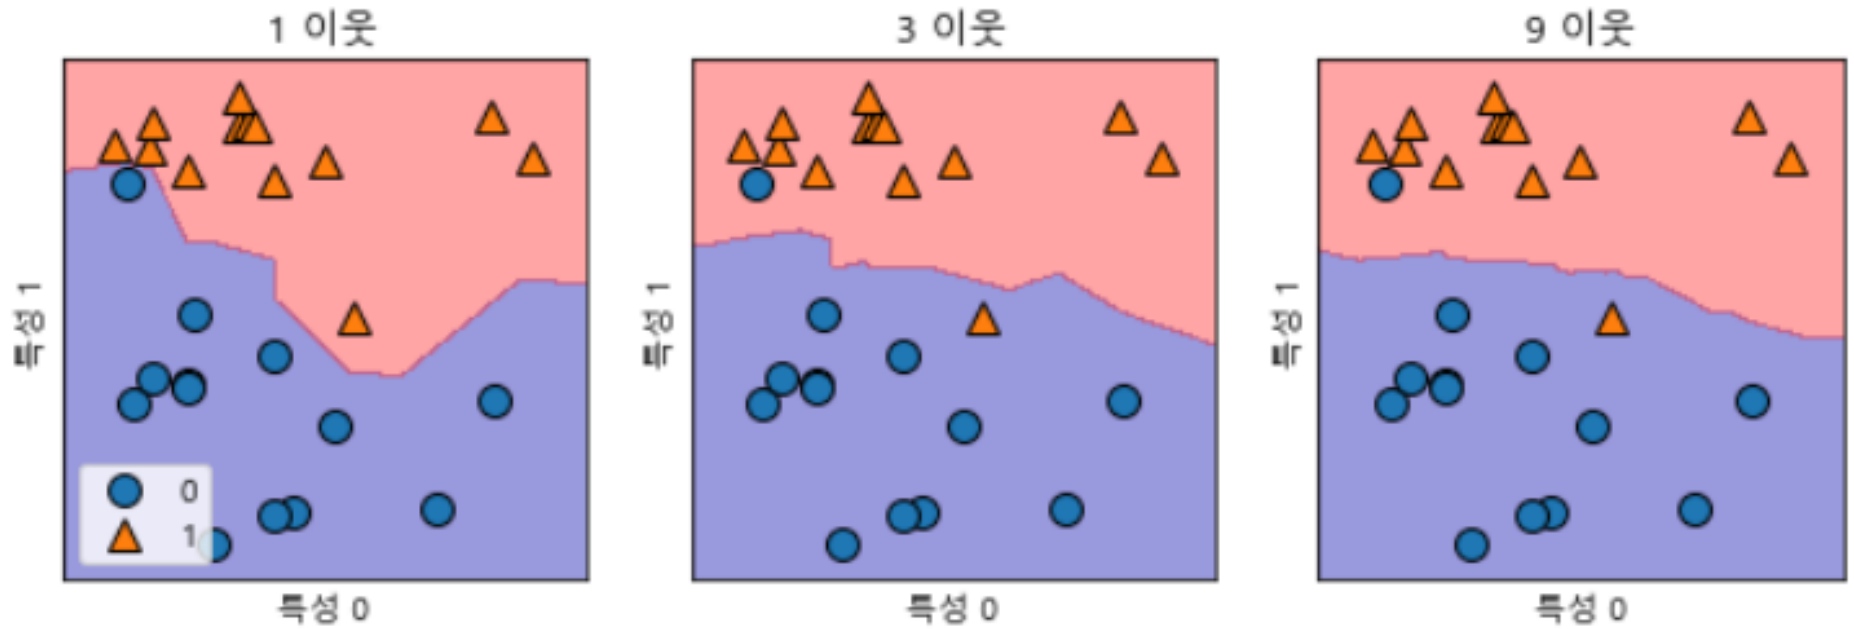

이웃의 수를 늘릴 수록 결정경계는 더 부드러워집니다.

02 k-최근접 이웃(k-Nearest Neighbors)

▶ knn 모델의 장점

A. 매우 쉬운 모델이다.

B. 많이 조정하지 않아도 자주 좋은 성능 발휘

▶ knn 모델의 단점

A. 수백 개 이상의 많은 특성을 가진 데이터 셋을 가진 데이터 셋에는 잘 동작하지 않음.

B. 특성 값 대부분이 0인 데이터 셋과는 잘 동작하지 않음.

03 선형모델(linear model)

▶ **선형 모델은 100여 년 전에 개발되었고, 가장 간단하고 오래된 회귀용 선형 알고리즘.**

▶ **선형모델은 입력 특성(feature)에 대한 선형 함수를 만들어 예측 수행**

$$\hat{y}(\text{예측값}) = w_1 * x_1 + w_2 * x_2 + \ldots + w_p * x_p + b$$

$\hat{y}$: 모델이 만들어낸 예측값

x_i : 특성

w_i : 각 특성에 대한 기울기(가중치)

▶ **선형모델은 w(가중치 or 계수)와 b(편향(offset) 또는 절편)를 학습하여 정하게 된다.**

▶ **선형모델은 특성이 하나일 때는 직선, 두 개일 때는 평면,**

더 높은 차원에서는 초평면이 된다.

04 하이퍼 파라미터(hyperparameter)

▶ **모델 파라미터 or 계수**

머신러닝에서 알고리즘이 주어진 데이터로 부터 학습하는 파라미터

▶ **하이퍼파라미터(hyperparameter) or 매개변수**

모델이 학습할 수 없는 사람이 직접 설정해 주어야 하는 파라미터

05 선형 회귀(linear regression)

▶ 선형회귀는 평균제곱오차(MSE)를 최소화하는 파라미터(w,b)를 찾는다.

$$MSE = \frac{1}{n(\text{샘플개수})} \sum_{i=1}^{n} (y_i(\text{실제값}) - \hat{y}_i\,(\text{예측값}))^2$$

▶ 선형 회귀는 매개변수(직접 지정하는 변수)가 없는 것이 장점

=> 따라서 모델의 복잡도를 제어할 방법이 없음.

05 선형 회귀(linear regression)- 결정계수

▶ 결정계수(R^2)

(1) scikit-learn의 score메소드에서 사용한다.

(2) 결정계수는 회귀 모델에서 예측의 적합도를 측정한 것이다.

▶ 결정계수(R^2)

$$R^2 = 1 - \frac{\sum (y - \hat{y})^2}{\sum (y - \bar{y})^2}$$

y : 타깃값

$\hat{y}$: 예측값

$\bar{y}$: 평균

선형회귀에 대한 과 적합 해결 방법은 있을까?

06 일반화하기

▶ **과적합을 해소하기 위해 우리는 정규화 항을 사용한다.**

MSE + regular-term(정규화 항)

▶ **선형회귀 모델**

$$\hat{y}(\text{예측값}) = w_1 * x_1 + w_2 * x_2 + \ldots + w_p * x_p + \text{b}$$

▶ **오차함수(cost function)**

$$\sum_{i=1}^{M}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{M}(y_i - \sum_{j=0}^{p} w_j - x_{ij})^2$$

06 라쏘 회귀(Lasso)와 릿지회귀(Ridge)

▶ 라쏘 회귀(Ridge) - L1규제

A. 선형 모델,

B. 가중치(w..)의 절대값을 w의 모든 원소가 0에 가깝게, 어떤 것은 정말 0이 된다.

- 일부 계수를 0으로 만들면 모델을 이해하기 쉽고 모델의 가장 중요한 특성이 드러남
- 자동으로 특성 선택(feature selection)이 이루어짐.

C. 모든 특성(feature)이 특성에 영향을 주는 영향을 최소한으로 함.

이런 제약을 우리는 규제(regularization)이라고 한다. 라쏘 회귀에 사용하는 규제를 **L1규제라** 한다.

D. Lasso도 계수를 얼마나 강하게 0으로 규제할지 alpha 매개변수를 이용.

06 라쏘 회귀(Lasso)와 릿지회귀(Ridge)

▶ 릿지 회귀(Ridge) - L2규제

A. 선형 모델,

B. 가중치(w..)의 절대값을 가능한 한 작게 만든다. w의 모든 원소가 0에 가깝게

C. 모든 특성(feature)가 특성에 영향을 주는 영향을 최소한으로 만든다.

이런 제약을 우리는 규제(regularization)이라고 한다.

릿지 회귀에 사용하는 규제를 **L2규제라** 한다.

D. 데이터를 충분히 주면 릿지 회귀에서의 규제항(alpha)은 덜 중요해 진다.

06 라쏘 회귀(Lasso)와 릿지회귀(Ridge)

▶ 라쏘 회귀 - L1규제

$$\sum_{i=1}^{M}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{M}(y_i - \sum_{j=0}^{p} w_j - x_{ij})^2 + \lambda \sum_{j=0}^{p} |w_j|$$

▶릿지 회귀 - L2규제

$$\sum_{i=1}^{M}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{M}(y_i - \sum_{j=0}^{p} w_j - x_{ij})^2 + \lambda \sum_{j=0}^{p} {w_j}^2$$

07 ElasticNet(엘라스틱넷)

▶ 엘라스틱 넷

A. Lasso와 Ridge을 결합한 모델.

B. 가장 좋은 성능을 내지만 L1과 L2규제를 위한 매개변수 두개를 조정해야 함.

08 결정트리(decision tree)

▶ 결정 트리(decision tree)는 분류와 회귀 문제에 널리 사용하는 모델

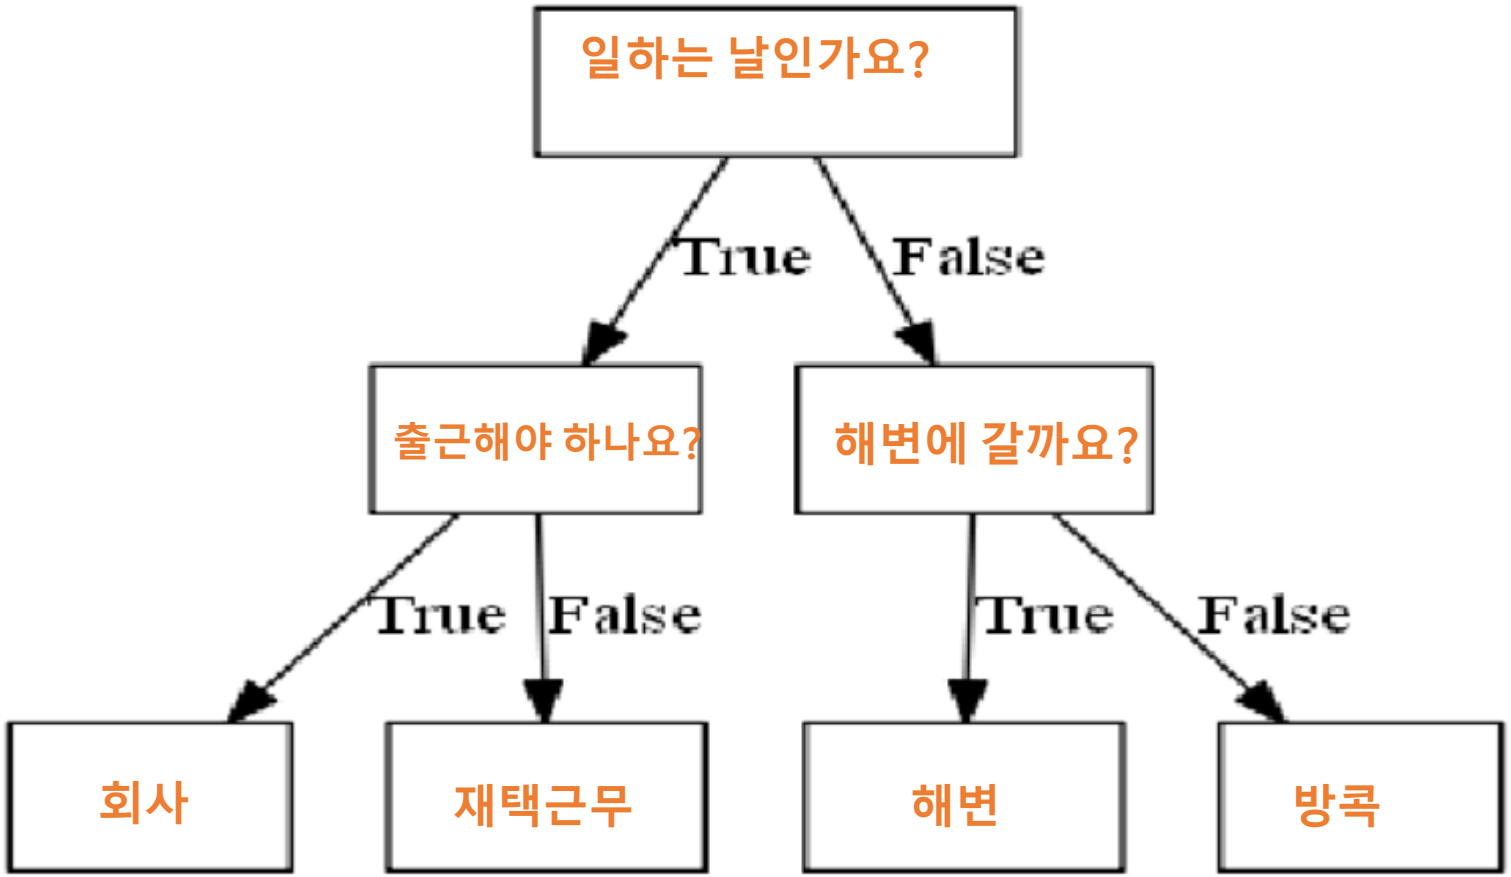

History

날짜	내용	비고
2020/09/10	내용 업데이트	
2020/12/02	릿지, 랏소 내용 추가	v113

