머신러닝(Machine Learning) · 지도학습

로지스틱 회귀와 분류용 선형 모델

결정 경계 · 규제 C · 일대다 · 오즈와 로짓 · 시그모이드

v03 · 2026.10

© 2026. LDJ all rights reserved.

학습 목표

이번 시간에 할 것

1. **분류용 선형 모델에 대해 알아봅니다.**
   결정 경계 · 규제 매개변수 C · 다중 클래스 · 장단점

2. **로지스틱 회귀에 대해 알아봅니다.**
   확률 → 오즈 → 로짓 → 시그모이드

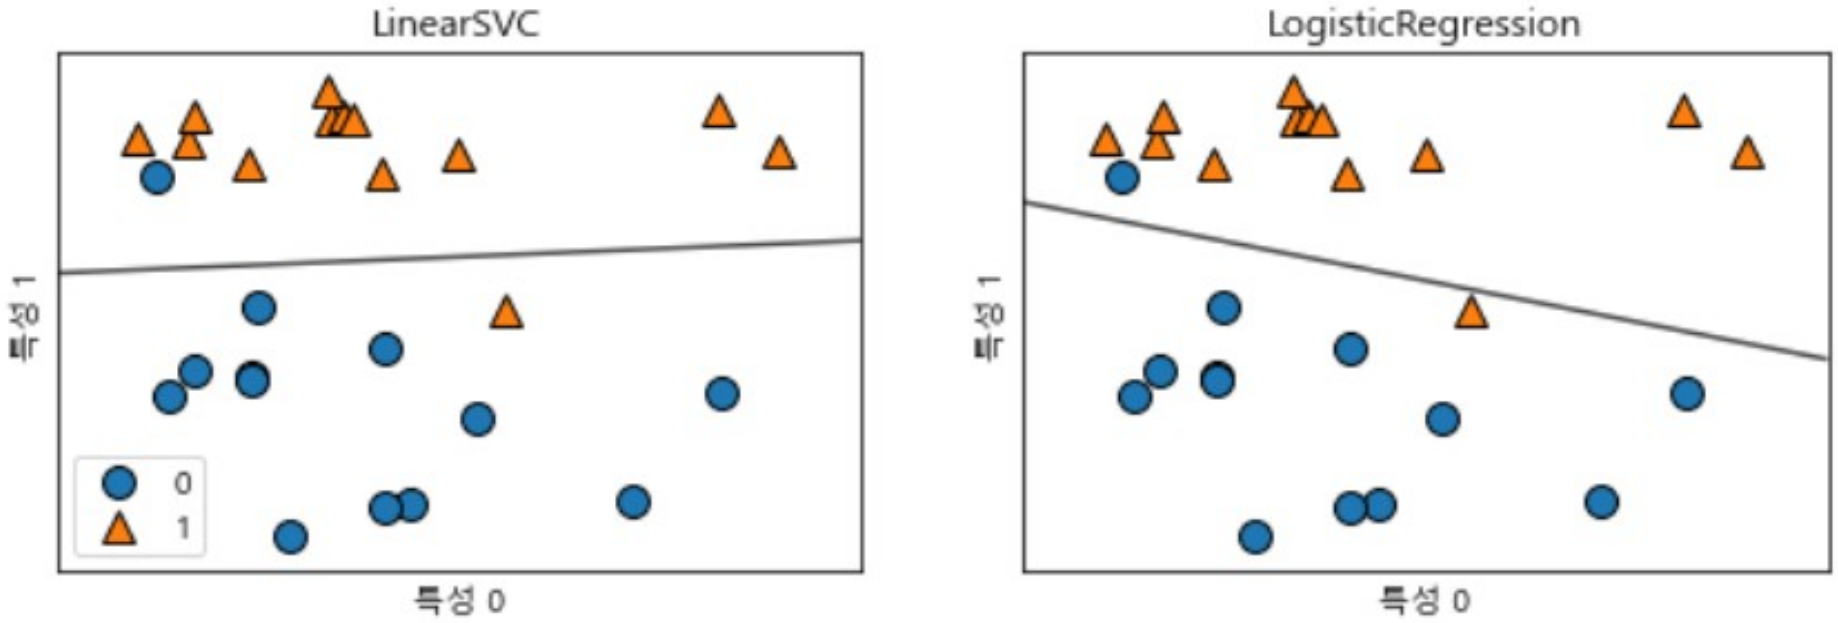
목차

01 **분류용 선형 모델**
결정 경계 · 규제 C · 다중 클래스 · 장단점 · 매개변수

02 **로지스틱 회귀(logistic regression)**
오즈 · 로짓 · 로지스틱(시그모이드) 함수

01 분류용 선형 모델

어떻게 분류되는가?



- LinearSVC와 LogisticRegression으로 만든 **결정 경계가 직선**으로 표현됨.
- 직선을 기준으로 위쪽은 클래스 1, 아래쪽은 클래스 0으로 나눠짐.

© 2026. Lim all rights reserved.

01 분류용 선형 모델

선형 분류기란?

선형 분류기

- **선, 평면, 초평면**을 사용해서 두 개의 클래스를 분류하는 분류기
- 특성이 2개면 선, 3개면 평면, 그보다 많으면 초평면

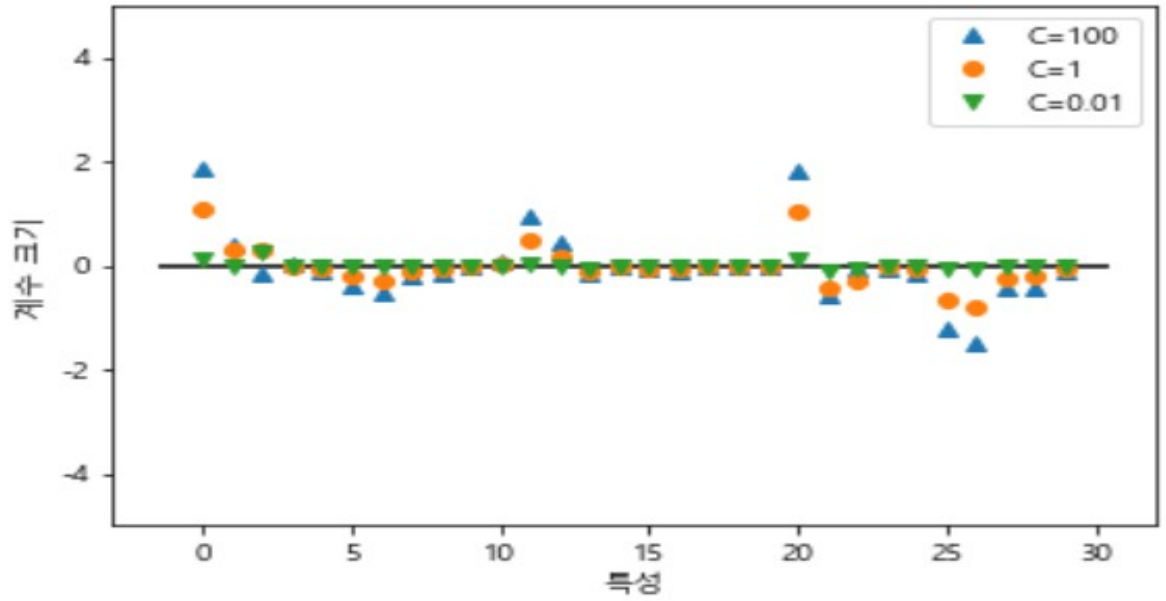
두 개의 선형 분류 알고리즘

- (1) 로지스틱 회귀(Logistic Regression)
- (2) 서포트 벡터 머신(support vector machine) - scikit-learn의 **LinearSVC**

© 2026. Lim all rights reserved.

01 분류용 선형 모델 - 일반화 시키기

규제를 결정하는 매개변수 C



- C는 규제 강도의 역수: C가 작을수록 규제가 강하다

© 2026. Lim all rights reserved.

01 분류용 선형 모델 – 종류

scikit-learn의 두 선형 분류기 (scikit-learn 1.9.1 기준, 확인일 2026-10-13)

	LogisticRegression	LinearSVC
결정 경계	**직선(초평면)**	**직선(초평면)**
규제 매개변수	**C** (작을수록 규제가 강함)	**C** (작을수록 규제가 강함)
다중 클래스	클래스가 3개 이상이면 **다항(multinomial) 손실**을 직접 최적화	기본은 **일대다(ovr)** 방식
multi_class	더 이상 없음	있음 (기본값 'ovr')

01 분류용 선형 모델 – 다중 클래스

일대다(one-vs-rest) 방식



클래스의 수만큼 이진 분류기가 만들어진다. LogisticRegression의 solver='liblinear'는 이진 전용이라 OneVsRestClassifier로 감싸 쓴다.

© 2026. Lim all rights reserved.

01 분류용 선형 모델 - 장단점

선형 모델의 장단점

장점

- 학습 속도가 빠르고 예측도 빠르다.
- 매우 큰 데이터셋과 희소한 데이터셋에도 잘 작동한다.
- 샘플에 비해 특성이 많을 때 잘 동작한다.

단점

- 저차원 데이터셋에서는 다른 모델들의 일반화 성능이 더 좋은 경우가 많다.

© 2026. Lim all rights reserved.

01 분류용 선형 모델 – 매개변수

주요 매개변수

규제 강도

- 회귀 모델(Ridge, Lasso)은 **alpha**, LinearSVC와 LogisticRegression은 **C**가 매개변수이다.
- C와 alpha는 로그 스케일(0.01, 0.1, 1, 10 ...) 후보 중에서 최적치를 찾는다.

규제 종류

- L1 규제를 사용할지, L2 규제를 사용할지 결정해야 한다.
- scikit-learn 1.8부터 LogisticRegression의 penalty는 지원 중단 예정 → **l1_ratio**로 지정 (0 = L2, 1 = L1)

solver와 대용량 데이터

- LogisticRegression의 기본 solver는 **'lbfgs'**이다.
- 데이터가 크면 LogisticRegression과 Ridge는 solver='sag' 또는 'saga'가 더 빠를 수 있다 (특성 스케일이 비슷할 때).
- 다른 대안으로 SGDClassifier와 SGDRegressor를 사용할 수 있다.

참고: scikit-learn 1.9.1 문서 (확인일 2026-10-13)

© 2026. Lim all rights reserved.

Q

예측할 값이 범주형이면 회귀 모델을 어떻게 쓸까?

예) 합격/불합격, 스팸/정상처럼 답이 범주일 때

02 로지스틱 회귀(logistic regression)

왜 로지스틱 회귀인가?

문제

- 예측하고자 하는 Y가 **범주형(categorical)**일 때는 다중 선형 회귀 모델을 그대로 적용할 수 없다.

해결

- 범주에 속할 **확률**을 예측하는 로지스틱 회귀 모델
- 이름과 달리 **분류 모델**이다. 확률에 기준값(기본 0.5)을 적용해 클래스를 정한다.

역사

- Berkson(1944)이 'logit'이라는 이름을 만들고 널리 알렸고, D.R. Cox(1958) 등이 발전시켰다.

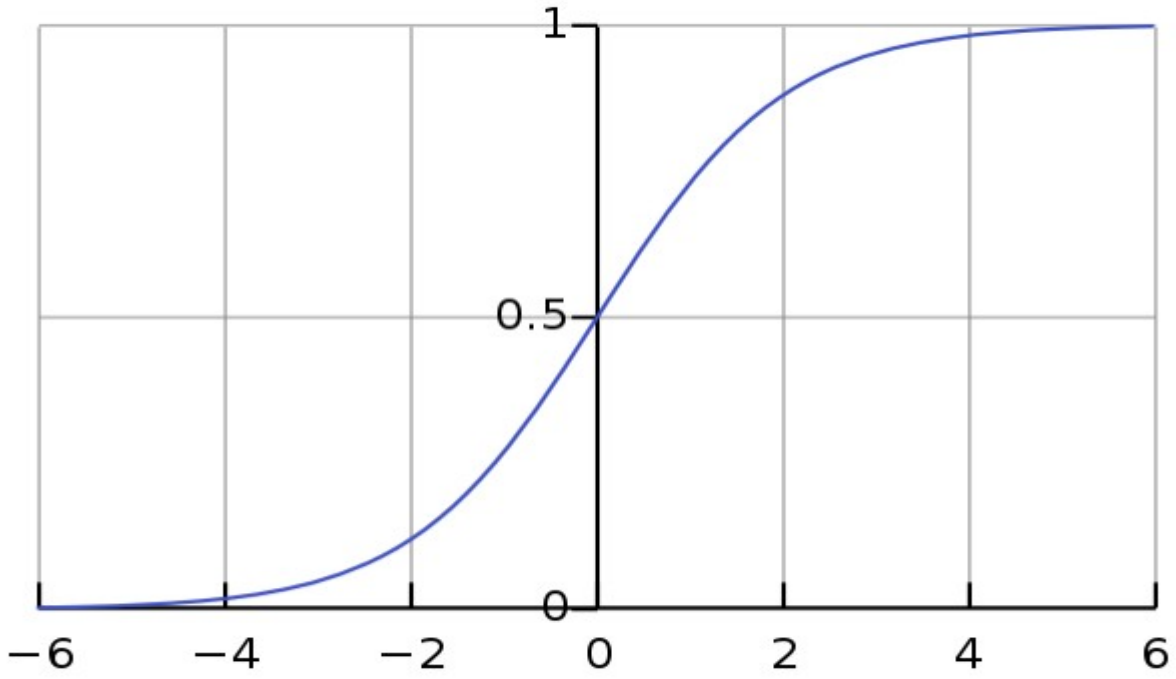
참고: 위키백과

02 로지스틱 회귀(logistic regression)

▶ 로지스틱 회귀(logistic regression)

회귀를 사용하여 데이터가 어떤 범주에 속할 확률을 0과 1사이의 값으로 예측한다.

로짓 변환을 통해 직선형 Regression을 곡선형으로 적합시킨다.(Fitting)



참고: 위키백과

02 로지스틱 회귀(logistic regression)

▶ 선형 회귀

$$\hat{y}_i = w[0] * x[0] + w[1] * x[1] + \ldots + w[p] * x[p] + b$$

▶ 로지스틱 회귀(logistic regression)

$$P(Y = 1) = w[0] * x[0] + w[1] * x[1] + \ldots + w[p] * x[p] + b$$

A. P(Y=1)의 범위는 0~1인데, w[0] * x[0] .. 의 범위는 -∞ ~ ∞ 로 맞지 않음.

⇒ (해결) P(Y=1)에 Logit을 적용해 범위를 -∞ ~ ∞로 바꾼다

02 로지스틱 회귀(logistic regression)

▶ 로짓이란 무엇인가?

Logit = Log Odds

▶ Odds란 무엇인가?

$$\text{Odds} = \frac{\text{성공할 확률}}{\text{실패할 확률}} = \frac{P}{1-P}$$

Odds ∈ (0, ∞)

P ∈ (0, 1)

Logit(P) = log(Odds) = log(P / (1 − P))



Log Odds ∈ (-∞, ∞)

02 로지스틱 회귀(logistic regression)

▶ P(Y=1)에 로짓 적용하기

$$\text{Logit}(P(Y=1)) = ax + b = \log\left(\frac{P}{1-P}\right)$$

$$z = \text{Logit}(P) = \log\left(\frac{P}{1-P}\right) = ax + b$$

※ ax + b 는 w[0]·x[0] + ... + b 를 짧게 쓴 것

02 로지스틱 회귀(logistic regression)

▶ 로지스틱 함수는 Logit 함수의 역함수이다.

$$\log\left(\frac{P}{1-P}\right) = ax + b$$

$$\Rightarrow \frac{P}{1-P} = e^{ax+b}$$

$$\Rightarrow P = (e^{ax+b}) * (1 - P)$$

$$\Rightarrow P(1 + e^{ax+b}) = e^{ax+b}$$

$$\Rightarrow P = \frac{e^{ax+b}}{1+e^{ax+b}} = \frac{e^{z}}{1+e^{z}} = \frac{1}{1+e^{-z}}$$