머신러닝(Machine Learning)

앙상블 기법

목 차

01 앙상블 기법

▶ 앙상블(ensemble)는 여러 머신러닝 모델을 연결하여 더 강력한 모델을 만드는 기법

▶ 랜덤 포레스트(Random Forest)와 그래디언트 부스팅(gradient boosting)

=〉 둘 다 모델을 구성하는 기본 요소로 결정 트리를 사용.

02 앙상블 기법-랜덤 포레스트

▶ **결정 트리의 주요 단점 - 훈련 데이터에 과대 적합되는 경향이 있음.**

A. 랜덤 포레스트는 이 문제를 회피할 수 있는 방법.

▶ **아이디어 : 조금씩 다른 여러 결정 트리의 묶음.**

Point 01. 여러개의 의사결정트리를 생성한다.

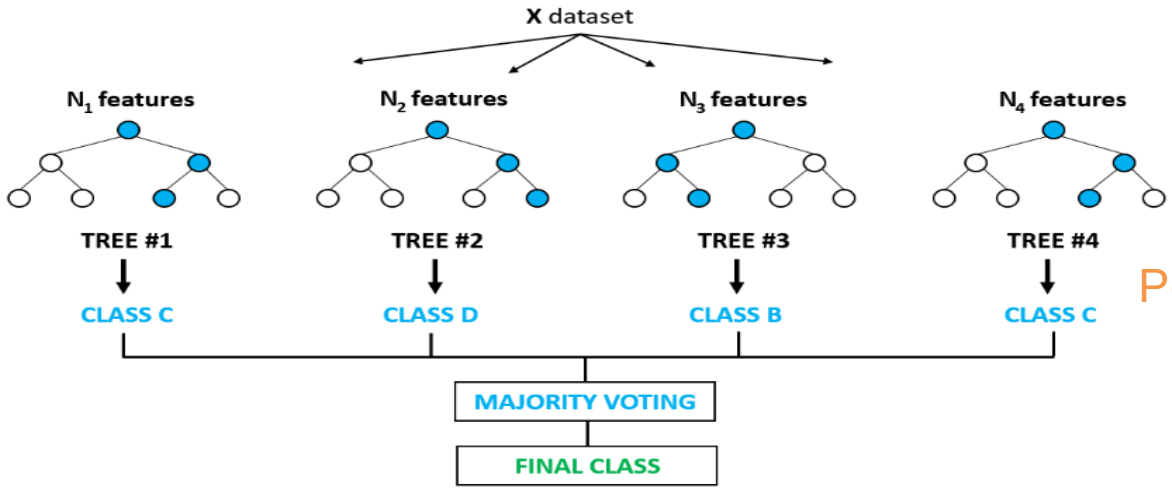

하나 하나의 트리는 데이터의 일부에 과대적합을 하는 경향이 있다.

Point 3. 예측
01. 회귀 : 만약 10개 트리모델이 있다면 10개가 예측한 값의 평균으로 예측
02. 분류 : 만약 10개 트리 모델이 있다면 10개가 예측한 값 중에 많은 값으로 예측한다.

http://bitly.kr/s2GOAgZm0 참조

02 앙상블 기법-랜덤 포레스트

▶ 결정 트리의 주요 원리

(A) 잘 작동하되 서로 다른 데이터에 대해서 과대 적합된 트리를 많이 만들어 평균을 내면 과대적합을 줄어든다.

(B) 수학적으로 증명됨.

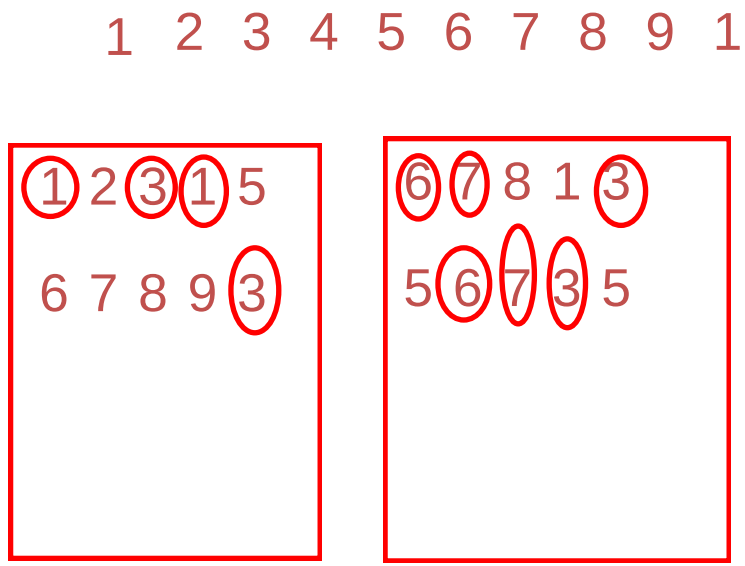

(1) 타깃 예측을 잘 해야 함.

(2) 다른 트리와 구별됨.

=〉 A. 데이터 포인트를 무작위로 선택

=〉 B. 분할 테스트에서 feature(특성)을 무작위로 선택

02 앙상블 기법-랜덤 포레스트

Point 2. 약간씩 다른 트리를 어떻게 만들 것인가?

▶ 랜덤 포레스트 만들기

(1) 각각의 트리마다 데이터 샘플링(중복 샘플링)
10000개의 데이터가 있으면 중복을 허용한
10000개의 데이터를 뽑는다.

(A) 생성할 트리의 개수를 정한다.

(B) 샘플을 생성한다. (부트 스트랩 샘플-bootstrap sample)

* n개의 데이터 포인트 중에서 n횟수만큼 반복 추출

* 어떤 데이터 포인트는 누락될 수 있고, 어떤 데이터포인트는 중복될 수 있다.

(2) 무작위로 일부 특성을 선택하고,
이 특성을 기준으로 모델을 만든다.
30개 -> 7, 8개

=〉 부트스트랩 샘플링은 랜덤 포레스트의 모든 트리가 서로 달라지도록 만든다.

(C) 각 노드에서 무작위로 특성(feature)을 선택 후, 이 후보들 중에서 최선의 테스트를 찾는다.

⇒ 관련 매개변수 : max_features

⇒ max_features 값을 크게 하면 랜덤 포레스트의 트리들은 매우 비슷해지고 가장 두드러진 특성을 이용해 데이터에 잘 맞춰질 것이다. 작게 하면 랜덤 포레스트 트리들은 많이 달라지게 된다.

02 앙상블 기법-랜덤 포레스트

▶ 회귀의 랜덤 포레스트 만들기

(A) 각각의 트리가 예측한 값들의 평균을 최종 예측으로 한다.

▶ 분류의 랜덤 포레스트 만들기

(A) 각 알고리즘이 가능성 있는 출력 레이블의 확률을 제공. 예측한 레이블의 확률을 평균을 내어 가장 높은 확률을 가진 클래스가 예측 값이 된다.

02 앙상블 기법-랜덤 포레스트

▶ 장점

(A) 개개의 트리보다 덜 과대 적합 되며, 훨씬 좋은 결정 경계를 만들어준다.

(B) 성능이 매우 뛰어나고 매개변수 튜닝을 많이 하지 않아도 잘 작동한다.

(C) 데이터의 스케일을 맞출 필요가 없다.

▶ 단점

(A) 매우 차원이 높고 희소한 데이터에서 잘 작동하지 않음.

(B) 선형 모델보다 많은 메모리를 사용하며 훈련과 예측이 느림.

02 앙상블 기법-랜덤 포레스트

▶ estimator_ 속성

랜덤 포레스트 안에 만들어진 트리

▶ max_features 매개변수

- 각 트리가 사용하는 변수의 개수. 각 트리가 얼마나 무작위가 될지를 결정. 일반적으로 기본값이 좋은 결정.
- 분류는 max_features=sqrt(n_features)이고, 회귀는 max_features=n_features입니다.

▶ n_jobs 매개변수

사용할 코어 수의 지정이 가능. -1일 경우 컴퓨터의 모든 코어를 사용.

▶ random_state

같은 결과를 만들어야 할 때는 random_state 값을 고정해야 한다.

▶ n_estimators

트리의 개수

03 앙상블 기법 - Gradient Boosting 기법

▶ 여러 개의 결정 트리를 묶어 강력한 모델을 만든다.

▶ 분류(Classification)과 회귀(Regression)에 모두 사용 가능.

▶ 랜덤 포레스트(random forest)와 달리 이전 트리의 오차 보완하는 방식

▶ 그래디언트 부스팅 회귀 트리는 무작위성이 없다. 대신 강력한 사전 가지치기 사용.

▶ 트리가 많을 수록 성능이 좋아짐.

▶ 랜덤 포레스트보다 매개 변수 설정에 더 민감하여 잘 조정하면 높은 정확도를 얻음.

03 앙상블 기법 - Gradient Boosting 기법

▶ 트리의 깊이가 5정도 깊지 않은 트리를 사용하며 메모리 사용이 적고 예측이 빠름.

이런 얕은 트리 같은 간단한 모델을 (약한 학습기-weak learner이라 한다.)

▶ 메모리 사용이 적고 예측이 빠르다.

▶ 머신러닝 경연 대회에서 우승을 많이 차지하였고, 업계에서도 널리 사용.

▶ 이전 트리 오차를 얼마나 강하게 보정할 것인가를 제어하는 파라미터 (learning_rate)

* 학습률이 크면 트리는 보정을 강하게 하므로 복잡한 모델이 만들어진다.

▶ 손실함수를 정의하고, 경사 하강법(gradient descent)를 사용하여 다음 추가될 트리의 예측값을 보정해 간다.

03 앙상블 기법 - Gradient Boosting 기법

▶ 단점

(1) 매개 변수를 잘 조정해야 한다.

(2) 학습 시간이 길다.

(3) 희소한 고차원 데이터에서 잘 작동하지 않는다.

▶ 장점

(1) feature 의 스케일을 조정하지 않아도 된다.

(2) 이진 특성이 연속적인 특성에서도 잘 동작한다.

03 앙상블 기법 - Gradient Boosting 기법

▶ learning_rate : 이전트리의 오차 보정 정도

▶ n_estimator : 트리의 모델 수

(A) n_estimator : 크면 클수록 좋음(랜덤 포레스트)

(B) n_estimator : 과적합의 가능성(그래디언트 부스팅)

▶ max_depth : 트리 모델의 복잡도

(A) max_depth를 매우 작게 설정하며 트리의 깊이가 5보다 깊어지지 않도록 한다.

▶ n_estimators을 맞춘 이후에 learning_rate를 찾음.

04 앙상블 기법 - 두 모델의 비교

▶ 두 모델의 비교- 그래디언트 부스팅 vs 랜덤 포레스트

A. 보통은 일반적으로 매개변수 설정을 하지 않아도 되는 랜덤 포레스트가 안정적이다.

B. 예측 시간이 중요하거나 머신러닝 모델에서 마지막 성능까지 쥐어짜야 할 때 그래디언트 부스팅을 사용하면 도움이 된다.

05 여러가지 모델

▶ KNN(최근접 이웃)

작은 데이터 셋, 기본 모델로서 좋고 설명하기 쉽다.

▶ 선형 모델

대용량 데이터 셋 가능. 대용량 데이터 셋 가능. 고차원 데이터에 가능

▶ 나이브 베이즈

분류만 가능. 선형모델보다 훨씬 빠름. 선형 모델보다 덜 정확함.

▶ 결정 트리

매우 빠르고, 데이터 스케일 조정이 필요 없음. 시각화하기 좋고, 설명하기 쉬움.

05 여러가지 모델

▶ 랜덤 포레스트

A. 결정 트리 하나보다 거의 항상 좋은 성능을 냄. 매우 안정적이고 강력.

B. 데이터 스케일 조정 필요 없음. 고차원 희소 데이터에 잘 안 맞음.

▶ 그래디언트 부스팅 결정 트리

A. 랜덤 포레스트보다 조금 더 성능이 좋음.

B. 랜덤 포레스트보다 학습은 느리나 예측은 빠름. 메모리를 조금 사용.

C. 매개변수 튜닝이 많이 필요.

▶ 신경망

특별히 대용량 데이터셋에서 매우 복잡한 모델을 만들 수 있음. 매개변수 선택과 데이터 스케일에 민감.

큰 모데른 학습이 오래 걸림

