MACHINE LEARNING BASICS

머신러닝(Machine Learning)
데이터 처리

스케일 조정 · 원핫 인코딩 · 구간 분할 · 다항식 · 비선형 변환

v12 · 2026.10

목 차

01 **데이터 전처리와 스케일 조정**
StandardScaler · RobustScaler · MinMaxScaler · Normalizer

02 **원핫 인코딩(가변수)**
라벨 인코딩 · 원핫 인코딩

03 **구간 분할(binning)**
KBinsDiscretizer

04 **원본 특성에 다항식을 추가하기**
PolynomialFeatures

05 **비선형 변환**
log · exp

© 2026. Toto all rights reserved.

01 데이터 전처리와 스케일 조정

네 가지 스케일러 — 같은 값이 어떻게 바뀌나

꽃받침 길이 (원본, cm)	StandardScaler	RobustScaler	MinMaxScaler
5.1	-0.90	-0.54	0.22
7.0	1.40	0.92	0.75
6.3	0.55	0.38	0.56
7.9	2.49	1.62	1.00

StandardScaler
평균 0, 분산 1로 (표준화)

RobustScaler
중간값·사분위 값으로 맞춤

MinMaxScaler
0과 1 사이로 (정규화)

Normalizer
행마다 길이를 1로

붓꽃(Iris) 150송이의 꽃받침 길이에 각 스케일러를 맞춘 실제 값 중 4개 (scikit-learn 1.9.1). Normalizer는 행 단위라 표에서 제외

© 2026. Lim all rights reserved.

01 데이터 전처리와 스케일 조정

▶ 표준화(StandardScaler)

(가) 각 특성(feature)의 평균을 0, 분산을 1로 변경

(나) StandardScaler 공식

$$X_{new} = \frac{X - X_{mean}}{X_{std}}$$

© 2026. Lim all rights reserved.

01 데이터 전처리와 스케일 조정

▶ RobustScaler

(가) 통계적 측면에서 StandardScaler와 유사.

(나) 평균과 분산 대신 median과 quantile을 사용.

* outlier의 영향을 덜 받음.

* 이상치가 있고 이를 제거하지 않을 경우, RobustScaler가 유리

(다) RobustScaler 공식

$$X_{new} = \frac{X - X_{median}}{(q3 - q1)}$$

© 2026. Lim all rights reserved.

01 데이터 전처리와 스케일 조정

▶ 정규화(MinMaxScaler)

(가) 모든 특성이 정확하게 0과 1사이에 위치하도록 데이터를 변경 (학습 데이터 기준. 새 데이터는 범위를 벗어날 수 있음)

(나) MinMaxScaler 공식

$$X_{new} = \frac{X - X_{min}}{(X_{max} - X_{min})}$$

© 2026. Lim all rights reserved.

01 데이터 전처리와 스케일 조정

Normalizer — 샘플(행)마다 길이를 1로

꽃받침 길이	꽃받침 너비	→ 변환 후 길이	→ 변환 후 너비	벡터 길이
5.1	3.5	0.825	0.566	**1.0**
7.0	3.2	0.909	0.416	**1.0**
6.3	3.3	0.886	0.464	**1.0**

유클리드 길이가 1

각 샘플을 자기 길이로 나눈다. 예: $0.825^2 + 0.566^2 \approx 1$

반지름 1인 원에 투영

특성이 2개면 원, 3개 이상이면 구 위로 옮겨진다

언제 쓰나

데이터의 **방향(또는 각도)만** 중요할 때 많이 사용

붓꽃 3송이의 꽃받침 두 열을 Normalizer로 변환한 실제 값 (scikit-learn 1.9.1)

© 2026. Lim all rights reserved.

01 데이터 전처리와 스케일 조정

스케일링의 목적

왜 스케일을 맞추나

- 표준화된 스케일로 각 특성을 다시 표현하여, **너무 큰 값으로 인한 잠재적인 수치 불안정성**을 방지한다.

© 2026. Lim all rights reserved.

02 원핫 인코딩(가변수)

라벨 인코딩 — 범주형 데이터를 숫자로

Color (원본)	라벨 인코딩 결과
Red	**2**
Red	**2**
Blue	**0**
Green	**1**

라벨 인코딩
범주형 데이터는 **숫자로 변경**해야 한다

원핫 인코딩 절차
정수로 바꾼 뒤, 그 위치만 1, 나머지는 0

scikit-learn
LabelEncoder는 **정답(y)용**. 입력(X)은 OneHotEncoder

scikit-learn LabelEncoder 실제 출력 — 알파벳 순으로 Blue=0, Green=1, Red=2

© 2026. Lim all rights reserved.

02 원핫 인코딩(가변수)

라벨 인코딩과 원핫 인코딩

라벨 인코딩

- 범주 구분을 **정수 하나**로 변경
- 숫자 크기에 순서가 있는 것처럼 보일 수 있다

원핫 인코딩 (가변수)

- 범주형 변수를 표현하는 데 **가장 널리 쓰이는** 방법
- 범주형 변수를 0 또는 1 값을 가진 하나 이상의 새로운 특성으로 바꾼 것

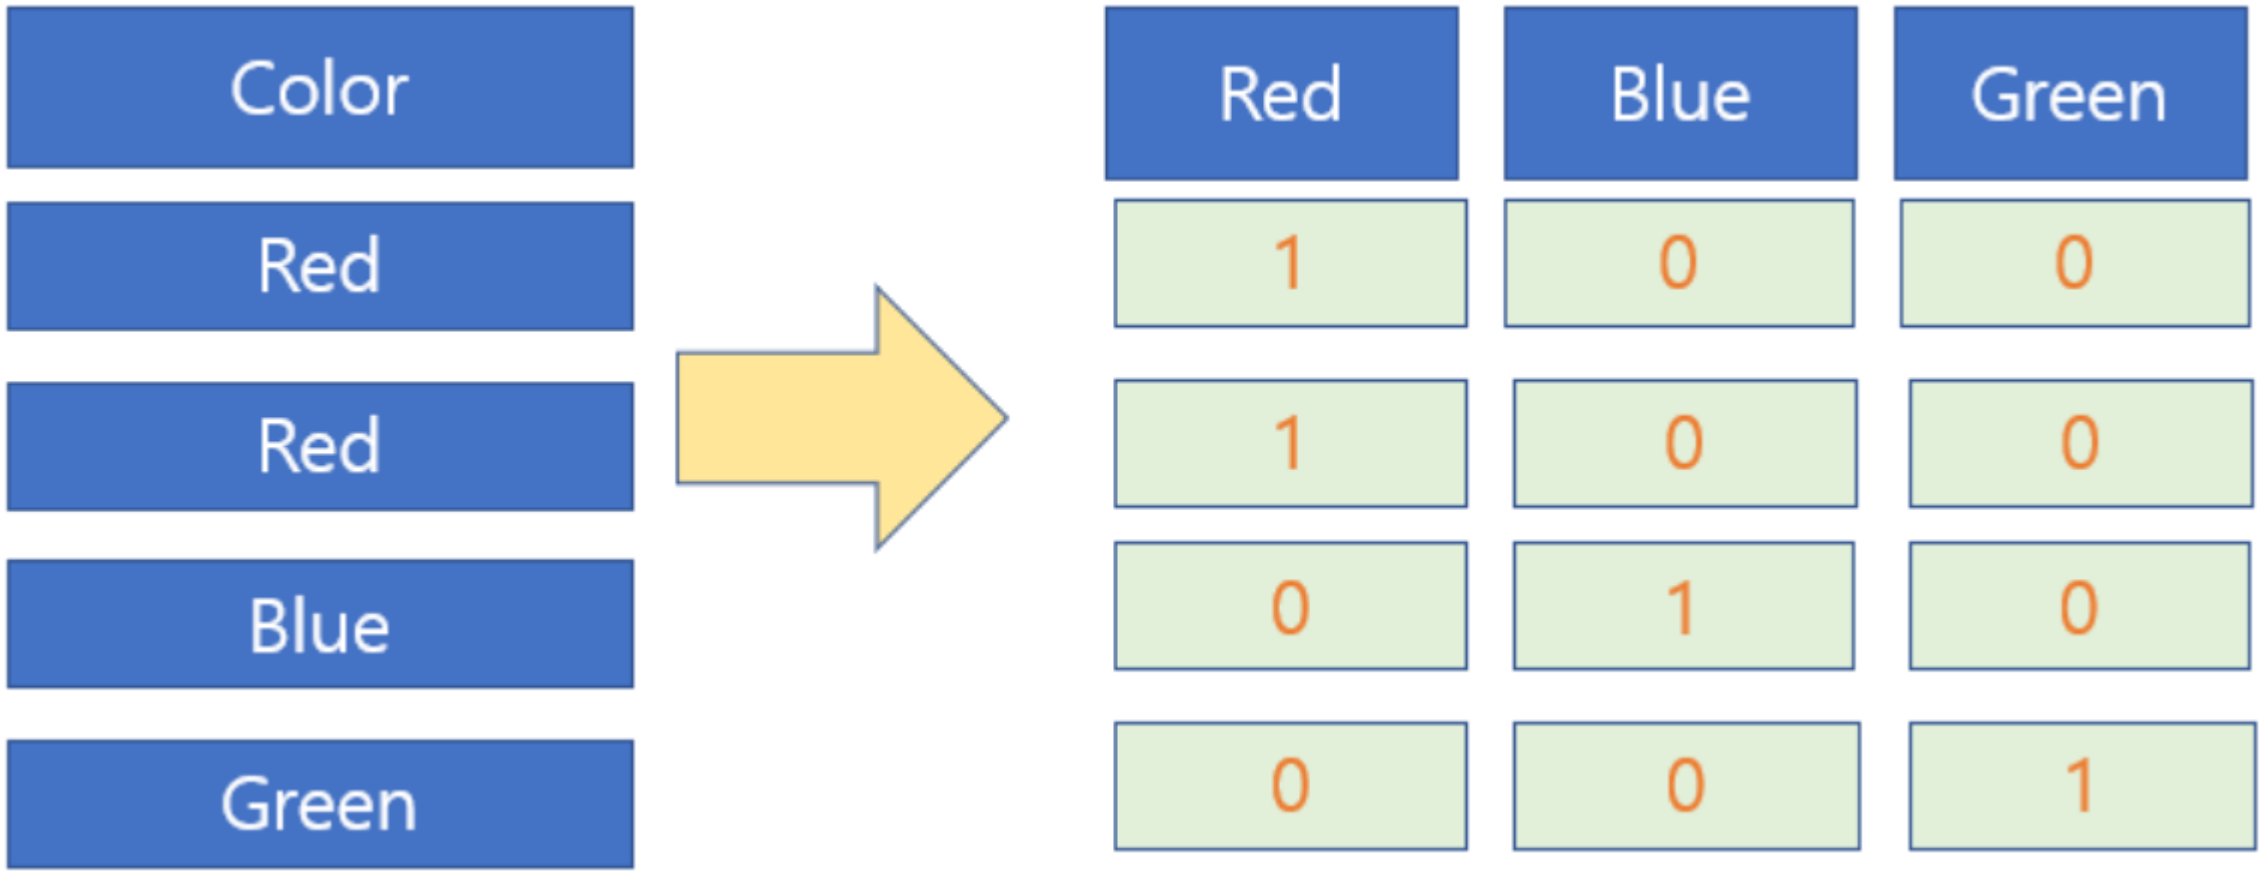
더미 코딩과의 차이

- 통계학의 더미 코딩(dummy coding)과 비슷하지만 완전히 같지는 않다. 더미 코딩은 범주 하나를 기준으로 빼서 k-1개 열을 만든다.

© 2026. Lim all rights reserved.

02 원핫 인코딩(가변수)

▶ 범주형 데이터를 이진 벡터(0,1)로 표현



© 2026. Lim all rights reserved.

03 구간 분할(binning)

한 특성을 여러 구간으로 나누기

꽃받침 길이 (cm)	구간 번호 (3구간)
5.1	**0**
7.0	**2**
6.3	**1**
4.9	**0**

구간 분할 (binning)

한 특성을 여러 구간(특성)으로 나눈다

왜 쓰나

선형 모델이 **연속형 데이터를 더 잘 다루게** 하는 방법 중 하나

scikit-learn

KBinsDiscretizer. 위 예: 4.3~5.5 / 5.5~6.7 / 6.7~7.9 (같은 너비)

붓꽃 꽃받침 길이에 KBinsDiscretizer(n_bins=3, strategy='uniform')를 적용한 실제 값 (scikit-learn 1.9.1)

© 2026. Lim all rights reserved.

04 원본 특성에 다항식을 추가하기

PolynomialFeatures — 특성 a, b로 2차 다항식 만들기

1	a	b	a^2	a·b	b^2
1	2	3	4	6	9

PolynomialFeatures

preprocessing 모듈. 원본 특성의 **제곱과 곱**을 새 특성으로 추가

예

a=2, b=3 → 2차 다항식 특성 6개 (1, a, b, a^2, ab, b^2)

효과

선형 모델이 **곡선 관계**도 표현할 수 있게 된다

PolynomialFeatures(degree=2)에 [a=2, b=3]을 넣은 실제 출력 (scikit-learn 1.9.1)

© 2026. Lim all rights reserved.

05 비선형 변환

log 변환 — 크기 차이가 큰 값을 좁히기

원본 x	log(1 + x)
1	**0.69**
10	**2.40**
100	**4.62**
1,000	**6.91**

비선형 변환

log, exp, sin 같은 **수학 함수**를 이용해 특성을 변환

효과

log, exp는 데이터의 스케일을 바꿔 선형 모델과 신경망의 **성능을 높일 수 있다**

예

1~1,000처럼 1,000배 차이 나는 값이 0.69~6.91로 좁혀진다

numpy.log1p로 계산한 실제 값

© 2026. Lim all rights reserved.