머신러닝 기초 · 비지도학습

비지도학습
기본 개념

군집 · 변환(차원 축소) · 연관 규칙

v02 · 2026.10

목차

01 **비지도학습이란**
정답 없이 구조 찾기 · 활용 분야

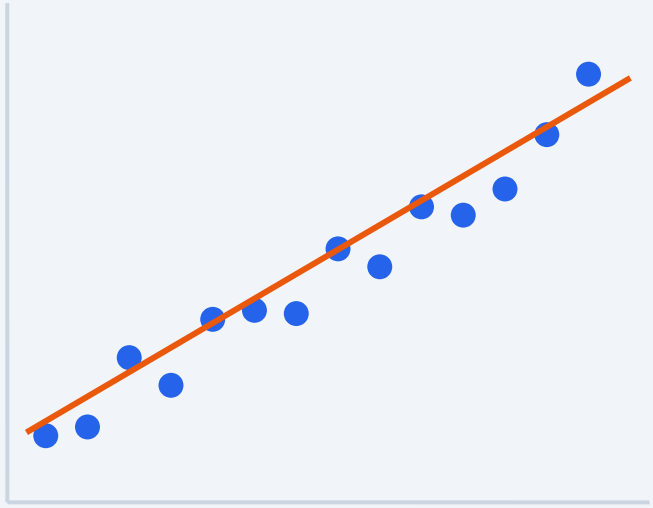
02 **군집 (clustering)**
K-means · 엘보 방법 · DBSCAN

03 **변환 (차원 축소)**
PCA · NMF · t-SNE · UMAP

04 **연관 규칙**
Apriori · FP-growth

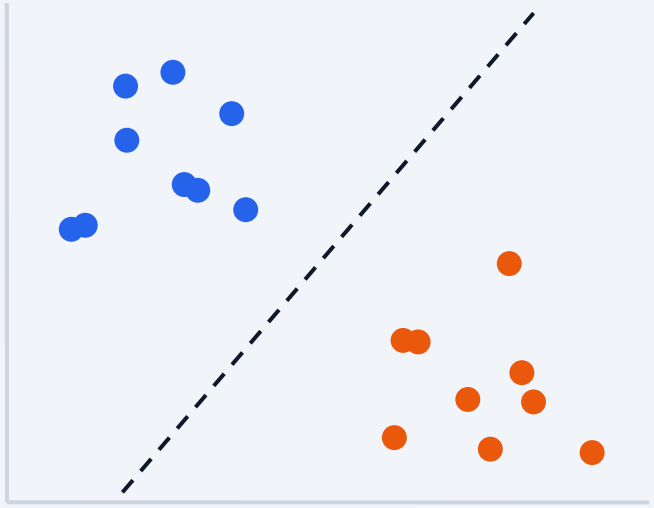
01 지도학습과 비지도학습

정답(레이블)이 있으면 지도, 없으면 비지도



회귀 (지도학습)

숫자를 예측: 점들의 **추세선**



분류 (지도학습)

정답 범주를 나누는 **경계선**



군집 (비지도학습)

정답 없이 **비슷한 것끼리** 묶기

예시 데이터로 그린 개념 그림입니다.

01 비지도학습의 세 갈래

정답 없이 데이터 구조를 찾는다

1. **군집 (clustering)**
   비슷한 데이터끼리 그룹을 만든다

2. **변환 (transform)**
   사람이나 다른 알고리즘이 다루기 쉬운 **새 표현**으로 바꾼다 (예: 차원 축소)

3. **연관 (association)**
   함께 나타나는 항목의 **규칙**을 찾는다 (장바구니 분석)

01 비지도학습이 쓰이는 곳

1. **시장 · 고객 세분화 (market segmentation)**
   구매 패턴이 비슷한 고객끼리 묶는다

2. **소셜 네트워크 분석**
   사람들 사이의 연결 구조에서 촘촘한 무리(커뮤니티)를 찾는다

3. **추천**
   비슷한 사용자, 함께 소비되는 상품 · 콘텐츠를 찾는다

02 군집 (clustering)

기본 이해

무엇을 하나

- 레이블이 **없는** 데이터를 비슷한 것끼리 묶는 비지도학습의 대표 기법

클러스터

- 비슷한 특성을 가진 데이터의 묶음
- 무엇을 '비슷하다'로 볼지(거리 · 밀도 · 확률)가 알고리즘마다 다르다

02 군집 알고리즘 종류

무엇을 정해 주고, 어떤 군집에 맞나 (scikit-learn 기본값)

	정해 주는 것	특징
K-means	군집 수 n_clusters (기본 8)	중심점 기준, 크기가 비슷한 둥근 군집에 적합
Mean Shift	bandwidth (기본: 자동 추정)	군집 수를 **자동**으로 정한다
GMM	n_components (기본 1)	각 점이 군집에 속할 **확률**을 준다
DBSCAN	eps (기본 0.5) · min_samples (기본 5)	밀도 기준, **노이즈(이상치)**를 따로 분리
계층적 (Agglomerative)	n_clusters (기본 2) · linkage (기본 'ward')	가까운 것부터 합쳐 나간다

02 K-means 동작

중심 배정 → 중심 이동을 반복

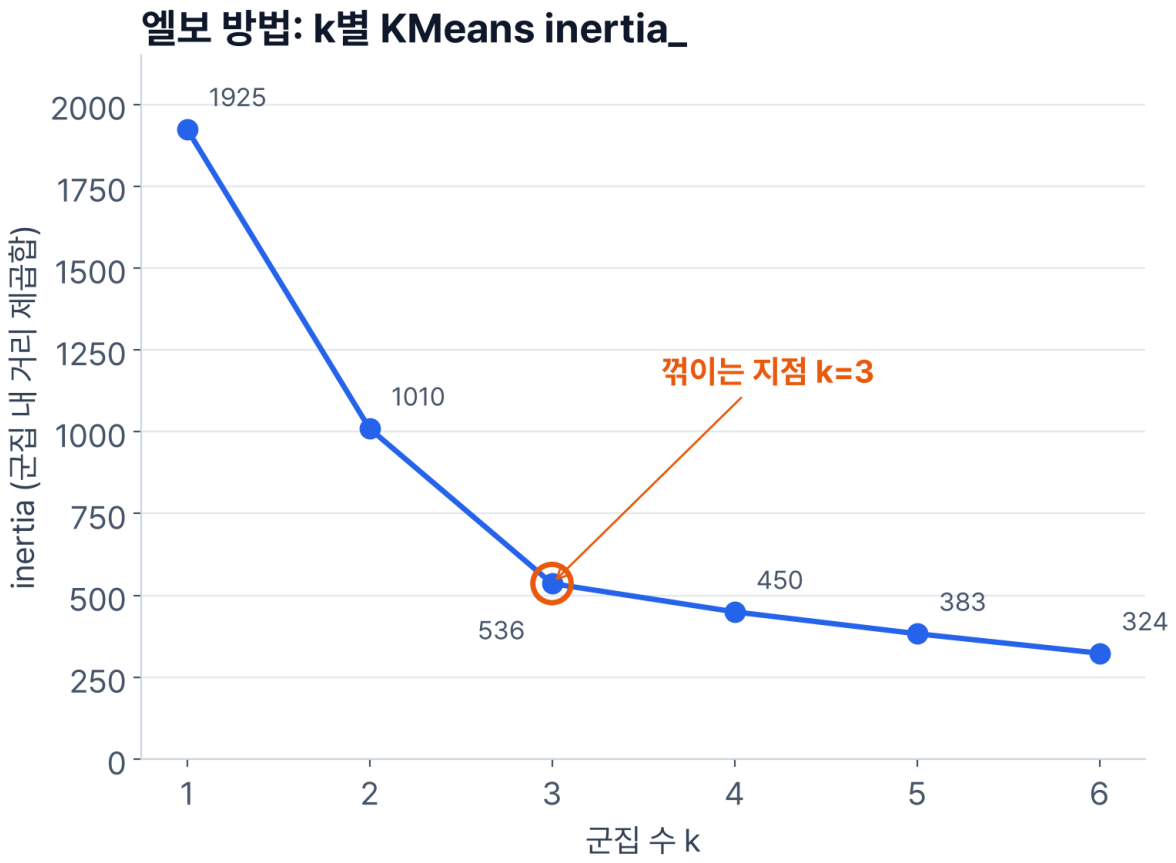
반복 과정

- ① 중심 k개를 고른다 (기본 init='k-means++': 서로 멀리 떨어지게)
- ② 각 점을 가장 가까운 중심에 배정한다
- ③ 군집별 평균으로 중심을 옮긴다 → 바뀌지 않을 때까지 ②③ 반복

scikit-learn 기본값 · 주의

- n_init 기본값은 1.4부터 **'auto'** (k-means++이면 1회 실행)
- k는 직접 정해야 한다 → 다음 장 **엘보 방법**
- 거리 기반이라 피처 **스케일링**이 필요하다

02 k 정하기: 엘보 방법



읽는 법

- k가 늘면 inertia(군집 내 거리 제곱합)는 **늘 줄어든다**
- 줄어드는 폭이 확 작아지는 꺾이는 지점을 고른다

이 데이터에서는

- k=1→2→3에서 크게 줄고 (1925→1010→536), 그 뒤는 완만
- → **k=3** (실제 중심 3개와 일치)

데이터: make_blobs(n_samples=300, centers=3, random_state=0), KMeans(random_state=0) inertia_, scikit-learn 1.9.1 실측 2026-10-13

02 DBSCAN 개념

밀도로 묶는다: eps 반경 안에 이웃이 충분하면 같은 군집

핵심 점 (core)

- 반경 **eps** 안에 이웃이 **min_samples**개 이상 (자기 자신 포함)

경계 점 (border)

- 핵심 점의 이웃이지만 스스로는 핵심 점이 아니다

노이즈 (noise)

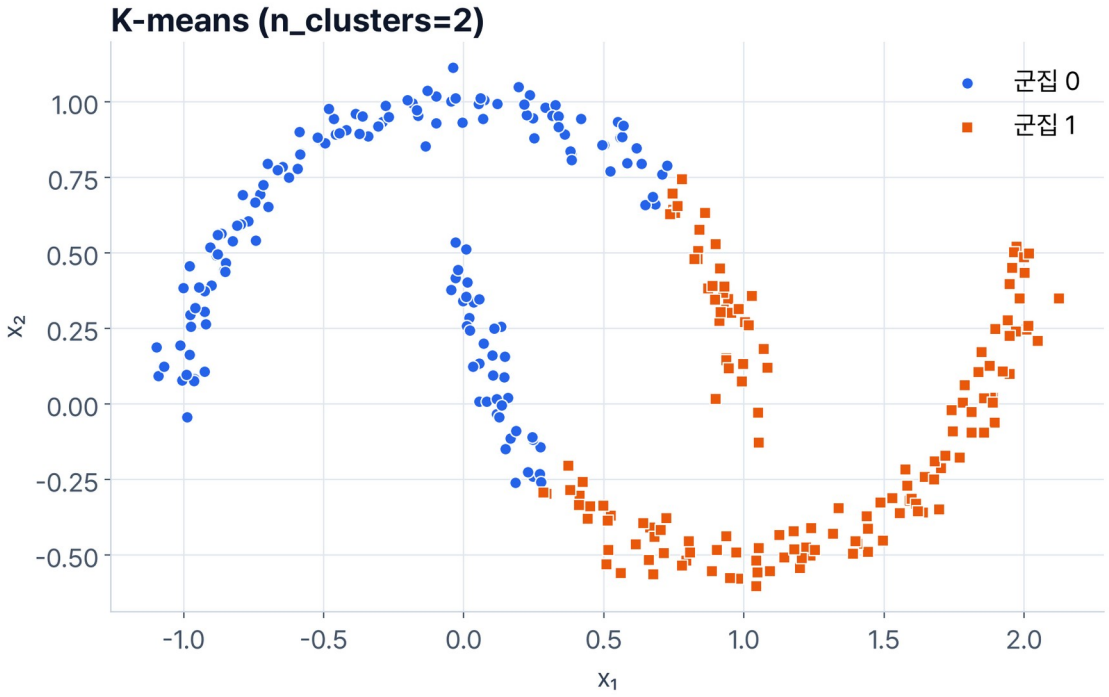
- 어느 군집에도 속하지 않는 점. 레이블 **-1**

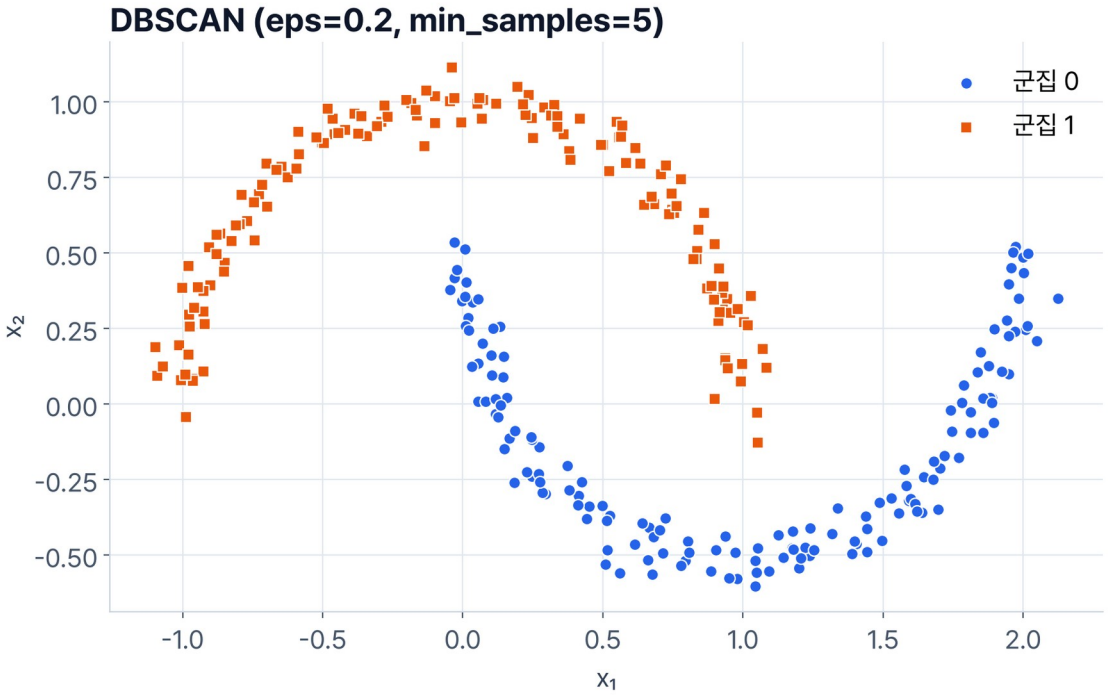
특징

- 군집 수를 정하지 않는다
- 모양이 자유로운 군집을 찾는다
- 기본값 eps=0.5, min_samples=5

02 K-means vs DBSCAN

반달 모양 데이터: 중심 기준과 밀도 기준의 차이





K-means: 반달을 가로질러 자른다

중심에서의 거리만 보므로 둥근 군집을 가정한다

DBSCAN: 반달 두 개를 그대로 찾는다

이어진 밀집 영역을 따라 묶는다 (eps=0.2로 지정)

데이터: make_moons(n_samples=300, noise=0.05, random_state=0) · KMeans(n_clusters=2, random_state=0) · DBSCAN(eps=0.2, min_samples=5), scikit-learn 1.9.1 실측 2026-10-13

03 변환

데이터를 새롭게 표현하기

정의

- 기존 데이터를 더 쉽게 해석하거나 다른 알고리즘에 넣기 좋게 **새로 표현**하는 비지도 알고리즘. 대표가 **차원 축소**

차원 축소의 대표 방법

- **PCA**: 분산이 큰 직교 축으로 축소 (선형) → 「PCA」 덱
- **NMF**: 음수가 없는 데이터를 부분의 합으로 분해 (선형)
- **t-SNE · UMAP**: 비슷한 점을 가깝게 두는 비선형 축소, 주로 시각화용 (UMAP은 umap-learn 패키지)

04 연관 규칙 (association)

함께 일어나는 패턴 찾기

무엇을 하나

- 거래 기록에서 **함께 나타나는 항목**의 규칙을 찾는다
- 예) {라면} ⇒ {김치}: 라면을 산 거래에는 김치도 함께 있는 경우가 많다

규칙을 고르는 기준

- 지지도(support): 두 항목이 함께 나온 거래의 비율
- 신뢰도(confidence): 라면 거래 중 김치도 있는 비율

어디에 쓰나

- 함께 사는 상품 추천 · 진열 · 묶음 할인

04 연관 규칙 알고리즘

Apriori vs FP-growth

Apriori (1994)

- 자주 나오는 항목 집합을 찾는 대표 알고리즘
- **후보 집합**을 만들고 데이터를 여러 번 훑으며 걸러 낸다

FP-growth (2000)

- 데이터를 **FP-tree**로 압축한다
- **후보 집합 생성 없이** 빈발 패턴을 찾아 DB 스캔이 적다

참고

- 연관 규칙 마이닝은 AIS 알고리즘(Agrawal · Imieliński · Swami, 1993)이 먼저 제안했고 Apriori가 이를 개선했다. 논문 정보는 노트 (확인일 2026-10-13)

정리 비지도학습 한 장 요약

군집

K-means: k를 정한다 (엘보 방법)

DBSCAN: 밀도 기준, 노이즈 분리

변환

PCA · NMF: 선형 차원 축소

t-SNE · UMAP: 비선형, 주로 시각화

연관

{A} ⇒ {B} 규칙, 지지도 · 신뢰도

Apriori · FP-growth

공통

정답 없이 **데이터 구조**를 찾는다

거리 기반이면 스케일링 먼저