> 🛠️ **2026.10 수정본 (v11)** — 원본: `ref_ch04_01_02_FE_OneHotEncoding_02.ipynb`
>
> - scikit-learn 1.4부터 `OneHotEncoder(sparse=False)`가 `sparse_output=False`로 이름이 바뀌어서 고쳤어요.
> - 실습 3(keras `to_categorical`)은 TensorFlow/Keras가 필요해요. 코랩에는 깔려 있고, 내 PC에서는 `pip install tensorflow` 후 실행하세요 (2026.10 TensorFlow 2.21 · Keras 3.15로 실행 확인).

One-hot encoding 정리해보기

학습 목표

> 가. 정수 인코딩과 원핫 인코딩은 무엇인가?
> 나. scikit-learn, Pandas, Keras 라이브러리를 사용하여 파이썬에서 데이터를 레이블 인코딩에 대해 알아본다.
> 다. scikit-learn 및 Keras 라이브러리를 사용하여 OneHotEncoding 하는 방법 알아보기

학습내용

- 1. 간단 One-hot encoding 해보기
- 2. 개요
- 3. One-hot encoding 이란?
- 4. 왜 One-hot encoding를 사용하는가?
- 5. scikit-learn를 이용한 One-hot encoding 해보기
- 6. One-hot encoding with Keras (케라스 이용)
- 7. One-hot encoding with pandas

In [1]:
```
from IPython.display import display, Image
```

01. 기본 실습 - One-hot encoding

> 간단한 데이터를 준비하여, 목표 feature인 'target'를 labelencode 후, 이후, 결과값을 이용하여 one-hot-encoding를 수행한다.

가. 데이터 준비

In [2]:
```
### 01. 데이터 준비
import pandas as pd
data = { "feature1":[2,3,8,4],
```

```
        "feature2":[22,32,82,42],
        "target": ["b","c", "a", "d"]
       }
df = pd.DataFrame(data)
df
```

Out[2]:

	feature1	feature2	target
0	2	22	b
1	3	32	c
2	8	82	a
3	4	42	d

In [3]:
```
from sklearn import preprocessing
```

나. LabelEncoder하기

a,b,c,d가 숫자 0,1,2,3로 변경

In [4]:
```
label_encoder = preprocessing.LabelEncoder()
df['lbl_en'] = label_encoder.fit_transform(df['target'])
df
```

Out[4]:

	feature1	feature2	target	lbl_en
0	2	22	b	1
1	3	32	c	2
2	8	82	a	0
3	4	42	d	3

다. 행렬변경(4X1)

In [5]:
```
train_y = df['lbl_en'].values.reshape(len(df), 1)
train_y
```

Out[5]:
```
array([[1],
       [2],
       [0],
       [3]])
```

라. One-hot encoding 하기

- 범주형 변수를 one-hot 수치형 배열로 변환

In [6]:
```
import sklearn
print(sklearn.__version__)
```

```
1.9.1
```

In [7]:
```
onehot_encoder = preprocessing.OneHotEncoder(sparse_output=False)
train_y_onehot = onehot_encoder.fit_transform(train_y)
print(train_y_onehot)
print(train_y_onehot.shape)
```

```
[[0. 1. 0. 0.]
 [0. 0. 1. 0.]
 [1. 0. 0. 0.]
 [0. 0. 0. 1.]]
(4, 4)
```

실습

- A. OneHotEncoder의 sparse를 True로 하면 어떤 결과가 나오는가?
- B. 희소 행렬은 무엇을 의미하는가?
- C. 변경한 내용을 기존의 데이터에 붙여보기

02. 개요

- **A. 머신러닝 알고리즘은 범주형 데이터에서 직접적으로 작동하지 않는다.**
- **B. 범주형 데이터는 숫자로 변경되어야 함.**

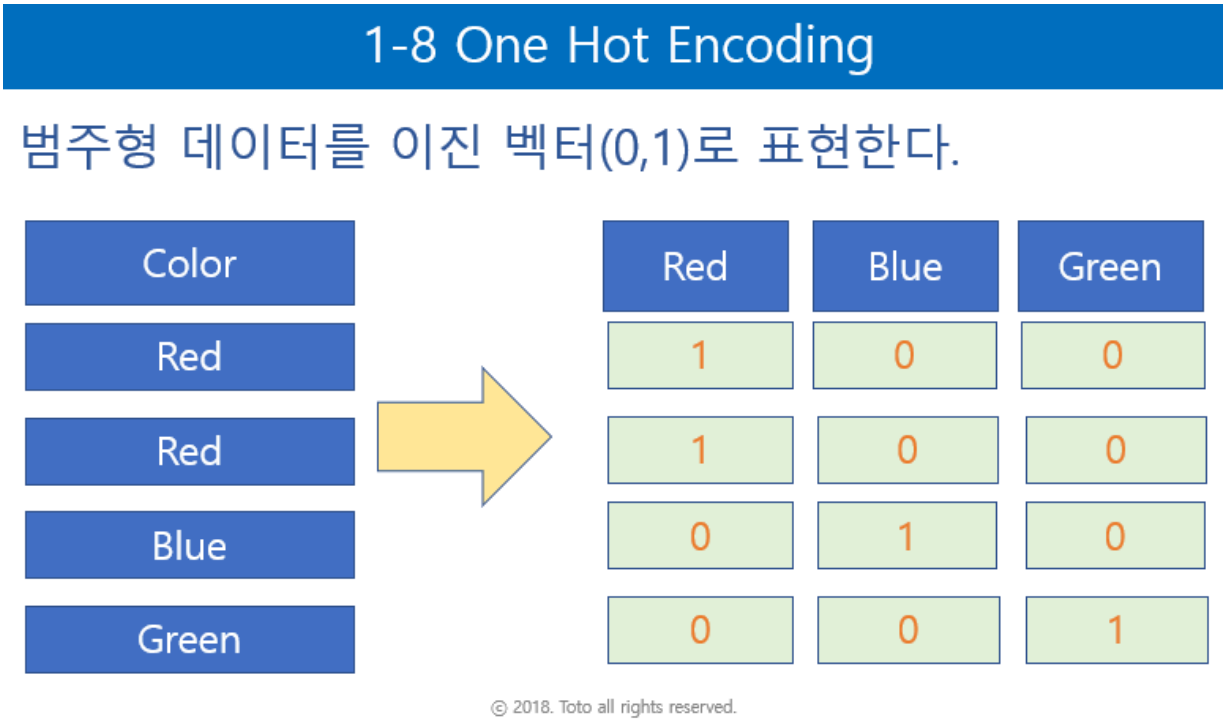
  Categorical data must be converted to numbers.
- **C. 신경망과 같은 심층적인 학습 방법을 사용할 때 적용.**

  This applies when you are working with a sequence classification type problem and plan on using deep learning methods such as Long Short-Term Memory recurrent neural networks.

03. One-hot encoding이란?

```
* 가. One-Hot Encoding은 범주형 변수를 바이너리벡터(0,1)로 표현한 것.
나. 작업 절차는
    A. 범주형 변수는 정수값으로 변경되어야 하고,
    B. 각각의 정수값은 해당되는 위치에 1로 표시되고 나머지는 0으로 표시.
```

In [8]:
```
display(Image(filename='img/onehotencoding.png'))
```



'red', 'red', 'blue', 'green'

정수로 encoding하기 (정보의 형태나 형식을 변환하는 처리방식)

0,0,1,2

one hot encoding하기

```
[1,0,0]
[1,0,0]
[0,1,0]
[0,0,1]
```

실습 1

spring, summer, autumn, winter을 레이블 인코딩, OneHotEncoding를 해보자.

04. 왜 One-hot encoding를 사용하는가?

가. 범주형 데이터를 숫자로 변경합니다. 단 이 데이터는 자연스러운 순서가 있다.
하지만 순서가 없을 경우, 문제가 될 수 있습니다.
(dog, cat, bird..)
나. 이 경우, 좀 더 표현력이 있는 One-hot encoding 방법을 이용하면 더 정밀한 예측을 가능하게 된다.

05. scikit-learn를 이용한 One-Hot Encoding

가. 우리는 4개의 레이블을 가지고 있다.

```
'spring', 'summer', 'autumn', 'winter'
We will assume the case where you have an output sequence of
the labels
```

나. 10개의 데이터를 가지고 있다.

```
spring, spring, summer, spring, autumn, autumn, winter,
spring, summer, autumn
```

다. scikit-learn 라이브러리(library)를 이용

```
LabelEncoder : label를 정수값으로 변경
OneHotEncoder : 정수로 인코딩된 값을 One Hot Encode로 만든다.
```

In [9]:

```
from numpy import array
from numpy import argmax
from sklearn.preprocessing import LabelEncoder
from sklearn.preprocessing import OneHotEncoder

data = ['spring', 'spring', 'summer', 'spring', 'autumn',
        'autumn', 'winter', 'spring', 'summer', 'autumn']
values = array(data)
print(values)

# integer encode
label_encoder = LabelEncoder()
integer_encoded = label_encoder.fit_transform(values)
print(integer_encoded)

# binary encode
onehot_encoder = OneHotEncoder(sparse_output=False)
integer_encoded = integer_encoded.reshape(len(integer_encoded), 1)
onehot_encoded = onehot_encoder.fit_transform(integer_encoded)
print(onehot_encoded)

# LabelEncoder에 입력하여 역변환 4번째 행의 값을 되돌리기
inverted = label_encoder.inverse_transform([argmax(onehot_encoded[4, :])])
print(inverted)
```

```
['spring' 'spring' 'summer' 'spring' 'autumn' 'autumn' 'winter' 'spring'
 'summer' 'autumn']
[1 1 2 1 0 0 3 1 2 0]
[[0. 1. 0. 0.]
 [0. 1. 0. 0.]
 [0. 0. 1. 0.]
 [0. 1. 0. 0.]
 [1. 0. 0. 0.]
 [1. 0. 0. 0.]
 [0. 0. 0. 1.]
 [0. 1. 0. 0.]
 [0. 0. 1. 0.]
 [1. 0. 0. 0.]]
['autumn']
```

06. One Hot Encode with Keras

케라스에서는 one hot encode를 위해 to_categorical() 함수를 제공한다.

In [10]:
```
from keras.utils import to_categorical
import numpy as np

# define example
data = [15,17,5,10,0]
dat = np.array(data)
print(dat)

# one hot encode
encoded = to_categorical(dat)
print(encoded)
```

```
[15 17  5 10  0]
[[0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 1. 0. 0.]
 [0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 1.]
 [0. 0. 0. 0. 0. 1. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0.]
 [0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 1. 0. 0. 0. 0. 0.]
 [1. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0.]]
```

In [11]:
```
encoded[0]
```

Out[11]:
```
array([0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 0., 1., 0.,
       0.])
```

In [12]:
```
# invert encoding
inverted = argmax(encoded[1])
print(inverted)
```

```
17
```

실습 2(scikit)

집을 선택할 때, 다음과 같은 유형의 조건이 있다.
Inside, Corner, FR2, CulDSac 이에 대한 정보를 레이블 인코딩, OneHotEncoding를 해보자.

실습 3 (keras)

Inside, Corner, FR2, CulDSac 이에 대한 정보를 레이블 인코딩, OneHotEncoding를 해보자.

07. One Hot Encode with Pandas

판다스에서는 one hot encode를 위해 get_dummies() 함수를 제공한다.

In [13]:
```
import pandas as pd
import os
```

In [14]:
```
demo_df = pd.DataFrame({"범주형_feature":['양말', '여우', '양말', '상자']})
display(demo_df)
```

	범주형_feature
0	양말
1	여우
2	양말
3	상자

In [15]:
```
onehot = pd.get_dummies(demo_df)
onehot
```

Out[15]:

	범주형_feature_상자	범주형_feature_양말	범주형_feature_여우
0	False	True	False
1	False	False	True
2	False	True	False
3	True	False	False

In [16]:
```
df = pd.concat([demo_df, onehot], axis=1)
df
```

Out[16]:

	범주형_feature	범주형_feature_상자	범주형_feature_양말	범주형_feature_여우
0	양말	False	True	False
1	여우	False	False	True
2	양말	False	True	False
3	상자	True	False	False